

仵明雨

性别：男

工作经验：1 年

电话：17638682387

邮箱：wmy3125005@163.com

教育经历

郑州西亚斯学院 区块链工程 本科（统招-四年学制提前修完学分毕业） 2022.09~2025.07

- 2023 年第五届码蹄杯程序设计大赛/国级/铜奖
- 2024 年(首届)河南省高等学校信息技术应用创新大赛-开源鸿蒙竞赛/省级/二等奖
- 2024 年第六届全国高校计算机能力挑战赛程序设计挑战赛/省级/三等奖

相关技能

- 熟悉主流大模型的 API 调用，掌握流式响应、错误重试、动态限流及多模型兼容封装。
- 掌握 Tool Calling/Function Calling 机制，能实现模型与外部工具的结构化输出解析与交互。
- 熟悉统一 LLM Gateway 设计能力，支持多模型路由、供应商切换、请求日志记录与成本统计。
- 掌握 vLLM/SGLang/TGI/llama.cpp/Ollama 等本地推理方案，理解其在私有化部署中的场景差异。
- 掌握 RAG 全链路技术，能实现语义分块、混合检索 BM25+Dense 及 Cross-Encoder Rerank 重排序。
- 熟练使用 Milvus/Chroma/Weaviate/pgvector 等向量数据库，掌握 HNSW/IVF 索引原理与调优。
- 熟练使用 LangChain/LlamaIndex 构建 RAG 与 Agent 应用，深入理解其核心组件与抽象机制。
- 熟练掌握 LangGraph 编排框架，能构建包含条件分支、循环及状态持久化的多 Agent 协作流。
- 掌握 Tool Use 全链路工程，包括动态工具注册、Schema 自动生成、参数校验、执行沙箱隔离与错误恢复。
- 具备 Agent 状态机设计能力，能实现任务中断恢复、幂等执行、死循环检测与人工审批阻断。
- 熟练掌握 FastAPI 异步 Web 开发，能运用依赖注入、中间件、后台任务等模式构建 RESTful API。
- 熟练使用 PostgreSQL/MySQL 进行业务元数据建模，掌握 SQLAlchemy 进行常规 CRUD 操作；
- 掌握 Redis 在 AI 场景中的应用，能实现会话上下文缓存、Token 配额管控及分布式锁。
- 掌握 Docker/Docker Compose 容器化部署，能编写包含 Python 依赖及基础运行环境的完整镜像。
- 掌握 Few-shot Learning 样本选择策略，能为复杂任务设计可验证的 Prompt 模板。
- 熟悉基于嵌入相似度的动态示例检索 Dynamic Few-shot 及样本质量评估方法。
- 掌握 Vision-Language Model 的图像理解、OCR 及图表分析能力；了解视频关键帧抽取与字幕转写流程。
- 熟悉 MCP 基本架构，理解 Client/Server/Tool 等核心概念，能基于 MCP 封装基础外部工具。
- 熟悉企业内部系统与 AI-Agent 的连接方式，掌握 OAuth、APIKey、Token 代理及最小权限控制等鉴权机制。

工作经历

天翼云科技有限公司上海分公司

全栈工程师

2025.07-2026.09

项目经历

星海 TeleBI 数据智能 Agent

项目说明：面向天翼云政企客户"有数据不会用"的普遍困境，基于大模型与多 Agent 编排构建对话式数据智能平台。业务人员在飞书中用自然语言提问，系统自动完成意图理解、指标口径匹配、SQL 生成执行、图表渲染与归因分析的完整链路，将传统需要 IT 排期数天的取数分析流程缩短为秒级对话交互，支撑天翼云从"卖基础设施"向"卖数据智能服务"的产品升级。

技术说明：Python、FastAPI、HermesAgent、Qwen-Max、text-embedding-v3、Milvus、MySQL、Redis、sqlglot、matplotlib、飞书开放平台、Vue3、ElementPlus

工作内容：

- 基于 HermesAgent 框架实现对话引擎，通过意图识别与 Skills 路由将用户提问分发至 Text-to-SQL、指标问答、归因分析等链路，组装飞书消息卡片返回图表与结论，支持多轮对话上下文继承与追问下钻。
- 通过 Prompt 工程将元数据 Schema、Few-shot 示例和 RAG 召回的指标口径拼装驱动 Qwen 生成 SQL，用 sqlglot 做 AST 语法校验与安全改写，EXPLAIN 拦截高危查询计划，失败自动重试。
- 基于 RAG 构建指标语义层，使用百炼 Embedding 将指标定义向量化写入 Milvus，查询时语义检索 Top-K 口径注入 LLM 上下文，确保 SQL 生成和归因分析基于统一权威定义。
- 数据 Agent 多维度下钻定位异常，分析 Agent 统计归因标注置信度，建议 Agent 生成行动建议；LLM 仅用于报告文案生成，数据计算走 SQL 确保有据可查。
- 权限中间件拦截后自动注入行级 WHERE 过滤与列裁剪，敏感字段自动脱敏，全部操作落 MySQL 审计日志。
- sqlglot 拒绝 DDL/DML，黑名单拦截危险函数，自动追加 LIMIT 限制结果集，SQLAlchemy statement_timeout 控制超时，失败重试三次后兜底提示。
- 基于 Redis 实现多轮对话状态管理，存储对话历史，Agent 处理追问时提取前序维度与时间范围，支持指代消解与条件扩展。
- 基于 FastAPI+SQLAlchemy 搭建 RESTful 管理 API，Vue3+ElementPlus 搭建前端，支持指标审核发布、数据源注册、Schema 同步、权限配置和审计日志查看。

星海 AI 智能知识库

项目说明：面向天翼云数百种云产品运维文档体量大、跨产品关联故障排查难、传统关键词知识库"搜不到、答不准、更新慢"的问题，基于 RAG 混合检索与 LangGraph 多步推理编排构建运维智能问答 Copilot。运维工程师用自然语言描述故障现象即可获得带引用来源的答案，系统通过反馈审核闭环持续进化知识质量。

技术说明：Python、FastAPI、LangChain、LangGraph、qwen-plus、text-embedding-v3、Milvus、MySQL、Vue3、ElementPlus、Docker

工作内容：

- 基于 LangGraph 编排运维问答 Agent 工作流，将意图识别、护栏校验、复杂问题拆解、混合检索、答案生成、引用校验编排为可分支可降级的状态图，通过 SSE 流式输出带引用来源的答案。
- 实现 RAG 知识入库流水线，对 PDF/Word/Markdown 等运维文档解析切块后向量化写入 Milvus，每个 chunk 携带产品线与版本 metadata 支持按条件过滤，文档更新时增量替换旧数据。
- 基于 Milvus 单引擎实现 dense 向量语义检索+BM25 关键词全文检索的混合检索，通过 RRF Ranker 融合两路召回结果，按 metadata 过滤产品线和版本，兼顾语义同义词召回与错误码、命令行等精确关键词匹配。

- Prompt 要求 LLM 基于检索片段生成答案并标注引用编号，引用校验节点验证每个编号对应真实检索结果，校验失败剔除无源结论重新生成，检索不到时直接拒答而非编造。
- 实现 Guardrails 护栏机制，在检索前对高危操作类问题和敏感话题做规则匹配，命中 block 规则直接拦截返回固定话术，命中 confirm 规则前置风险提示后继续检索，规则支持管理员在后台动态配置。
- LangGraph 判断问题涉及多产品联动时自动拆解为多个子问题，各子问题并行混合检索后融合去重，解决单一检索无法覆盖跨产品链路的问题。
- 工程师点踩自动生成审核任务，管理员在审核工作台查看问答记录与引用片段后判定原因，触发文档增量重入库替换过时知识，形成使用→反馈→修正→重入库的持续进化链路。
- 基于 FastAPI+SQLAlchemy 搭建 RESTful 后端，Vue3+ElementPlus 搭建前端，支持文档上传与入库进度监控、运维问答与历史记录、护栏规则维护、反馈审核工作台等功能页面。

自我评价

- 面对陌生领域或突发变化时，能快速调整状态并制定学习计划，不畏惧试错，将挑战视为能力拓展的契机。
- 工作风格稳健细致，注重时间管理与成果校验，即使在紧迫周期内也能守住质量底线，确保任务可靠落地。
- 具备良好的团队融入力，乐于分享信息、响应协作需求，在集体项目中主动补位，营造正向合作氛围。
- 工作有主人翁意识，遇到困难优先思考对策，虚心接纳他人建议并即时修正，追求持续改进而非一次性完成。
- 对技术和业务保有纯粹的好奇心，甘于从基础事务做起，相信扎实积累是成长的唯一路径，拒绝浮躁。
- 为人真诚坦率，尊重师长与同事的经验传授，以空杯心态吸收养分，努力成为团队中值得信赖的伙伴。