

个人简历

PERSONAL RESUME

姓名：冯强

邮箱：18834202687@163.com

电话：18834202687



求职意向

意向岗位：NLP 算法工程师

教育经历

西安工商学院

2017.9-2021.6

计算机科学与技术 | 本科

工作经历

2025.7 至 2026.4

开通金融

AI 算法工程师

深度参与金融公司内部项目全生命周期管理，基于不同业务线的差异化需求，主导多个垂直领域项目的规划与落地，覆盖智能服务（智能客服、AI 动漫）、企业协同（企业微信监控）、效能工具（票务预定、API 聚合）等核心板块，确保项目高效交付与业务目标达成。

深度开发 AI 动漫创作平台的全流程开发，集成国内外主流多模态模型能力，构建覆盖智能分镜、资产生成（人物/场景/道具）、图片/视频生产的完整工作流。基于前端无限画布实现可视化拖拽编排，并搭载 Agent 智能体支持自然语言交互，用户可通过对话式指令自动生成分镜资产及成片，降低专业创作门槛。

独立负责鸿联九五 RAG 模块架构设计与开发，协同完成 TTS、ASR 等语音交互模块的功能迭代。基于公司自有客服通话数据训练 ASR 模型，并融合百度多音色 ASR 能力，构建支持普通话、英语、粤语的多语种识别体系，覆盖国内主流语言场景，具备方言扩展能力。

负责 TMC-Bot 智能票务系统的 Agent 架构设计与开发，基于 LangGraph 框架搭建多 Agent 协作系统，支持机票预订、退票、改签及行程信息修改等全场景闭环处理。对接暖界商旅平台，实现企业微信内自然对话式交互，意图识别准确率达 X%。联动企业内部微信监控工具，构建人机协同机制，确保高复杂度场景下无缝转接人工并实时预警值班人员。

独立搭建企业微信监控平台与大模型 API 聚合中台两大基础设施工具，面向公司内部项目提供标准化能力支撑。API 聚合平台统一封装多厂商大模型调用接口，实现鉴权、限流、计费、路由的集中管控，降低业务线接入成本；企微监控平台打通消息推送、状态监控、异常告警链路，为各项目提供统一的企微生态接入入口与运维观测能力。

参与理想汽车内部管理系统的智能化项目研发，针对多业务场景定制化实现各类算子逻辑，灵活响应实际业务需求。基于不同模型能力及应用目标，设计并持续优化多种 Prompt 策略，通过 Prompt 工程精细化调控大模型行为，实现业务效果最大化。

主导 NL2SQL、维度抽取、多轮问答、Query 标准化与意图识别等关键模型的训练与调优，确保模型在复杂场景下的稳定性与持续迭代能力。

构建高质量训练数据集，设计并落地数据一致性校验算子，有效提升模型泛化能力与输出准确性。

设计 SSC (Shared Service Center) 领域 AI 助手整体架构，完成基于 RAG 与 Agent 的人力智能助手搭建，实现对 SSC 政策知识的高效理解与智能应答。

深入阅读并复现李飞飞团队 S1K 模型相关论文，复现其训练与推理流程。结合 Budget Forcing 方法，在满足计算资源约束的前提下，有效激发大模型的通用能力，提升多任务场景下的表现。

部署和微调 ChatGLM、LangChain 和其他大型 NLP 模型，以支持公司的自然语言处理需求。

设计和训练 Transformer 和 BERT 模型，用于情感分析、命名实体识别和知识图谱构建。

设计和训练 T5 模型，开发文本纠错系统，提高文本数据的质量和准确性。

职业技能

大模型部署和微调，LangChain。

问答机器人、文本分类、命名实体识别、情感分析、知识图谱、文本纠错和机器翻译等任务。

Transformer、BERT、GPT 等预训练语言模型架构原理。

Bagging、Boosting、Stacking 等集成学习。

Pytorch、Tensorflow 等深度学习框架。

Numpy、Pandas、Scikit-learn 等第三方库。

熟悉 Python 语言。

了解 RAG 流程搭建。

整体项目流程的构建及优化。

Agent 的搭建以及归因分析的设计。

业务知识的快速整理以及落地。

设计 AI 动漫平台、模型聚合平台。

项目经历

AI Animation

项目需求

深度参与 AI 动漫创作平台的全栈能力建设，目标是通过 AIGC 技术重构漫剧生产流程。平台集成 Agent 智能体、图片/视频生成、分镜自动化、剧本拆解、资产提取、姿势调整、智能抠图、局部重绘八大核心模块，支持"对话即创作"与"精细化手动编辑"双模式：用户可通过自然语言对话驱动 Agent 自动完成分镜视频生成，也可调用单点能力进行个性化内容创作，实现从创意到成片的端到端覆盖。

项目实施

基于 LangGraph 框架构建多 Agent 协同系统，采用"Agent 编排层+模型能力层"解耦架构。Agent 层聚焦创意流程，下设项目初始化（剧本拆解、风格定义、资产提取等）与分镜设计（场景生成、镜头调度、镜头生成等）两大独立模块；图片/视频生成等重算力任务则直接调用 API 聚合平台能力，通过前端直链模式完成，避免 Agent 系统阻塞，实现创作流程与生成效率的最优平衡。

项目初始化模块的架构设计，基于 LangGraph 多 Agent 框架实现剧本智能拆解与资产自动化提取。采用决策 Agent 统一路由+子 Agent 垂直处理模式，针对人物、角色、道具三类异构资产，设计差异化 Prompt 策略并行提取，提升处理效率。针对剧本格式不统一的行业痛点，前置格式理解 Agent：将 5000 字剧本内容送入大模型进行结构解析，输出标准化格式模板，指导后续精准拆解，解决多源剧本的兼容性问题。

设计分镜自动化生成引擎，基于剧本块并行提取场景单元（单分镜≈5 秒），按幕结构+时间线双维度排序重组，确保叙事连贯性。提取过程中实时关联已沉淀的资产库，强制校验分镜元素与全局资产的一致性，避免模型随意生成导致的风格漂移，保障视觉统一性。

主导分镜设计模块的交互与生成链路，支持对话驱动+自主生成双模式。对话模式下，Agent 融合用户输入与资产库内容生成定制化分镜；自主模式下，Agent 基于分镜信息自动合成首帧图，并智能调度聚合平台模型完成视频生成（文生图/图生视频链路自动衔接）。生成前向用户展示 Prompt 预览确认，生成结果实时回传至前端无限画布，支持可视化拖拽编排与二次调整，实现"AI 生成-人工干预-灵活组合"的闭环创作体验。

设计智能模型调度系统，赋予决策 Agent 模型选型能力。通过 Prompt 使 Agent 掌握各多模态模型的特性边界（生成质量/速度/成本/风格），结合用户输入语义与 LangGraph 全局记忆推断用户偏好，动态匹配最优模型。模型调用参数自动从分镜表结构化提取，实现"理解-决策-执行"的全自动化链路。

项目结果

基于 LangGraph 多 Agent 框架构建智能分镜系统，采用"编排层+能力层"解耦架构，实现剧本自动拆解、资产智能提取与分镜自动化生成。通过决策 Agent 统一路由与差异化 Prompt 策略，解决多源剧本兼容性问题；设计双模式交互链路支持对话驱动与自主生成，结合智能模型调度系统动态匹配最优多模态模型。项目成功打通"AI 生成-人工干预-灵活组合"的闭环创作流程，显著提升影视前期制作效率与视觉统一性。

API 聚合平台

项目需求

主导多模态大模型 API 聚合中台建设，旨在解决漫剧 Agent 场景下多厂商模型调用标准不一、管理分散的问题。平台统一封装市面上主流多模态模型（文生图/图生视频/语音合成等）的接口协议与入参规范，实现鉴权、路由、限流、计费的集中化管控，并提供调用频次、成功率、成本消耗的全维度监控看板，为业务线提供开箱即用的模型能力与数据驱动的选型决策支持。

项目实施

主导多模态模型聚合中台的核心架构实现，统一接入 Nano Banana、Seedance、Seedream、Veo、Kling、Hailuo 等主流文生图/视频模型。设计参数映射层解决多厂商协议差异，将异构入参标准化为统一接口规范；构建模型配置中心，基于 SQL 数据库存储各模型分辨率、比例、时长等差异化能力配置，实现前端动态渲染与热更新；采用异步任务，统一封装为 TaskId 驱动查询模式，支撑高并发场景下的长时任务处理与状态追踪，并最后进行落库记录。

设计智能路由与容灾降级系统，解决国外模型中转平台不稳定及谷歌官方算力波动问题。构建多活节点池（同一模型多平台接入）+ 实时健康检查机制，当检测到超时或异常时自动触发同级模型无缝切换，确保生成任务高可用完成，前端用户无感知。

设计定时兜底扫描机制，确保异常场景下数据最终一致性。系统周期性扫描数据库中"处理中"状态任务，对 24 小时内未返回结果的任务自动发起补偿查询，捕获高峰期偶发的异步回调丢失或服务商响应延迟，实现请求全量落库与状态闭环。

设计模型计费与积分运营体系，支撑平台商业化能力。构建模型-积分映射配置中心，针对不同模型设置差异化积分消耗策略；开发积分扣除算子，实现请求前预估展示、成功后实际扣减的完整链路。针对视频类模型秒级计费的特殊场景，独立设计时长阶梯计价逻辑，确保计费精度与成本可控。

项目结果

主导构建企业级多模态 AI 模型聚合中台，统一纳管 Nano Banana、Seedance、Seedream、Veo、Kling、Hailuo 等 6+主流文生图/视频模型，实现异构协议标准化与统一接口输出。设计参数映射层与 SQL 配置中心，支撑前端动态渲染与模型能力热更新；基于异步任务队列与 TaskId 驱动模式，实现高并发长时任务的可靠处理与全链路状态追踪。构建多活节点池+实时健康检查的智能路由容灾体系，解决海外平台不稳定及谷歌算力波动问题，实现故障秒级自动切换与用户无感知降级；配套定时兜底扫描机制，保障 24 小时内异常任务的最终一致性闭环。独立设计模型计费与积分运营体系，支持差异化积分策略及视频秒级阶梯计价，完整覆盖预估-扣减-对账商业化链路，支撑平台规模化商业变现能力。

TMC-Bot

项目需求

TMC-Bot 智能商旅订票系统的多 Agent 协作架构设计，基于自然语言交互重构传统订票流程，用户通过对话即可完成机票查询、预订、改签、信息变更及退票等全场景操作。系统支持多模态输入（航班号/航班截图/自然语言），自动解析用户意图并调度专属 Agent 处理，实现从"平台操作"到"对话即服务"的体验升级。

项目实施

基于 LangGraph 框架构建多 Agent 协作系统，采用决策 Agent 统一路由+子 Agent 垂直处理的分层架构。决策 Agent 基于全局状态管理实现短期记忆存储，支撑多轮对话上下文连续性；意图识别 Agent 精准解析用户目的（订票/改签/退票/信息补充/闲聊），触发对应业务链路。利用 LangGraph 原生能力实现出票前订单状态回滚与信息修正，打通企业微信、短信等多渠道通知体系，完成订票闭环。

设计多模态输入处理链路，基于 Qwen 多模态模型实现图片智能解析。针对航班截图场景构建有标识/无标识双路径处理策略：有标识图片直接提取标记航班信息，跳过信息确认环节直达预订流程；无标识图片则提取全量航班列表生成候选表单，用户仅需回复序号即可完成选择，显著降低交互成本。

设计订单确认风控机制，预订前向用户推送结构化确认卡片（航班信息/价格明细/项目条款），基于明确意图识别触发订票动作，确保交易可追溯。订票成功后自动调用企微监控中台，实时推送成交信息至对应业务群组，实现业务闭环与运营数据同步。

设计三级人机协同保障机制：系统异常或用户主动触发转人工后，人工 Agent 自动标记并推送至高优先级队列，企微监控中台同步执行私发通知+值班群广播的双通道触达；若 5 分钟内未响应，自动升级至@业务主管的督办机制，确保人工介入时效与服务质量可控。

项目结果

TMC-Bot 重构商旅预订体验，将传统平台操作转化为"对话即服务"的交互模式，显著降低客户操作门槛。针对多人多行程的复杂场景，支持差异化行程配置与批量处理能力，较传统方式提升 X%预订效率。通过"自动化处理+多级人机协同"双轮驱动，在缓解值班人员压力的同时，确保异常场景分钟级响应，实现服务质量与运营成本的平衡优化。

企微监控

项目需求

搭建企业微信统一监控与消息推送中台，作为公司内部核心基础设施，支撑客服系统状态监控、业务预警、消息触达等多场景需求。已覆盖 TMC-Bot、资金划扣、考勤异常、催收通知等多条核心业务线，实现关键信息实时触达与全链路可观测，保障业务连续性与响应时效。

项目实施

基于企业微信监控 API 构建数据采集与存储体系，实现对企微账号消息流的全量监控与结构化落库。设计包含消息内容、消息类型（正文/撤回/系统通知）、消息 ID 及用户基础画像的多维数据模型，支撑后续检索分析、审计追溯及运营统计需求。

基于自定义 API 构建企业微信消息发送引擎，支持富文本交互能力（消息引用、撤回、@用户/全体）及智能发送策略。设计定时任务系统，实现分场景差异化触达策略；内置发送人白名单过滤机制，自动屏蔽人工客服账号，避免监控误触发导致的用户体验干扰。

项目成果

企微监控平台已覆盖公司 5 条核心业务线，实现分业务系统的精细化消息路由与自动化触达，显著降低人工运维成本。同时承担 7×24 小时异常告警监控职责，关键故障秒级通知，保障业务连续性与服务稳定性。

鸿联九五

项目需求

主导与中信证券合作的智能客服机器人项目，针对金融催收及业务咨询场景，规划并落地鸿联机器人产品，覆盖电话还款提醒、业务咨询、在线客服三大核心模块，推动客服系统智能化升级，实现业务流程自动化，显著提升内部客服效率与服务质量。

项目实施

主导构建智能语音交互平台四大核心能力模块：ASR 语音转写、TTS 语音合成、RAG 知识检索、智能通话机器人。采用模块化架构设计，各模块独立部署专属模型与垂直业务数据，支持灵活组合与按需调用，全面覆盖金融催收、业务咨询、还款提醒等高复杂度语音场景。

RAG 知识检索：

负责 RAG 知识检索系统的架构设计与优化，面向在线客服场景，基于中信证券公司问答型知识库构建向量检索能力。系统采用 Query 优化-多重检索-精准排序三层架构：调用 Qwen 模型对用户输入进行意图理解与降噪处理；通过初步检索+重排机制提升结果相关性；针对"天天宝"等业务专属名词设计热词保护策略，避免关键信息被过滤。最终输出 Top1 精准答案。

同时打通 ASR 语音链路，支持音频文件自动转写后进入 RAG 流程，实现语音问答闭环

ASR 语音转写：

基于百度 PaddleSpeech ASR 模型构建语音识别服务，支持用户上传音频文件及网页端实时语音流的双模态输入，自动转写为可编辑文本，满足企业通话内容的合规留痕与审计需求。

TTS 语音合成：

使用公司原有的 TTS 模块进行语音合成，构建文档转语音服务，支持用户上传多格式文档（PDF/Word/TXT）的智能解析与语音合成，生成自然流畅的音频输出，主要应用于在线客服场景的语音回复与通知播报。

项目成果

鸿联九五智能客服系统上线后，实现 7×24 小时全天候自动化响应，客服人效提升，平均响应时效从 2 分钟缩短至 10 秒，客户满意度提升至，显著降低人工坐席压力的同时保障服务质量稳定性

理想同事

项目需求

在共享服务中心（SSC）领域，目标是打造一位智能 AI 同事，助力提升企业内部员工的人力资源服务速度和科技水平。理想中的 AI 同事能够覆盖多个业务场景，包括业务办理、假期申请与查询、财经领域数据查询以及政策问答等，为员工提供全方位的支持。

该智能同事不仅能够大幅提升 SSC 的办公效率，还将整合企业全量知识库与制度文件，确保员工能够随时随地准确获取企业政策信息，快速完成各类业务办理，实现真正意义上的智能化人力服务。

项目实施

该智能 AI 同事主要由三个助手组成：IT 助手、财经助手和人力助手，分别负责不同领域的业务服务。每个助手均具备该领域的专业知识和全面信息，能够高效支持对应业务的办理需求。

- IT 助手：**基于工程设计和 Prompt 策略，依托大模型驱动，专注于 IT 领域的业务办理。它能够帮助员工处理 IT 工单，自动获取并验证员工令牌信息，从而为员工提供个性化且符合权限的业务办理流程 and 解决方案。
- 财经助手：**该助手专注于财经领域的业务支持与信息响应。鉴于财经数据的重要性和专业性，财经助手通过构建 Agent 系统，结合大模型，实现对财经领域问答的精准回复与简单业务办理。其设计旨在快速响应员工的财经相关咨询，提供准确、及时的财经信息支持，提升财经业务的处理效率和服务质量。
- 人力助手：**主要负责员工日常业务办理及政策问答。与其他两个助手类似，人力助手同样基于 Agent 机制实现业务流程自动化，涵盖假期申请、本地外出、出差、调休等常见人事业务。同时，人力助手支持员工主动查询个人信息，例如根据员工基本资料和规则计算剩余年假天数，并实时反馈给用户。

人力助手的核心功能之一是政策问答，旨在解答员工关于企业各类文档、制度及管理政策的咨询。该模块整合了企业所有信息文档、地区政策及社会业务办理流程和条件，确保员工能够快速、准确地获取所需的政策信息与办理指引。

政策问答模块的实现依托于两个关键子模块，第一个为 QA 对模块。该模块内预置了大量高频提问及标准答案，能够实现对员工常见问题的快速、精准响应，显著提升问答效率。

此外，系统引入了多维表格管理机制，支持灵活接入各类业务数据，具备良好的扩展性，便于快速适配多种业务场景。针对企业内部敏感信息，QA 模块集成了基于用户身份的权限控制体系，确保仅授权用户可访问对应数据，有效防止信息泄露，保障企业数据安全。

政策问答的核心为基于 RAG (Retrieval-Augmented Generation) 的知识问答模块，该模块整合了企业内部所有文档信息。我们采用多路召回策略以提升回复质量，包括：Query 与文档切片的直接匹配、以及通过 Query 提取的子 Query 与切片的匹配。所有召回结果会通过重排模型进行排序，选取相似度最高的前三个片段进行信息整合，最终输入大模型生成优化回复。

针对教程类文档，我们做了特殊处理，仅允许召回人工提炼的摘要部分，以避免冗余回复和因流程不完整而导致的误导。此外，系统还结合用户的城市和身份类型，实现了定制化回复，进一步提升了“理想同事”的智能化水平和实用价值。

项目成果

“理想同事”一期已正式上线，在实际应用场景中获得了高度评价。其不仅支持智能化业务办理，还能高效、精准地响应用户的政策咨询，显著提升了 SSC（共享服务中心）领域的办公效率。

Data Copilot

项目需求

为满足公司内部商业人员、销售代表、零售店店长及分析团队对实时数据查询与业务洞察的需求，理想汽车提出构建一个智能、高效、准确的数据查询与分析平台。该系统不仅支持灵活查询，还集成了可视化看板分析、报告自动生成、定时推送等能力，帮助管理层快速掌握运营动态，提升决策效率。

基于这一目标，数据智能团队联合数据分析与数科团队，共同打造了企业级数据平台——Data Copilot。该平台覆盖商业分析、战败归因、门店运营管理等关键业务场景，提供实时查询、数据追踪、策略支持等核心功能，全面提升数据驱动能力，助力公司在零售与战略层面实现更科学、高效的运营与管理。

项目实施

本项目由多个关键模块协同构建与合作完成，包括：数据合成泛化、数据一致性校验、Query 标准化、意图判断、维度抽取、拒识模型与引擎、多轮追问理解、智能编辑模块、NL2SQL 模块，以及各类工程化组件。这些模块相互配合，构成了完整的技术体系，有效支持了项目在业务场景的应用。

NL2SQL:

针对不同模型设计了相应的数据泛化策略，依托完善的业务知识体系，包括维度表和指标表，进行结构化信息的抽取与组合。在 NL2SQL 方向，数科团队首先构建了种子 SQL 样本，结合业务维度与指标信息，扩展生成多样化的训练数据，并引入链式思维（Chain-of-Thought, CoT）提示，辅助模型更精准地生成 SQL 语句。

生成的数据经过严格的一致性校验，剔除存在维度与指标冲突或不匹配的样本，最大限度保证数据的有效性和质量。最终，所有泛化数据均由数科团队的 SQL 语句专家进行抽检与人工审核，确保训练数据具备高度准确性和业务可信度。

模型训练选用了 Qwen 系列中的 Qwen2.5-Coder-32B 模型，采用两阶段的监督微调（Supervised Fine-Tuning, SFT）方法进行优化。训练过程中，设计了特殊的 Prompt 机制，结合动态召回技术，将 Data_kg、指标平台及业务维度表等关键信息实时提供给模型，辅助其生成精准的 SQL 语句。动态召回机制确保上下文信息的准确传递，提升了模型对业务数据的理解能力和生成效果。

此外，目前已引入 GRPO 训练方法，针对 Qwen2.5-1.5B 和 Qwen2.5-3B 模型进行了训练，实验结果表明模型性能保持稳定，未出现明显下降。

多轮追问:

多轮追问能力是 NL2SQL 流程中的关键前置模块，其核心目标在于融合用户上下文信息，实现对历史对话内容的有效记忆，从而准确理解用户在多轮交互中的真实意图，提升 SQL 生成的上下文一致性与准确性。

该模块主要包括两个子模块：**意图判断与 Query 改写**。

1. **意图判断**模块负责识别用户第二次及之后的提问是否属于追问语境。系统将用户意图划分为四类：追问、指示、对比、其他。通过意图分类，决定是否触发改写流程。其中，“其他”类别视为非追问类问题，无需改写。
2. 在完成意图识别后，**Query 改写**模块会根据具体意图类型，结合用户首次提问中的关键信息，对当前的 Query 进行改写或补全，确保上下文信息得到延续，防止历史信息的缺失或歧义篡改，从而生成更符合用户真实需求的结构化查询表达。

该设计有效提升了系统对复杂交互场景中用户意图的理解能力，有效提升了多轮对话场景下 NL2SQL 语句的生成准确性，同时增强了智能编辑模块在复杂交互中的应用能力。

模型训练同样基于 Qwen 系列，初始阶段采用 Prompt 策略，调用 Qwen2.5-72B 大模型实现多轮对话中的意图判断与 Query 改写任务。在后续迭代过程中，逐步将 72B 模型替换为经过 Fine-tuning 优化后的 Qwen2.5-3B 模型，在确保任务性能稳定的前提下，显著降低了计算资源消耗，并提升了推理效率。

维度抽取:

维度抽取模块在整体流程中具有核心作用，主要服务于拒识引擎，通过对用户 Query 中的维度信息进行识别与提取，同时解析其中的分组条件和约束条件，为后续拒识判断提供关键依据。

拒识流程分为两个主要层级：

1. 业务逻辑校验：判断用户表达的维度是否符合当前系统所支持的业务逻辑与计算规则。若该维度在业务层面不被支持，则直接触发拒识；
2. 指标适配校验：在维度逻辑合规的前提下，进一步判断所提维度是否能与用户请求的指标进行合法组合。若业务语义上该指标不支持与该维度联用，同样触发拒识。

此外，维度抽取还包括对时间维度的识别，尤其关注是否为时间段表达。时间维度作为业务规则的重要组成部分，也被纳入拒识判断的核心条件之一。

通过维度抽取模块的精准识别，拒识引擎能够有效过滤掉非法、无效或语义不合理的查询请求，从而确保后续 NL2SQL 模块生成高质量、业务合法的 SQL 语句。

在训练阶段，维度抽取模型的数据构建方式与 NL2SQL 存在显著差异。训练数据主要依赖大模型生成部分维度相关及“维度以外”的多样化数据，提升模型对复杂 Query 结构的泛化能力。训练过程中引入了 Chain-of-Thought (CoT) 思维链提示机制，并在 Prompt 中动态召回 Data_kg 知识图谱信息，辅助模型对 Query 的语义结构和维度语义进行更深层理解，进一步提升维度提取的准确性。

模型评估方面，采用规则逻辑验证结合人工校验的方式进行严格评测。由于维度抽取结果直接影响拒识引擎的判断准确性，因此对其识别精度要求极高，以保障整个系统的稳定性和业务可信度。

Query 标准化：

该模块主要负责将用户口语化表达的 Query 转化为标准且专业的 Query，从而提升后续处理的准确性。其业务场景涵盖五大类：同环比、多指标、简单排名、排名交叉以及指定对象排名。其中，同环比场景细分为四种类型，包括支持天级别指标、不支持天级别指标、上险量与竞品订单同环比，以及商机不可累加指标。针对不同场景，设计了专门的 Prompt，并结合 Data_kg 中的业务知识进行 Query 标准化，同时在新增维度或指标时持续优化改写策略。

模型训练采用 Fine-tuning 方式，重点学习垂直领域知识，以确保改写的准确性和专业性。

项目成果

目前，Data Copilot 已在商业领域稳定运行一年多。其功能从最初的机械式操作，逐步演进为支持自动化接入新指标的能力，并集成了强化学习、GRPO、Agent 机制及智能编辑等先进技术，已成为一款好用、实用且高效的数据查询工具，获得企业内广泛认可，成功打破了大家对模型不可靠性的固有认知，且准确率持续提升。

通过知识蒸馏技术，项目将所有 Qwen2.5-72B 大模型逐步替换为体积更小、效率更高的 Qwen2.5-3B 模型，在保持 90% 以上准确率的前提下，显著降低了计算成本和资源消耗。同时，查询响应速度由原先的 12 秒缩短至 6 秒，且仍有进一步优化空间。

目前，Data Copilot 已成功接入财经领域的指标体系，且正在逐步拓展至更多业务领域。未来，平台计划由 Data Copilot 升级转型为功能更全面、更智能的 Data Agent。

智能顾问

为了让商家提供即时回应问题的高效服务，我们计划开发一个智能顾问系统，以满足用户在浏览酒店时可能提出的咨询。这个系统旨在解决人工客服无法全天候在线且成本高昂的问题。我们的智能顾问将能够快速回答用户疑问，并具备与用户进行轻松对话的能力，从而为商家节省成本和精力。通过这种方式，商家可以在不牺牲服务质量的前提下，实现对资源的优化配置。

数据清洗与处理：收集大量的用户咨询酒店的问题数据，包括酒店卫生、性价比、地理位置、服务态度等等方面的问题，并将这些数据进行清洗、整理和标注，把整理好的数据转换为 JSON 数据，为了模型能够更好的读取数据。

模型训练：使用 P-Turning 和 Lora 微调的方式对 ChatGLM2 进行垂直邻域的微调训练，通过对比 P-Turning 和 Lora 的微调结果，选出对于该项目来说微调效果更好的为微调方式，并将该微调方式应用到该项目。使其具备垂直邻域的专业问答能力，对于问题能够生成相应的回答，然后接入 LangChain 对生成的回答进行优化，能够根据用户的需求，更准确的返回用户咨询问题的答案。

外观设计：设计一个简洁的界面，便于用户方便地使用该工具进行酒店的咨询。

通过持续的努力和测试，我们已成功完善了 langchain 技术，并开发出一套高效的酒店咨询问答系统。该系统能够准确并及时地回应用户的查询，提供了卓越的用户体验，显著提升了用户满意度。此次开发成果不仅为我们赢得了客户的认可，还积累了宝贵的行业经验。

评论分析

为了高效地获取并分析客户在酒店住宿后的反馈，商家需要一个能够快速识别评论正负的平台或工具。这样的系统将自动评估客户对酒店卫生、性价比、服务态度、设施完善度以及周边环境的评价。通过实施酒店评论分析项目，商家旨在节省人工评估的时间与精力，迅速作出策略调整，以提升服务质量，并针对高净值客户群体实施精准的引流、留存和付费转化策略。

该项目使得商家能够更深入地了解客户反馈的问题，从而制定出更具针对性的改进措施。项目在分类性能指标上表现还不错，为实际业务带来了显著的价值。未来，我们计划继续优化模型性能，并探索更多先进的中文文本分类技术，以进一步支撑公司的业务增长和提升客户满意度。

文本纠错

为了提升评论质量，确保信息的准确性和可读性，我们开发了一款文本纠错工具。这款工具能够自动识别并纠正评论中的错别字，从而提高评论内容的整体质量。这不仅便于后续客户浏览理解，也让商家能够更准确地分析客户反馈，进而快速采取改进措施，优化服务。

经过反复的测试和精细调整，我们的文本纠错工具在识别和修正拼写错误、语法错误等方面展现出良好的性能，有效提升了评论质量。这一工具不仅成为商家分析评论的得力助手，还增强了评论的可读性，为用户提供了更优质的浏览体验。

实体识别

本项目旨在构建一个先进的命名实体识别系统，利用深度学习技术，它能够在自媒体视频、公众号文章以及酒店宣传材料中精确识别并提取各类实体信息，如酒店名称、地理位置、服务态度等关键信息。这将极大地提升我们对酒店相关信息的检索效率和准确性，为用户提供更全面和精准的信息服务。

通过实施命名实体识别项目，我们显著增强了酒店信息检索的能力，现在能够有效地识别出酒店的相关信息，理解实体之间的关联性，并监测价格变化幅度等关键功能。这些进步不仅提升了检索效率，还为用户提供了更加丰富和相关的信息，从而优化了整体的服务体验。

 自我评价

良好的沟通和协调能力，有较强的学习能力、开发中各个流程包括前后端、据库设计都熟悉一些、大模型及 Agent 具有浓厚的兴趣、具备团队精神、跨部门沟通、喜欢研究技术、旅游。