

求职方向：AI 应用研发工程师 / Agent 开发工程师

个人优势

- Agent 编排与任务执行**：熟悉 Agent Harness、Loop 与 LangGraph，能够将复杂任务拆解为检索、生成和评审节点，通过 MCP 与 Skills 组织工具调用，结合 Checkpoint 实现状态恢复、失败重试与人工审核。
- RAG 与知识工程**：熟悉 Wiki、LightRAG、GraphRAG 和 Neo4j，掌握语义分块、元数据过滤、向量与 BM25 混合召回、Rerank 及多跳检索，能够构建支持引用回溯、效果评测的业务知识体系。
- 模型微调与应用**：具备领域数据构建、LoRA 微调与 vLLM 部署经验，能够完成去重脱敏、自动标注、人工抽查和训练评测，将线上误分类与低置信样本回流，形成数据、训练、部署与反馈闭环。
- Evaluation 与质量迭代**：围绕检索命中、引用依据、规则检测与工具调用建立 Eval Case，将失败案例纳入回归测试，结合人工确认持续优化 Prompt、知识内容与执行流程，验证迭代对业务输出的影响。
- 多模态 AI 应用**：具备 VLM、图文检索及 AIGC 内容生成实践，能够统一管理图片、视频和文本素材，贯通内容解析、语义检索、创意生成与广告验证，并以投放反馈支持素材复用和生成策略优化。

工作经历

2025.09-至今

反舌鸟科技（杭州）有限公司 | AI应用研发

- 负责策划案生成、海外玩家舆情、短视频热点挖掘、多模态素材管理等内部 AI 项目，从业务拆解、技术选型到上线迭代全流程推进。
- 设计统一的 RAG、Agent、MCP / Skill 与模型服务底座，沉淀检索、记忆、Prompt、评审、告警、报告等可复用能力。
- 对接飞书 SSO、消息卡片、多维表格与通知流程，建立人工审核、权限隔离、运行日志和异常回溯机制。
- 围绕生成质量、检索命中、工具成功率和业务采纳率建立 Eval Case 回归，持续优化 Prompt、知识库与工作流。

2024.07-2025.08

杭州代码部落教育科技有限公司 | 大模型应用开发

- 构建知识图谱与 RAG 驱动的智能答疑链路，将检索、生成、事实校验和人工兜底封装为标准化流程。
- 结合用户画像、意图分类与 Prompt 策略提供差异化回答，并参与领域样本标注与轻量微调实验。
- 负责 FastAPI 服务、结构化输出、日志监控与异常处理，支撑模型能力稳定接入业务系统。

项目经历

项目一：游戏策划生成与一致性评审 Agent 平台

项目介绍：面向游戏策划撰写与一致性检查，整合历史方案、设计规范和关联知识，构建共享 Agent 底座；不同角色按任务调用检索、生成与评审能力，完成方案补全、冲突定位和人工复核。

- Agent Harness + Loop 执行**：以 Agent Harness 统一工具调用、执行状态和异常处理，Loop 围绕任务目标与验收条件推进“检索—生成—校验—反馈”；通过 MCP、Skills 复用能力，结合 Checkpoint、失败重试与人工确认，支持中断恢复和结果复核。
- Wiki + RAG 知识体系**：以 Wiki 管理设计规范与确认后的项目经验，通过 LightRAG 检索历史方案；结合 GraphRAG、Neo4j 关联题材、玩法、系统与商业化信息，支持跨系统多跳分析，为方案补全与设计约束检查提供知识依据。
- 混合检索与证据回溯**：对长篇策划文档进行语义切分与 Metadata 过滤，通过向量、BM25 混合召回及 Qwen Rerank 筛选相关片段，将来源证据保留到生成与评审环节，便于核对引用、追溯设计出处并排查无关召回。
- 策划生成与冲突检测**：结合历史方案、知识图谱与规则 Skills 补全玩法和系统设计，以规则校验检查明确约束，结合 RAG Evidence 与 LLM Judge 识别跨段落的数值、规则和设定冲突，输出冲突依据供策划复核与修订。
- Eval 回归验证**：基于 200+ 历史策划案和 100+ 冲突 Case 建立 Eval 集，分别回归检索、引用、规则检测与 Agent 输出；将执行失败和评审遗漏沉淀为案例，验证 Prompt、知识与流程调整，并将人工确认的有效方案回写 Wiki。

项目二：短视频趋势洞察与广告创意验证平台

项目介绍：面向游戏买量与立项分析，串联 YouTube、TikTok 内容采集、热点识别、AIGC 图片与视频生成和广告投放验证，将热点线索转为可测试的创意素材，以投放反馈辅助推广决策。

- 1. **真实浏览器持续采集**: 通过 Playwright、CDP 驱动真实 Edge 浏览器，持续采集 YouTube、TikTok 游戏短视频，支持多账号运行与增量更新；将内容信息、互动数据和发布时间汇集到分析流程，支撑热点识别与后续趋势跟踪。
- 2. **内容理解与热点识别**: 通过 ASR 提取视频语音，结合 Embedding 聚类归并内容主题，并以播放、点赞、收藏、转发和时间衰减计算热度；分别观察单视频爆发与主题持续增长，将内容语义和互动信号结合，筛选值得验证的创意方向。
- 3. **AIGC 与广告验证**: 结合热点主题与历史游戏案例生成玩法方向、美术方案和广告创意，调用生图、视频模型制作素材，并接入 Roblox Ads 开展 A/B Test；通过实际投放表现比较创意方案，为素材选择与后续迭代提供反馈。
- 4. **投放反馈回流**: 结合展示量、点击量、CTR 和投放成本分析素材表现，将高表现玩法、Prompt 与广告素材回流后续生成流程，贯通“热点发现—创意制作—广告验证—结果回流”，使生成方向能够依据投放反馈调整。

项目三：玩家反馈语义分析与异常预警系统

项目介绍: 面向海外玩家运营，构建 Discord 反馈增量处理、主题聚合与异常预警流程，将分散消息转为可追踪问题，通过飞书通知和人工反馈支持 BUG 爆发识别与运营核实。

- 1. **增量处理与主题路由**: 通过 Discord API 定时获取新增消息，清洗有效玩家反馈后，结合 Embedding 与 Topic Routing 匹配已有主题、聚合同类问题；无法归类的反馈形成新主题，为后续窗口统计与问题追踪提供统一处理入口。
- 2. **BUG 爆发检测**: 基于时间窗口统计各 Topic 的反馈量与增长趋势，识别同类 BUG 在短时间内的集中爆发并触发异常预警，将分散消息汇总为主题级问题，帮助运营从日常反馈中定位需要优先核实的异常变化。
- 3. **自动化告警通知**: 围绕异常主题生成问题摘要，汇总典型反馈与原始消息链接，通过飞书 Bot 自动推送运营人员；将问题概况和溯源证据一并呈现，支持接收人直接核查玩家表述，减少在聊天记录中反复检索。
- 4. **人工反馈闭环**: 记录运营对有效告警、误报和新问题的确认结果，结合反馈调整主题分类规则与异常检测阈值，将人工复核结论反馈到下一轮增量处理；持续修正主题归类和告警判断，减少同类问题重复核实。

项目四：玩家反馈领域模型训练与推理平台

项目介绍: 面向海外玩家反馈分类，构建领域数据生产、自动标注、LoRA 微调与推理服务，针对游戏缩写、反讽及复杂意图完善分类能力，通过线上难例回流与评测推动模型迭代。

- 1. **领域数据构建**: 对海外玩家反馈进行清洗、去重与脱敏，建立 BUG、建议、其他等多级标签体系，整理典型表达并划分训练与验证数据；统一数据整理和标注口径，为自动标签、领域微调与效果评测提供样本基础。
- 2. **数据标注与难例生产**: 结合大模型生成初始分类与标签，通过人工抽查修正误标，重点整理游戏缩写、反讽、多轮对话和复杂意图等 Hard Case；围绕边界类别与易混表达补充样本，使训练数据覆盖日常反馈中的难判场景。
- 3. **LoRA 模型微调**: 使用 LLaMA-Factory 对 Qwen3.5-9B 进行 LoRA 领域分类微调，以固定 Eval 集比较训练配置，结合复杂意图和易混类别的误分类案例调整数据与参数，再通过回归评测检查调整效果。
- 4. **推理部署与分层调用**: 通过 vLLM 部署微调模型并接入反馈分类流程，高置信结果自动处理，低置信或复杂问题转人工或强模型复核；以分层调用保留疑难反馈的兜底路径，兼顾自动分类效率、结果可靠性与通用模型调用成本。
- 5. **数据回流与迭代**: 汇集线上误分类、低置信反馈及人工复核结论，经核查后用于训练样本补充或独立 Eval Case 回归，将数据生产、模型训练与线上反馈串联，持续检查易错类别的识别效果，避免仅凭训练结果判断改进。

项目五：多模态素材语义检索与复用平台

项目介绍: 面向游戏策划、美术和广告场景，统一管理图片、视频与文本素材，通过自动解析、图文语义检索及投放素材回流，支持跨场景查找、内容生成与优质素材复用。

- 1. **图文统一语义检索**: 通过多模态 Embedding 对齐图文语义，将图片、视频描述与文本纳入统一检索流程，支持文本搜图和以图搜图；为 Multimodal RAG 提供检索素材与描述，使策划及广告创意能够复用相关视觉参考。
- 2. **素材智能解析**: 对上传图片、视频使用 VLM 识别画面内容，并通过 ASR 提取视频语音，自动生成描述、标签和分类信息；补充仅靠文件名难以表达的内容语义，减少人工整理，并为后续筛选和检索提供依据。
- 3. **统一素材管理**: 通过 PostgreSQL 管理素材来源、描述与业务关联，结合 VikingDB 完成向量检索，支持题材、风格、项目等条件筛选；将语义相关性与业务范围结合，帮助策划、美术和广告人员查找可复用素材。
- 4. **离线解析与索引维护**: 通过离线任务完成多模态解析、Embedding 更新与索引维护，使图片、视频分析先于在线检索完成，避免查询时重复执行高成本解析；支持新素材持续入库与增量更新，将素材处理与检索服务解耦。
- 5. **素材与效果回流**: 将广告验证中表现较好的图片、视频及 Prompt 沉淀回素材库，通过已有描述和标签支持再次检索，使后续策划与创意生成能够复用经过投放验证的参考内容，形成“生成—验证—入库—复用”的素材回流路径。

教育背景