

信 基本信息



姓 名	胡相歌	年 龄	23 岁
学 历	本科	毕业院校	安阳工学院
联系电话	15836381057	电子邮箱	15836381057@163.com

技 核心技能

大模型与智能体技术

- 掌握 LangChain、LangGraph 全代码开发，熟练掌握 ReAct、Plan-and-Solve 等 Agent 架构设计，具备多智能体协作与状态机编排能力
- 深入理解 RAG 检索增强生成全流程，掌握混合检索、重排序、向量库构建与 Grounding 校验等优化方法
- 熟悉 LoRA 等参数高效微调范式，掌握 LLM 提示工程（Zero-shot / Few-shot）、结构化输出（JSON Mode）与输出校验方法
- 熟练接入 DeepSeek、Qwen 等主流大模型，具备多模型异构调度与降级容错设计经验

开发与工程框架

- 熟练使用 Python，掌握 FastAPI 后端框架与 Pydantic 数据建模，可独立完成 RESTful 接口开发与流式服务构建
- 掌握异常捕获与分层降级设计，具备高可用工程化开发思维；了解开源项目协作流程，具备多人协同开发经验

运维与部署工具

- 熟悉 Linux 操作系统与常用命令，了解 Docker 容器化部署与 Git 版本管理流程
- 掌握 Chroma 向量数据库与 Redis 缓存的使用，具备数据持久化与性能优化基础

AI 编程工具

- 熟练使用 Cursor、Trae、Claude Code 等 AI 编程工具进行日常开发，显著提升编码、调试与重构效率

职 工作经历

河南擎安网络技术有限公司

2025.12 - 2026.08

公司主营企业数字化与 AI 智能体产品研发，业务覆盖企业智能办公协同、行业应用集成与客户项目交付；我所在的 AI 智能体产品线负责将大模型能力封装为可交付的企业级应用。

岗位：AI 大模型应用开发工程师（AI 智能体产品线）

- 岗位职责：**参与公司 AI 智能体产品线的研发与迭代，聚焦企业智能办公协同场景，负责 LLM 应用层开发、RAG 知识库优化与 Agent 工作流编排，支撑客户项目从方案设计到交付验收。
- 负责的业务模块：**产品线面向企业办公场景，拆分为知识检索、数据查询、智能审批、日程协同四类业务模块，我主要承担知识检索与数据查询两个模块的技术设计与实现，并负责四类模块统一接入的多智能体编排中枢；同时参与客户侧知识库建设与智能体工作流编排等交付工作。
- 飞书智能办公协同平台（核心参与项目）：**作为公司 AI 智能体产品线的落地项目，我负责整体架构设计、多智能体编排中枢、Text-to-SQL 与企业级 RAG 三个核心模块——承担全局状态与路由契约设计、只读安全守卫、混合检索链路与失败安全降级机制（详细实现见「项目经历」）。
- 多意图智能客服 Agent：**基于 LangGraph 搭建「意图路由 - 任务执行 - 结果兜底」双层 Agent 架构，结合 Few-shot 提示工程与 JSON 结构化输出校验，落地咨询、报修、投诉等 5 大类客服意图自动分流；在测试集上意图识别准确率从 78% 提升至 89%。
- 企业级 RAG 知识库：**全流程负责客户业务文档的知识库构建，完成 PDF/Word 解析、语义分块与 BGE 向量化，落地「BM25 + 向量」混合召回与重排序；知识库问答准确率提升至 87%，单条检索平均延迟控制在 120ms 以内。
- 智能体业务流编排与工具集成：**基于 Dify 平台编排售后咨询、工单自动创建等标准化工作流，封装企业 CRM、内部工单系统 API 为 Agent 可调用工具，实现用户咨询到工单生成的自动化；单条售后工单的人工处理时长缩短 40%。
- 大模型垂直场景调优：**基于 LoRA 对 Qwen-7B 进行客服领域语料微调，搭建 200+ 条样本的评测集完成效果验证，垂直场景业务回复合格率提升 15%；沉淀 3 类场景标准化 Prompt 模板，复用至同类型客户项目。
- 交付与协作：**参与需求分析与方案评审，输出接口契约与技术文档；与产品、前端及测试协作完成联调与验收，支撑多个客户项目的按期交付。
- 工程规范建设：**推动团队内统一结构化输出规范（JSON Mode + 输出校验）与分层降级约定，降低多模型接入与线上异常排查成本。

智能无人机地面站 AI 插件

2026.05 - 2026.08

Python

LangGraph

LangChain

FastAPI

DeepSeek / Qwen

BGE

ChromaDB

MAVLink

项目背景

小组协作开发的开源实践项目：将工作中沉淀的 LangGraph 多智能体编排与 RAG 工程经验迁移至无人机飞控场景。针对传统地面站操作门槛高、专业术语壁垒强、异常故障依赖人工处置的问题，以插件形式为开源地面站 LinkGCS 开发旁挂式 AI 模组，**将专业飞控操作转化为对话式交互**。

核心职责与技术实现

- ◆ **Multi-Agent 工作流编排**：基于 LangGraph 构建有向状态机工作流，覆盖「意图解析 → 知识检索 → 航线规划 → 故障诊断 → 决策执行 → 状态监控」全链路；路由采用「**规则词典优先 + 大模型兜底**」，高频请求毫秒级命中；设计异构模型调度策略并内置 Checkpointer 实现状态持久化与断线恢复。
- ◆ **指令解析引擎与坐标解耦**：搭建「LLM 语义抽取 + 规则兜底」三级降级解析链路，支持应急配送、巡检、航拍等 **5 类任务**与起终点、高度区间、避让约束等 **8 类结构化参数**；设计**坐标解耦机制**——LLM 仅负责语义字段提取，经纬度由确定性地理编码模块解析，**从架构上杜绝模型幻觉产生坐标偏差**。
- ◆ **故障诊断推理链与安全护栏**：主导分级故障诊断流程，覆盖电量骤降、GPS 丢星、链路中断、障碍物 4 类故障，融合规则基线、RAG 检索与 LLM 推理三层能力；落地 **Grounding 真实性校验**（n-gram 重叠验证结论与知识库原文匹配度，低置信自动回退）抑制编造；建立「**安全等级只升不降**」护栏，LLM 决策仅可向更保守方向修正，并全链路决策留痕满足审计要求。
- ◆ **高可用与降级容错**：全模块遵循「**失败静默降级**」原则，LLM 异常、依赖缺失、网络中断时自动回退规则引擎，核心飞行控制不受影响；设计指令安全门，高风险操作（起飞、降落、返航）需人工二次确认，从接口层拦截非法指令。

项目难点

飞行安全场景对「**控制精度要求确定、交互语言天然模糊**」的矛盾最为苛刻——LLM 输出的经纬度一旦有偏差即可能造成事故。通过**坐标解耦**将「语义理解」与「空间计算」彻底分离，并以 Grounding 校验与安全等级单向上锁双重兜底，使模型能力只在可控边界内生效。

项目成果

离线全链路（解析-检索-规划-诊断-决策-执行）跑通并完成 **LinkGCS SITL 仿真环境端到端联调**，实现自然语言下达任务 → 自动规划航线 → 起飞巡航 → 故障自主处置的完整闭环；自建测试集**任务解析准确率达 92%**，**规则基线路径故障响应 < 1s**，支持无网络环境纯本地安全运行，多级缓存使**重复指令响应延迟降低约 70%**。

跨境电商智能运营 Agent

2026.02 - 2026.04

Python

FastAPI

LangGraph

LangChain

Qwen

BGE-M3

BGE-Reranker

BM25

Chroma

Redis

Docker

项目背景

针对跨境电商商品信息分散、咨询效率低、售后流程复杂、需求难以精准理解等问题，研发融合 RAG、多智能体协作与业务 Workflow 的智能运营系统，实现**智能推荐、订单查询、售后自动化与多轮交互**，将高频运营事项交由 Agent 自动处置。

核心职责与技术实现

- ◆ **Agent 编排与路由**：基于 LangGraph 设计 **Supervisor + Worker** 多 Agent 架构，大模型识别用户意图实现 Shopping、AfterSale、Order 等智能体自动分流；结合 State 状态管理与条件路由完成复杂任务拆解。
- ◆ **RAG 混合检索系统**：构建商品、用户反馈、物流规则及售后政策知识库，搭建 **BGE-M3 向量 + BM25 关键词 + RRF 融合 + BGE-Reranker 重排序**的混合检索链路；自建评测集上 **Recall@5 达 1.0、MRR 达 0.933**。
- ◆ **多轮对话与用户记忆**：基于 Redis 实现 Conversation Memory、用户画像与检索缓存，结合 **Query Rewrite** 解决上下文依赖，持续记忆用户历史需求、国家区域与商品偏好。
- ◆ **售后 Workflow 自动化**：将退货退款流程拆解为订单校验、政策匹配、风险检测、审批处理、退款及物流等节点，状态机 Workflow 自动执行，支持异常人工介入与降级。

项目难点

售后政策高度依赖上下文——同一用户在不同国家区域、不同订单状态下适用的退货规则不同，单轮检索难以命中正确条款。通过 **Query Rewrite** 完成指代消解后再送入检索，结合 **RRF 融合**两路召回规避分数尺度不一致的问题，并用 Redis 缓存用户画像与检索结果降低重复计算，使多轮场景下的召回稳定性与响应速度同时得到保障。

项目成果

基于 **FastAPI** 提供统一服务接口，**Docker Compose** 完成应用 / Redis / Chroma 容器化部署，**自动化测试完成 95 项功能验证**保障稳定运行；自建评测集 **Recall@5 达 1.0、MRR 达 0.933**，售后流程由状态机自动执行并支持异常人工介入，降低运营人工成本。

项目背景

针对企业日常办公中跨系统数据查询繁琐、内部知识检索效率低、审批填报与会议协调周期长等问题，设计并实现**飞书智能办公多 Agent 协同系统**：通过**数据查询、知识检索、智能审批、日程管理**四个 Agent 分别解决，将大模型能力嵌入飞书 workflow，辅助业务人员自助查询数据、快速定位制度依据、自动生成审批与会议安排。系统以飞书机器人为统一入口，员工用自然语言描述意图即可完成跨系统操作，无需在多个 OA 模块间切换。

核心职责与技术实现

- ◆ **Multi-Agent 架构与编排**：基于 LangGraph **StateGraph** 搭建编排器与四个业务 Agent，识别用户意图后通过条件路由调用对应 Agent 并统一汇总结果；路由采用「**flash 模型分类优先 + 关键词规则兜底**」双通道设计，模型异常或输出不可解析时自动回落规则判定，保证路由始终可用。
- ◆ **状态管理与接口契约**：定义全局状态与 **reducer** 实现跨节点上下文追加，使多轮对话上下文可直接对接缓存持久化；统一 **AgentResult(answer, payload)** 输出契约，把结构化产物收敛到统一载体，**新增 Agent 仅需三步注册**，支撑四个模块并行开发、互不阻塞。
- ◆ **数据查询 Agent**：基于 **sqlite_master + PRAGMA table_info** 实时动态注入 Schema（换数据库无需改提示词）、Few-shot Prompting 对齐业务字段语义，由强推理模型生成 SQL 并输出可视化图表；针对「**查询意图灵活、数据安全刚性**」的矛盾，设计**双层只读守卫**（语句白名单 + **PRAGMA query_only**），关键写操作零容忍。
- ◆ **知识检索 Agent**：负责企业制度文档检索问答，返回**带出处与重排序得分的答案**，让结论可追溯；基于 **BM25 + 向量双路召回、RRF 倒数排名融合**规避两路分数尺度不一致的问题、**BGE-Reranker 重排序**精排提升相关性；口语化提问自动回落抽取式回答，检索不足时如实拒答，抑制模型编造。
- ◆ **输出约束与服务化**：统一各 Agent 输出格式与 **payload** 结构化载体，降级产出以 **generated_by** 标注来源（llm / heuristic / extractive）保证可追溯；异常返回哨兵值触发本地兜底而非向上抛出，避免单点故障污染整条链路。
- ◆ **工程化与可验证性**：基于 **FastAPI** 提供统一对话接口，内置调试台使得**无需飞书凭证即可逐意图验证全链路**；编写端到端、HTTP 接口、检索链路与多轮上下文等多组验证脚本，把「能跑通」变为可复现的验收结论。
- ◆ **多轮上下文与会话隔离**：以 **session_id** 为键将对话上下文持久化至 Redis（TTL 可控），既支撑「按刚才的结果再查一遍」这类指代型追问，又保证不同用户会话互不串扰；结合全局固定窗口限流防止单会话过量调用。
- ◆ **可观测性建设**：在状态中记录 **intent_source**（路由来自模型还是规则）与各 Agent 的实际产出方式，使线上「意图跑偏」「答案来自兜底」等问题可被快速定位，无需逐条复现对话。

项目难点

初期未做量化验证即引入词法重排序，主观认为「加了重排序一定更好」。自建 A/B 评测集（15 篇主题高度重叠的制度文档 / 60 个切块 / 22 条带答案锚点的 query，用 Hit@1、Hit@3、MRR 对比四种配置）后，定位到**重排序使 Hit@1 从 95.5% 反降至 81.8%（下降 13.7 个百分点）**——根因是词法重排序采用**对称 Jaccard 相似度**，其分母含并集，**惩罚了较长但包含完整答案的切块**，反而让只命中少量词的短切块排名靠前；改用**查询侧覆盖率**指标排序，配合零命中沉底与稳定排序保持上游 RRF 顺序，使重排序不再劣化检索质量，并确认**混合检索 + RRF 相对单路 BM25 带来 Hit@1 +4.5%、MRR +0.0227 的真实增益**。评测同时暴露天花板效应：非重排序配置 Hit@3 已达 100%，说明该评测集区分度有限，需补充更难样本才能测出重排序的真实收益。

项目成果

系统实现业务数据自然语言查询、制度文档检索问答、审批事项自动提取与会议时段智能推荐，将原本需跨系统、跨岗位流转的办公事项收敛至**单一对话入口**；实测 **RAG 检索 Hit@1 由 90.9% 提升至 95.5%、MRR 由 0.9470 提升至 0.9697**，非法 SQL 拦截率 **100%（4/4）**，LLM 端点完全不可达时**六条业务链路仍 100% 可用**，全链路端到端 **6/6 通过**、平均响应 8.9 s。系统上线后，数据查询与知识检索两类原本依赖人工整理的高频事项实现自助化，减少了跨岗位反复问询。

自我评价

- ◆ 具备 AI 大模型应用开发实战经验，**主导多个 Agent 项目核心模块从 0 到 1 落地**，具备从需求拆解、方案设计到联调交付的端到端能力
- ◆ 熟悉 RAG、多智能体编排、模型微调等核心技术栈，能快速把新技术落地到具体业务场景并沉淀为可复用方案
- ◆ 具备较强的问题定位能力，习惯先搭建可量化评测再判断方案收益；注重工程规范与文档沉淀，具备良好团队协作意识