

个人信息

姓名：周谊华
年龄：25岁
电话：15005559817

英语：CET-4
邮箱：pe_hfzyh@126.com
学历：安徽财经大学|本科

个人技能

- 熟练使用 DINOv3,YOLOV8s 等视觉本地部署模型，对图片进行向量化处理和图片进行精准裁剪处理
- 熟悉 MCP 协议、A2A 通信协议及 Function Call 架构，支持 Agent 工作流设计与外部工具集成落地
- 掌握 RAG 架构设计与开发流程，参与构建多层次检索系统，通过混合检索、重排序及元数据过滤等多策略优化，提升问题回答的相关性与准确率
- 熟悉 LangChain 框架，具有多 Agent 协同系统搭建经验，具备复杂任务拆解与流程编排经验
- 熟悉 LoRA、QLoRA 等大模型高效微调方法，参与小样本场景下的模型参数高效微调
- 熟练应用 COT、TOT、Reflexion 等高级提示词技术，通过 prompt 迭代优化，将复杂场景下的模型推理准确率提升 10%
- 熟练使用低代码平台（如 Coze、Dify）与专业工具（如 RagFlow）进行智能体开发、应用编排与知识库增强。
- 熟悉 Transformer 架构与 Attention 机制，熟悉 bert、gpt 系列模型原理
- 熟悉 RNN 及其变体如 GRU、LSTM 等序列模型架构
- 熟练使用 PyTorch 框架完成模型搭建、训练与调试
- 熟悉 SQL，熟练使用 MySQL、Milvus、Redis 数据库与向量库，支持结构化与非结构化数据检索
- 熟练使用 Python 语言，熟练使用 Numpy、Pandas 等库进行数据清洗、筛选操作

工作经历

北京融海数据科技股份有限公司	人工智能算法工程师	2023.09 – 2025.12
杭州知几智能科技有限公司	AI 垂类大模型开发工程师	2026.03 – 2026.08

- 研发智能 AI 宠物智能体平台，基于 LangChain 实现多智能体协作，完成宠物医疗问诊，品种识别，情绪识别等功能。
- 设计并落地多模态 RAG 架构，构建猫狗品种图片 Milvus 向量库，涵盖 392 个犬类品种和 145 个猫类品种，一共 5000 张标准图片。
- 改善相似度计算方式，提高品种识别准确率，将品种识别准确率从 58.57%提升至 93.57%。
- 使用 YOLO 模型对猫狗图片进行裁剪，提高品种识别准确度，并将 DINO 模型和 YOLO 模型单独部署成微服务，将品种识别项目的结构在 GPU 服务器和 CPU 服务器进行隔离，实现对算力的高效配置。
- 构建品种识别、情绪识别的开放平台微服务，对外提供独立的接入入口与服务能力。
- 通过压测统计各链路实际 token 消耗，据此对开放平台服务进行成本测算与定价评估，为对外商业化提供数据依据。
- 沉淀通用技术框架，支持智能问答、多智能体系统在跨业务场景中的快速复用。

2026.03 - 2026.08

宠拍档-宠物医疗 AI 智能体平台

技术栈: DINOv3, YOLOv8s, CatBoost, Silero VAD, bge-m3, Pytorch, MinerU, Qwen3-vl-plus, Qwen3.7-max, Qwen3-omni-flash, Qwen-tts, Qwen3.7-flash, Python, Langchain, Langgraph, Harness, FastAPI, uvicorn, DashScope SDK, OpenAI SDK, pydantic, 微服务, MongoDB, Milvus, 阿里云 OSS, Docker, GPU, Linux, 阿里云 SLS, FFmpeg

项目背景

主导设计并开发了基于 LangChain 多智能体协作的宠物医疗 AI 智能体平台「宠拍档」，平台采用「主流程编排 + 意图识别 Agent + 微服务工具集」三层 Harness 架构，LangChain 主流程串联意图识别 Agent 与三大核心微服务，由 LLM 自主判断调用哪个微服务、怎么组合。三个核心微服务分别承担不同 AI 能力：

(1) 问诊灵光微服务：构建兽药知识库 RAG 系统，把药物适用物种 / 用法剂量 / 频次 / 注意事项等结构化字段入库，通过检索把兽药知识喂给 LLM，让模型结合兽药知识回答用户的用药咨询；收敛跨物种、剂量、查库时机与文案清洗等风险。

(2) 品种识别微服务：针对多模态大模型直接识别猫狗品种准确率仅 58.57%、对中华田园犬等国内常见品种认知不足、高相似品种极易混淆的问题，以「向量检索命中 + 大模型兜底」双链路识别为核心，融合 DINOv3 图像向量化、YOLO 目标检测与 Milvus 向量检索，构建从宠物图片检测裁剪、特征向量化、品种向量检索到大模型兜底判定的完整链路，建设覆盖 392 个犬类、145 个猫类品种共 5000 张标准图片的品种向量库。

(3) 情绪识别微服务：建立端到端「视频优先 → 音频兜底 → CatBoost 本地直出 → Omni 灰区兜底 → 报告异步生成」的多层链路，融合多模态大模型 (qwen3.7-max / qwen3-omni-flash / qwen-flash) 与轻量模型 (CatBoost / Silero VAD)，输出 9 类标准情绪标签；人宠翻译场景扩展 ASR + 意图识别 + 拟人化文案 + TTS 合成链路。已上架应用商店，为上层业务提供稳定的 AI 识别与多智能体协作基础能力。

主要职责

- 多智能体协作平台架构：基于 LangChain 搭建主流程编排层，设计意图识别 Agent 调度品种识别、情绪识别、医疗问诊等微服务，形成「主流程 + 意图识别 + 微服务工具集」三层 Harness 架构；LLM 在意图识别层作为决策核心，自主判断调哪个微服务、如何组合。
- Harness 工程化设计：分层异步兜底 (直出 → 灰区 → 失败回调)、Mongo 状态持久化、videoAnalyse / result 双阶段异步轮询、固定测评集回归门禁 (58.57% → 88.57%)、高混淆对灰区保护策略。
- 问诊灵光微服务开发：构建兽药知识库 RAG 系统，将药物适用物种 (applicable_species) / 用法剂量 / 频次 / 注意事项等结构化字段入库；按档案物种与本轮问询物种判定；建立 5+ 类风险规则封堵——禁止按档案体重换算剂量、未命中库不写精确剂量、仅用药意图查库、禁止「猫狗通用剂型」等内部字段泄漏；多轮换药串库修复。
- 品种识别微服务开发：搭建「向量检索命中 + 大模型兜底」双链路识别主链路；图像缩放 + 视觉先验 + YOLO 微服务裁剪 + DINO 微服务取向量 + Milvus Top-200 召回 + 距离与频次融合判定。两阶段优化：补库 + 国内通用名 (58.57% → 75.71%, +17pct)，再底库门槛 + 融合判定 + 高混淆对灰区保护 (75.71% → 93.57%, +18pct)。同一测评集三回归，DINO 检索命中支 ~94.4%，兜底支 ~73.3%，主链路已由检索扛住。
- 情绪识别微服务开发：搭建端到端「视频 VL 直出 → 音频兜底 → Omni 灰区 → qwen-flash 异步报告」分层链路；双阈值决策 + 9 类标准标签约束；videoAnalyse | result 双阶段异步轮询 + report.json 缓存；人宠翻译扩展 ASR + 拟人化文案 + TTS 合成。猫狗混合路由 91.54%，Presence 本地决策 92.09%。

项目优化与技术创新

- 数据 × 策略两步闭环 (品种识别)：先「补库 + 国内通用名」解决检索没样本 / 名称偏国际协会名 (+17pct)，再「底库门槛 + 融合判定」解决检索粗、易误命中 (+13pct)，累计 +30pct，把识别从大模型硬猜推进到「底库可检 + 策略可判」。
- 融合判定机制 (品种识别)：扩大召回 → 按品种聚合 → 距离与频次联合打分 → 高混淆灰区保护，降低近邻稀疏与单样本偶然相似带来的误命中。
- 多层兜底分层链路 (情绪识别)：视频 VL 直出 → 音频 fallback → Omni 灰区兜底 → qwen-flash 异步报告；任何一层失败都可降级到下一层，端到端可控、可上线。
- 双阈值情绪决策 (情绪识别)：top1 prob 同时过类别阈值、margin 同时过间隔阈值才判 direct，否则 gray；Omni 输出强制 9 类标准标签约束，避免兴奋 / 急躁等口语词引入歧义。
- 场景引擎收敛风险 (问诊灵光)：applicable_species + 档案物种 + 本轮问询物种三维冲突；6+ 类风险规则封堵 (乱写剂量 / 体重换算 / 跨物种 / 历史串药 / 编造禁忌频次 / 内部规则泄漏)，用户可见文案与内部字段严格隔离。
- 平台 Harness 工程化：Mongo 状态持久化、videoAnalyse / result 双阶段异步轮询、按 audio_url 缓存 report.json；意图识别 Agent 基于 LLM 自主判断调哪个微服务、如何组合，三个微服务作为可调用工具集被主流程 Harness 串起。

项目成果

问诊灵光微服务：封堵 6+ 类高频风险 (乱写剂量 / 体重换算 / 跨物种 / 历史串药 / 编造禁忌频次 / 内部规则泄漏)，用户可见文案与内部字段严格隔离；

品种识别微服务：同一测评集准确率 58.57% → 93.57%，累计 +35pct (58.57% → 75.71% → 93.57%)；DINO 检索命中支 ~94.4%，兜底支 ~73.3%，主链路已由检索扛住；

情绪识别微服务：猫狗混合路由准确率 91.54% (相对纯大模型 +6.15pp)，Presence 本地决策 92.09% (非灰区 98.31%)；

平台整体：基于 LangChain 多智能体协作框架，三个核心微服务已上线应用商店稳定运行，支持意图识别 Agent 自主路由 + 多智能体协同，可对外提供 AI 识别与多智能体协作能力。

2025.02 - 2025.12

WealthGuard 多智能体智能金融管家项目

技术栈：Python, MCP, A2A, LangChain, MySQL, Milvus, Docker, RAG, LoRA, LLM

项目背景

针对传统银行数字化服务模块孤立、客户体验断裂的问题，主导设计并开发了一套基于多智能体协同与模块化能力协议 (MCP) 的全流程智能金融服务系统。该系统深度融合大语言模型、智能体间通信 (A2A) 与模块化服务架构，构建从用户意图理解、智能追问、智能体协作、MCP 服务调用、业务工具执行到结果优化输出的完整自动化流程，为客户提供无缝衔接、主动化、个性化的全场景金融服务，显著提升服务效率与客户满意度。

主要职责

- **全流程智能体系统架构**：主导设计并实现覆盖“输入-处理-输出”全链路的智能体协作架构。核心包括：具备 NLU 与主动追问能力的意图识别 Agent，用于确保任务信息的完整性；包含理财推荐、账户管理、支付处理、保险评估、政策解析等 9 大领域的专家 Agent 矩阵；以及负责多源结果整合与自然语言生成的优化输出 Agent，形成完整的业务处理闭环。

- **模块化能力协议（MCP）服务层开发：**负责构建统一、安全的金融工具 MCP Server 集群，封装银行内部核心系统与外部数据接口。具体包括开发产品画像、账户管理、支付处理、保险评估等专属 MCP Server，并集成 RAG 系统作为知识 MCP Server，为上层智能体提供标准化、安全化的数据与工具调用能力。

- **信贷风险评估 Agent 的 ReAct 框架实现：**独立设计并实现基于推理-行动（ReAct）框架的信贷风险评估 Agent。该 Agent 能自动解析贷款申请，通过智能调用 MCP Server 中的征信查询、收入分析、负债比对等工具链，完成从数据收集、分析到初步风险评级与授信建议生成的全自动化流程。

- **端到端系统集成与流程验证：**负责多智能体协作主流程的串联开发与全链路测试，确保从用户多模态输入、意图识别与追问、智能路由、多 Agent 并行/串行处理、MCP Server 调用、业务工具执行、数据库/RAG 访问，到最终结果优化与交付的完整业务闭环的稳定与高效。

项目优化与技术创新

- **动态任务依赖分析与混合调度引擎：**设计并实现智能体任务的动态调度策略。通过实时分析子任务间的依赖关系，对无依赖任务（如信用评估与市场分析）启用并行执行，对存在强逻辑链的任务进行串行调度。该机制使复杂业务请求的整体处理效率提升 40%。

- **场景自适应的动态上下文管理：**针对不同业务场景的对话特点，设计差异化上下文管理方案。对于简短查询，采用滑动窗口保留最近对话；对于长期的财富规划类深度会话，则利用大语言模型（Qwen-Max）对历史对话进行递归式摘要压缩，提取关键决策与客户偏好，有效解决了长对话带来的性能与成本挑战。

- **企业级 RAG 系统与向量化知识库构建：**主导构建基于 Milvus 向量数据库的银行内部知识增强检索（RAG）系统。将产品手册、合规文件、历史案例等海量非结构化文档向量化存储，为各业务智能体提供实时、精准的知识检索支持，并将其封装为知识 MCP Server，确保输出内容的专业性与合规性。

项目成果：

- 成功整合银行零售业务 7 大核心场景（查、咨、交、贷、投、风、服），将客户单次需求解决率提升至 90%，客户满意度达 90%。
- 系统实现 85% 以上常见零售金融业务的自动化处理，尤其在智能投顾与信贷预审场景形成高比例自动化闭环，有效释放客户经理产能。
- 通过多智能体协同调度与混合模型策略，使系统平均任务响应时间缩短 30%，高峰期并发处理能力提升 3 倍，为未来面向海量客户的服务扩展奠定了坚实基础。

2024.04 - 2025.03

基于 RAG 的银行智能客服系统（邮储智答）

技术栈：Python, Milvus, BERT, Sentence-BERT, Qwen2.5-7B, LoRA, RagAS, OCR, FastAPI

项目背景

银行客户日常咨询高度集中于账户管理、贷款政策、理财产品、安全风控等高频问题，传统规则引擎或关键词匹配方式存在语义理解弱、知识更新慢、跨文档推理能力差等问题。为提升客户服务效率与合规性，设计并落地了一套面向金融领域的智能问答系统——**邮储智答**，实现精准、可信、可解释的自动应答能力。

主要职责

- 构建银行专属 RAG 知识库，整合内部制度文件、产品说明书、监管政策、FAQ 手册等非结构化资料（PDF/Word/扫描件），累计处理 60 万+条高质量数据；
- 文档预处理：实现金融文本加载、敏感信息脱敏、语义分块（按条款/章节边界）、多模态内容解析；
- 搭建 Milvus 向量数据库，设计 3 个独立 collections 分别存储：产品知识（理财/贷款）、合规政策（银保监/反洗钱）、客户服务流程，支持权限隔离与高效检索；

- 开发 BERT 意图识别模块，支持 4 类核心意图分类：（账户服务、信贷咨询、理财推荐、风险与合规），F1-score 达 91%；
- 实现端到端 RAG 流程：根据用户意图路由至对应知识子库，动态拼接 Prompt，调用 Qwen2.5-7B 模型生成合规、简洁、专业的自然语言回答，支持对话上下文感知与风险提示。

项目优化与技术创新

1 金融多模态文档增强处理

针对银行大量扫描合同、表格、利率表等图像型 PDF，集成 PaddleOCR + Layout Analysis 提取结构化文本与关键字段（如年化利率、还款周期），并通过大模型补全文档语义，显著提升知识完整性与准确性。

2 Query 理解与金融语境重构

设计面向金融场景的 Query 优化策略：

- 术语标准化（如“房贷” → “个人住房贷款”）
- 模糊指代消解（如“这个产品”结合上下文定位）
- 合规性约束重写（过滤诱导性/承诺性表述）
- HyDE 伪答案生成（模拟合规回答引导检索）

3 混合检索与金融相关性排序

- 采用 父-子块索引策略：父块保留完整条款上下文，子块用于细粒度匹配；
- 融合 稠密向量（Sentence-BERT） + 稀疏向量（BM25），加权召回兼顾语义与关键词匹配；
- 引入 Cross-Encoder Reranker 对 Top-10 结果重排序，Top-5 金融相关性提升 38%。

4 领域适配与生成控制

- 基于 LoRA 对 Qwen2.5-7B 进行轻量化微调，注入银行术语、监管话术及风险披露模板；
- 设计 结构化 Prompt 模板，强制模型包含“免责声明”“以官方文件为准”等合规要素，有效抑制幻觉与越权回答。

5 评估体系与合规验证

- 采用 RagAS 框架 量化评估系统性能：
 - 答案相关性（Answer Relevance） ≥ 0.90
 - 忠实性（Faithfulness） ≥ 0.92 （严格对齐原文，避免编造）
- 构建 1200 条人工标注测试集，覆盖典型业务场景与边缘案例，整体准确率达 93%，并通过内审合规初筛。

项目成果

- 系统上线后覆盖 85%+ 的常规咨询场景，**人工坐席重复性工作**量下降约 55%；
- **客户首次响应准确率**提升至 90%+，**NPS（净推荐值）**环比提升 12 个百分点；
- 支持监管政策动态热更新，具备私有化部署能力，已应用于 3 家区域分行试点，**获总行数字化创新奖提名**。

2023.09 - 2024.06

基于知识图谱的智能商业问答系统

技术栈： Python, PyTorch, Transformers, BERT-BiLSTM-CRF, CasRel, Neo4j, Scikit-learn, Flask

项目背景

面对客户在市场分析、竞品追踪和风险预警中频繁提出的结构化查询需求，传统关键词搜索或人工查阅效率低下且难以理解语义。本项目在原有舆情知识图谱基础上，构建了一个**端到端的知识图谱问答系统（KGQA）**，支持用户以自然语言提问，系统自动解析意图、链接实体、生成图谱查询并返回精准答案，显著提升商业情报获取的交互效率与智能化水平。

主要职责

1 自然语言问句理解与语义解析：设计并实现问句意图分类与槽位填充模块，结合预训练语言模型（BERT）对用户问题进行语义解析，识别核心实体、关系类型及查询模式。

2 实体链接与消歧增强：复用并优化原项目中的两阶段实体消歧方案（规则+BERT 语义匹配），将问句中的提及（mention）精准链接至 Neo4j 图谱中的标准实体节点，解决“苹果”指代公司还是水果等典型歧义问题。

3 图谱查询自动生成与执行：基于解析结果，动态生成 Cypher 查询语句，对接 Neo4j 数据库执行查询。针对复杂问题，设计模板+规则+神经排序混合策略，提升查询生成准确率。

4 问答服务与交互界面开发：基于 Flask 构建 RESTful API，提供问答接口；开发轻量级 Web 前端，支持用户输入自然语言问题、查看结构化答案及关联子图可视化，实现“问-答-探查”一体化体验。

项目优化与技术创新

• 面向商业场景的问句-图谱对齐机制

构建领域适配的问句模板库，结合 CasRel 抽取的关系类型进行对齐，使 90%以上的常见商业问题可映射到标准图谱查询路径。

• 语义增强的实体链接（Entity Linking）

在原有消歧基础上，引入 FAISS 向量索引加速候选实体检索，并利用上下文 BERT 嵌入计算问句与实体描述的语义相似度，链接准确率达 92.3%（测试集 F1）。

• 混合式查询生成策略

对简单问题采用规则模板生成 Cypher；对复杂/模糊问题，使用序列到序列（Seq2Seq）模型生成候选查询，再通过图谱验证+重排序选出最优执行方案，兼顾准确性与泛化能力。

• 高效问答响应

通过 Neo4j 索引优化、Cypher 查询缓存及异步批处理机制，在包含 8 万+实体、35 万+关系的产业知识图谱上，95%的问答请求响应时间控制在 1 秒内。

项目成果

- 成功将静态知识图谱升级为可交互的智能问答系统，用户无需学习图数据库语法即可获取结构化商业情报。
- 在内部测试中，系统对典型商业问题的回答**准确率达 87.6%**，分析师日常查询效率**提升约 65%**。
- 已部署至 3 个重点客户场景，支持“供应链穿透查询”、“竞企合作网络分析”、“高管关联挖掘”等高价值问答任务，获得客户高度认可。
- 沉淀出一套可复用的 KGQA 技术框架，涵盖**问句理解、实体链接、查询生成、图谱执行**四大模块，为后续金融、医疗等领域的知识问答系统提供标准化基础。

教育背景

安徽财经大学

2019.09-2023.07

本科

自我评价

- 三年开发经验，深耕 RAG、多智能体与大模型应用方向，完整经历多个项目从设计、开发到上线的全过程。
- 可独立开发项目，具备从需求分析、架构设计、编码实现到部署上线的全流程闭环能力，曾主导宠物品种识别服务从 0 到 1 落地。

- 责任心强，善于把复杂技术转化为稳定可用的解决方案，注重用户真实反馈与业务价值。
- 熟练使用 Cursor、Claude Code 等 AI Coding 工具辅助开发，显著提升开发效率与代码质量。