

张岳

AI应用开发工程师

☎ 离职 📅 1998/12 📞 13227717538 ✉ 1016708772@qq.com

专业技能

- 智能体架构与安全：熟练掌握Agent Harness Engineering，实现智能体工具调度、安全权限管控、掌握MCP(Model Context Protocol)工具协议、权限Hook拦截、上下文状态管理，构建稳定可控的Agent生产运行环境。精通vibe coding及各类主流 AI编程工具，包括codex、cursor、Claude code、trae等。
- 提示词与上下文工程：精通Prompt & Context Engineering，具备提示词版本管理、长上下文策略控制、自动化评测与负样本优化经验；熟练运用Pydantic Schema/JSON Mode 实现复杂的LLM 结构化输出。
- RAG检索增强全链路：熟悉RAG 全链路，涵盖文档切片、Embedding向量化、HNSW混合检索、Cross-Encoder Rerank，Metadata 过滤及权重调优等环节，具备实际项目落地经验。
- 多智能体协同与核心机制：熟悉 Agent智能体开发，掌握Function Calling/ Tool Use机制与 Skills 技能库设计；深入理解MCP协议标准与双层Memory 记忆机制，熟练运用ReAct推理范式进行多Agent协同编排(Multi-Agent)，具备工具链注册、意图拆解与状态流转等深厚工程实践经验。
- LLM 推理与性能调优：熟悉 LLM 推理性能调优，了解 Prefix Caching/ KV Cache 机制，具备 TTFT 优化、Token分级控制、多模型动态路由等调优经验。
- 工程编排与可观测性：熟悉LangGraph/LangChain 工作流编排，具备SubGraph子图拆分、Checkpoint状态持久化、SSE流式输出、LangSmith全链路追踪等实践经验。
- 全栈开发与工程素养：熟悉Python后端(FastAPI、asyncio)与现代前端工程化(Vue/React、TS、H5/数据看板适配)，具备AI应用全链路交付能力；熟悉PostgreSQL、向量数据库、Docker容器化部署。

工作经验

深圳市腾辉电子商务有限公司

AI应用开发工程师

2022/07 - 2026/05

- 负责AI应用后端服务开发与核心技术验证，围绕智能客服、数据中台、内容运营、直播切片、素材中心、销售考核和模型微调等场景推进产品化落地。
- 主导聊天数据清洗、RAG知识库、Prompt评测、LLM推理优化、LangGraph Agent编排、RTC实时语音链路和模型微调等核心模块建设。
- 参与MCP多Agent共享服务架构设计，将LLM网关、RAG、记忆、Prompt管理抽象为共享服务，支撑多个AI业务复用同一底座。
- 建立数据中台回流机制，让客服对话、直播ASR、素材增强、考核结果和微调样本形成闭环，持续提升模型回复质量与业务一致性。

- 1.对公司员工进行AI培训；
- 2.负责公司AI Agent开发，与各Agent归属部门对接需求。

项目经历

项目一：售前顾问Agent

AI应用开发工程师

2024/03 - 至今

业务场景：面向电商私域销售场景，把销售在微信/WhatsApp的对话数据经中台清洗后建立RAG知识库，构建可实时语音对话的智能客服，承接商品咨询到引导下单的全流程。

核心贡献：

1. 知识库直接消费数据中台导出的RAG数据:采用自定义标识符切片解决语义截断，应用HNSW_HYBRID 混合检索+Int8量化，构建Metadata标签过滤机制，存储空间降低75%。
2. 接入多模态内容资产平台，命中图片、视频等素材后以“文字+图片+视频”混排分条返回，让语音/图文客服具备多模态应答能力。
3. 针对语音场景优化检索链路，通过降维+精简Limit策略，引入base-rerank轻量模型，动态平衡dense_weight权重，在保持语义理解的同时显著提升专有名词命中率，检索速度提升4倍。
4. 极致优化 LLM 推理链路：固定 RAG 检索片段排序、合并System Prompt 消息体，深度触发模型前缀缓存(Prefix Caching)与KV Cache，将复杂 RAG场景的首字延迟(TTFT)从 15s 压缩至 2s内，并针对多轮模型选型与资源池优先级调优。
5. 深度优化RTC传输链路(ASR/TTS):基于ASR实时捕获用户情感波动，配合TTS声音复刻实现情绪化回复；结合FEC前向纠错+自适应 Jitter Buffer，在 50%高丢包环境下实现语音对话无感知恢复。

项目二：AI数据中枢&模型微调

AI应用开发工程师

2024/03 - 至今

项目描述：构建 AI 生态的数据底座，打造从微信原始聊天记录清洗、脱敏，到SFT/DPO规范化训练数据准备，再到 RAG 知识库扇出的全链路数据治理与模型微调闭环。

1. 流水线数据治理：从微信本地SQLite(MSG0-5.db + MicroMsg.db)抽取消息,完成 wxid → 显示名映射、群消息发送者解析、时间过滤与(session,timestamp,content) 去重后落 raw_chats 不可变原始库（不可变）。
2. 构建过滤与脱敏引擎：构建多级优先级（系统、媒体、敏感、过短、闲聊、垃圾、高价值）规则分类引擎，对手机号、身份证、银行卡、邮箱、API Key 等敏感信息做正则脱敏；设计清洗时 + 写入时 + 导出时三重冗余脱敏，以 5 分钟时间窗切分并合并同角色对话，脱敏准确率达98%。
3. 建设 Staging审核中枢：以approved状态数据为唯一可信源，支持ShareGPT / Alpaca等多格式导出，并在扇出前经过风格修复，价格脱敏硬红先等7个节点为微调级清洗，防止信息泄露。
4. 灵活的数据分流策略：贯彻“微调管风格、RAG管知识”的架构理念，将清洗后的数据精准分流为SFT训练集与RAG知识库，后续业务知识更新仅需维护知识库，无需重新训练模型。
5. 构建三层评估体系：确立自动化指标、人工A/B盲评与线上业务指标三层评估模型，微调模型上线后客户回复率提升23%，咨询到下单的转化率达到18.2%(与人工客服的19.7%基本持平)。
6. 实施本地+云端 & SFT+DPO两阶段微调：本地采用 LLaMA-Factory + Qwen2.5-3B-Instruct 做 QLoRA微调验证数据质量，通过后采用数据等你缩放超参结合火山方舟对doubao-通用litter进行生产级LoRA微调；SFT 解决「从不会到会」的风格模仿，DPO 对销售标注的偏好进行精排训练，解决「会说但说不好」;跳过奖励模型训练、实现高稳定、低成本的风格对齐。
7. 构建Embedding - 向量检索 -Rerank三阶段RAG Pipeline：Embedding 向量化 + 向量检索 top-20 粗召回，引入 Cross-Encoder 精排取 top-5，解决双编码器在语义相近文档上区分度不足的问题，知识命中率从 72% 提升至 89%。

8. 微调后的模型作为 LLM 层接入 RTC 实时语音链路(客户语音 → ASR → RAG → 微调LLM → TTS → 语音回复), 通过微调缩短 system prompt 降低 TTFT,完成「数据中台 → 微调 → 客服」闭环。

项目三：AI直播内容生产Agent

AI应用开发工程师

2024/03 - 至今

项目描述：公司有直播带货场景，把直播回放交给 AI自动找精彩片段、配标题文案，减轻剪辑师工作，转写结果同步回流数据中台留存复用

1. 设计「视频 → AI 找精彩片段 → 输出短视频切片」端到端三层架构：React 19 + FFmpeg.wasm 前端、FastAPI + SQLAlchemy 2.0 后端、Groq Whisper+ DeepSeek 外部 AI。
2. 浏览器内 FFmpeg.wasm 提音频：用 WORKERFS 零拷贝挂载源文件,转码为 16kHz/单声道/64kbpsMP3, 把 2.5GB 视频压到约 30MB 再上传,上传体积降低 99%,用户等待从分钟级降到秒级。
3. 用PostgreSQL 实现任务队列，API 写入 pending 秒回、Task Runner 后台协程每秒抢占一条串行执行，进程崩溃时自动重置「进行中」任务回 pending,实现零云依赖 + 崩溃可恢复。
4. 打造可观测 Pipeline：进度统一写库 + SSE 每秒读库推送,进度源唯一、断线可续、多端一致；长音频用 ffmpeg -c copy 按 25 分钟无损分段串行转录，时间戳加 offset 标记时闭环。
5. 导出阶段二次复用FFmpeg.wasm:在浏览器内按AI时间段批量裁剪切打包ZIP，后端不碰重型转码；ASR转写结果回写数据中台留存，为后续内容分析/训练备用。

项目四：内容营销 Agent

AI应用开发工程师

2024/03 - 至今

项目描述:持续产出商品图、商品介绍、宣传文案，做一个内容生成Agent降本增效；产出的图片直接关联到素材中心，反哺多模态知识库。

1. 基于LangGraph构建多阶段内容生成工作流，用SubGraph子图将选题、写作、配图拆为独立编排单元；通过PostgreSQL Checkpointer持久化状态，支持任意历史节点回溯与增量重试，将故障恢复粒度从整单降低到单节点。
2. 设计MetricsContext上下文管理器做LLM全链路追踪，采集各节点Token消耗、推理延迟、错误率，结合火山引擎定价模型完成成本核算，为模型选型提供数据支撑。
3. 实现SSE 流式输出与LangGraph astream_events 深度集成，监听 on_chat_model_stream 捕获Token级实时流，配合前端ReadableStream将感知TTFT降低60%，并保证流式/非流式下checkpointer数据结构一致。
4. 针对弱类型生成或异常并行优化:asynciogather+run_in_executor将同步API封装为协程并发执行，引入指数退避重试(1s → 2s → 4s)应对服务抖动，整体生成耗时缩减70%。
5. 构建结构化输出路由:简单任务走轻量Flash模型，复杂任务走旗舰模型，配合with_structured_output 做 Pydantic Schema 强约束，并用 JSON Mode + 手动解析解决结构化输出与Token统计不兼容问题，降低 40%推理成本。
6. 设计环境变量驱动的Mock开关体系(llm/image/checkpointer)解耦外部服务，配合SwaggerUI可视化评测与 Ngrok公网映射，将本地调试效率提升3倍；接入LangSmith+测试gpt-4o+request_id实现全链路可观测、问题定位从小时级缩短到分钟级。

项目五：MCP Infrastructure服务集群

AI应用开发工程师

2024/12 - 至今

项目描述：随 AI 项目增多做架构层统一收口，把 LLM 网关、RAG检索、会话记忆、Prompt 抽离为可独立调用的MCP Server集群，让所有业务复用同一套底座。

核心贡献：

1. 模型无关架构设计与网关治理：构筑模型无关的网关治理中心，统一收口LLM。通过YAML配置实现逻辑模型名到多级Endpoint的热切换，业务侧无感替换。在网关层集成统一的重试、限流、熔断及Fallback机制，优化调度策略，降低40%推理成本。
2. 基于MCP协议的原子化能力能力套件(Harness)：采用 MCP 协议作为架构基座，将LLM网关、RAG检索、Memory记忆抽离为3个独立的 MCP Server，实现能力的原子化、可插拔化与跨业务复用。通过 Streamable HTTP 暴露标准化Tool/ Prompt/Resource原语，使上层业务仅需专注于 Agent编排，达成快速接入。
3. 四层中间件桥接网关：基于FastAPI构建「认证→日志配额→限流熔断→路由」四层中间件链，将传统 REST请求高效转换为MCP调用。实现项目维度租户隔离与Token配额计量，全链路TraceID驱动可观测性。
4. 实现多租户 RAG 共享：基于火山引擎 Viking DB 按 project_id 划分独立 Collection 做物理隔离，按 Markdown 标题层级 + 段落边界语义切分，新项目调 ingest_document Tool 即可自助接入。
5. 设计双层记忆架构：对话记忆按项目于会话硬隔离，用户画像数据基于 PostgreSQL UPSERT 幂等共享，使客服 Agent 提取的用户偏好能即时同步至自媒体运营Agent，同时让Agent进程完全无状态，支持弹性水平扩容。

项目六：AI多模态内容资产平台

AI应用开发工程师

2024/03 - 至今

项目描述：统一管理商品图 / 详情 / 视频 等营销素材, 为智能客服体统提供多模态回复能力。

1. 三模态统一表架构：基于pgvector (1024 维 + HNSW)设计跨模态数据表，实现文字、图片、视频三模态用一张表。核心理念为向量化多模态素材的“检索文本”而非媒体本身，实现一条SQL完成跨模态精准召回。
2. 自动化数据离线增强：落地离线增强流水线，组合调用 RapidOCR 提取图片文本、豆包视觉模型生成看图描述、ASR+LLM提取视频口播摘要，将机器增强内容追加重写至检索文本并重新向量化，召回相似度从 0.38显著提升至0.71。
3. 支持长视频分段与混排应答：长视频按 ASR 时间戳分段为多条rag_assets,media_url携带 #t= 秒数，命中后播放器直接跳转精彩片段；统一应答按「文字必发、图≤3、视频≤1」混排、阈值递增；隐私红线为命中返回打码版 TOS URL。
4. 视频时间戳精细定位：在离线 ASR 阶段保留每句口播的时间戳，长视频按60s窗口切分为独立资产，生成的 media_url 携带时间锚点（如#t=60），前端命中后播放器可直接跳转对应时间点。
5. 隐私合规与文件管理：系统检索展示层对外仅暴露打码/水印后的 masked 版本资产，原始高精度图仅对 OCR/VLM可见；支持云存储与本地存储双模式，并提供基于大模型的标签自动补全建议。

自我评价

对AI应用开发充满热情，保持对大模型、Agent、RAG等新技术的持续学习与实践。具备较强的问题分析和工程实现能力，做事踏实，责任心强，能够承受较大的工作压力。

教育经历

太原学院

物联网工程

2018/10 - 2022/06