

张杰

电话: 17681104864 | 邮箱: zhangjay1024@163.com

年龄: 27岁 | 性别: 男 | 政治面貌: 中共党员

教育: 河南牧业经济学院-数据科学与大数据技术-全日制统招本科-2023年

当前状态: 在职, 正在找工作 | 求职意向: Agent开发工程师 | 学历: 本科 | 工作经验: 4年



工作经历

深圳市讯方技术股份有限公司

2024.08 - 至今

Agent 开发工程师 研发中心

参与教学有方Agent系统与智慧教育平台从0到1的开发, 包括业务调研, 技术选型, 最终技术落地, 服务于500+高校使用。

参与政企知识大脑 RAG 系统调研与开发, 落地知识接入、权限过滤、版本管理与多轮问答等功能。

山东婴儿儿健康管理有限公司

2023.02 - 2024.07

开发工程师 流程与信息中心

主导华恩追溯系统与华恩供应链(ERP) 从0到1的建设包括技术选型, 编码实现, 数据库设计, 测试上线等, 服务于900+加盟店。

参与婴儿儿业务系统, 婴儿儿APP的功能迭代升级, 技术选型等, 服务与1000+门店, 5000+员工使用。

项目经历

教学有方 (Agent 系统)

Agent 全栈开发工程师

2025 年 10 月-至今

项目介绍: 教学有方是面向高校校企合作场景打造的 AI 智能体教育 SaaS 平台, 服务学生、教师、院校管理者及运营人员。

项目在对接智慧教育平台多租户权限基础上, 建设 AI 智能体中台, 提供校规智能问答、课程知识问答、教案与试题生成、授课质量分析及视频知识点定位等能力, 形成覆盖“学、教、管、评”的智能化教学闭环。

核心技术: FastAPI + LangGraph + Milvus + BGE-M3 + bge-reranker-v2-m3 + RabbitMQ + Celery + Redis + MySQL

个人职责:

- 参与 AI 智能体中台架构设计与技术选型, 主导 Python Agent 服务与 Java 业务系统的集成落地; 通过 RESTful API 承接实时问答类同步调用, 基于 RabbitMQ 解耦教案生成、文档解析等长耗时异步任务, 通过请求幂等、消息确认、失败重试及补偿机制, 保障异步任务可靠投递与结果回传, 支撑跨系统业务数据的最终一致性。
- 基于 LangGraph 构建 Supervisor-Worker 多智能体工作流, 由 Supervisor Agent 负责意图识别与任务路由, 编排课程知识问答、教案生成、试题生成等专用 Agent; 基于 StateGraph、条件路由及 Checkpoint 等能力, 统一业务 State Schema 和 Agent 输入输出协议, 并封装节点异常重试与中断恢复机制。
- 设计并落地全链路多租户数据隔离体系, 向量层基于 Milvus Partition Key 实现租户数据逻辑分区, 写入侧强制绑定租户及文档权限元数据; 检索侧将租户、课程及可见范围过滤条件下推至召回请求, 构建 BGE-M3/BM25 多路召回、RRF 融合及 bge-reranker-v2-m3 精排链路, Agent 运行态透传租户标识实现会话与记忆数据隔离。
- 基于 RabbitMQ + Celery 搭建教学文档异步处理流水线, 实现 PDF、Word、PPT 等格式的解析、清洗、语义切片、Embedding 及向量入库; 在写入阶段绑定租户、知识库、课程及可见范围元数据, 支持院校自助构建课程与校规知识库。
- 设计教学场景多租户分层会话记忆体系, 基于 Redis 管理 Agent 工作流 Checkpoint 与实时上下文, MySQL 持久化会话消息、滚动摘要与结构化记忆, Milvus 构建可检索记忆向量索引, 通过 Celery 异步完成摘要更新与记忆沉淀。

项目亮点:

- RAG 检索架构升级: 落地 BM25 稀疏检索与向量稠密检索并行召回 + RRF 融合+Reranker 精排的三级检索架构, 多路召回 20 个候选段落, 经重排后输出 Top4 注入生成环节, 解决单一检索召回率低、语义相关性不足的问题。基于垂直领域测试集评测, Recall@20 达 94.3%, MRR@5 达 0.81。
- 文档分块策略升级: 替换固定长度切片为“标题层级优先 + Token 兜底”分块方案, 配套标题路径注入、表格分片保活、冗余内容清洗策略。优化后切片无效 Token 占比从 31% 降至 9%, 知识点跨切片截断率降至 4%; 同等召回量下单轮上下文 Token 减少 38%, 在降低推理成本的同时, Top-5 检索准确率提升 7 个百分点。
- 并发上涨后大模型接口频繁限流、超时, 单链路失败直接导致用户请求失效。搭建“重试+备用轻量模型降级+语义缓存兜底”

三级容错链路,失败自动重试,超限切换模型,极端场景命中缓存直接返回。最终大模型整体调用成功率从 92.5% 提升至 99.7%, 全程用户无感知。

4、针对简单问答也走完整多 Agent 流程、冗余开销高的问题,在 Supervisor 层新增意图复杂度分级:校规查询、单知识点问答等事实类简单问题,直接短路到「单路检索 + 生成」的轻量路径,跳过多节点规划与全量工具加载;仅教案生成、跨章节综合题等复杂任务,才展开完整 Supervisor-Worker 链路。基于 600 条标注 Query 验证,简单问题占比约 55%,该类请求平均 Token 从 4200 降至 1600,全站推理 Token 成本下降约 31%;简单问答 P95 时延从 1.8s 降至 0.9s,路由准确率达 94%,复杂问题误短路比例控制在 3% 以内。

5、针对 Supervisor 向 Worker 全量透传 State,造成历史消息、跨节点工具结果重复注入的问题,基于统一 State Schema 建立按节点维度的字段投影与上下文预算机制,仅向下游传递任务参数、滚动摘要及必要检索证据,过滤无关历史与原始工具输出。优化后多 Agent 内部调用平均输入 Token 降低约 35%,长链路场景 Prompt 超限率下降约 80%。

政企知识大脑 RAG 系统

Agent 全栈开发工程师

2025 年 04 月-2025 年 10 月

项目介绍: 政企知识大脑 RAG 系统是讯方技术面向运营商业务、政企数字化、华为云服务、大企业 IT 服务四大政企业务板块,基于检索增强生成(RAG)技术打造的企业级智能知识管理系统。系统旨在解决企业知识分散难检索、经验随人员流动流失、新人培养周期长、售前方案设计效率低、涉密知识权限管控难等核心痛点,将分散在文档、邮件、日志、代码中的技术知识与项目经验,整合为可智能检索、可问答、可生成的企业知识资产。

核心技术: FastAPI、LangGraph、Celery、RabbitMQ、Milvus、BGE-M3、bge-reranker-v2-m3、MySQL、Redis

个人职责:

- 1、负责知识接入与处理链路开发,基于 Celery、RabbitMQ 构建异步处理任务,实现 PDF、Word 等文档解析、内容清洗、结构提取、分块、BGE-M3 向量化及 Milvus 入库;根据标题层级、段落、表格和长度阈值进行混合分块,保留章节路径、页码及来源信息。
- 2、负责知识生命周期与版本管理,实现文档上传、审核发布、批量导入、版本更新及失效下线;文档更新时按文档 ID 清理旧版本 Chunk,并重新完成解析、分块和向量化,避免多个版本同时参与检索。
- 3、负责 OA 权限信息与知识检索链路集成,对接 OA 获取用户身份、部门及负责业务等组织信息,结合知识平台中的业务线、客户项目、密级和可见范围计算授权范围;检索时将权限条件下推至 Milvus,并在召回内容进入大模型上下文前再次校验。
- 4、参与多轮问答与异常处理功能开发,基于 LangGraph 管理会话状态,通过历史消息和问题改写改善连续追问效果;针对模型超时、检索无结果等情况实现重试、纯检索结果返回和无证据拒答。

项目亮点:

- 1、实现企业共享、业务线共享、客户专属和项目专属知识的分级检索,通过“OA 身份信息、Milvus 权限过滤、生成前校验”控制知识访问范围,降低跨业务和跨项目越权风险。
- 2、针对企业知识内容来源复杂、版本更新频繁及历史文档失效等问题,设计知识审核、版本管理和增量更新机制。审核通过后的文档自动完成分块、向量化及 Milvus 入库;文档更新时根据文档版本和分片标识进行增量替换,避免重复向量和旧版本知识干扰检索结果。
- 3、落地面向企业场景的多轮问答记忆机制。通过历史消息加载、指代消解和问题改写提升连续追问场景下的检索准确性;采用“最近 8 轮问答+滚动摘要+关键事实”压缩上下文。在多轮问答测试集上,追问回答准确率达到 92%,关键事实召回率达到 96%;在 50 轮会话场景下,相比全量携带历史消息,平均输入 Token 消耗降低 65%。

讯方智慧教育平台(SaaS)

全栈开发

2024 年 08 月-2025 年 03 月

项目介绍: 面向职业院校产教融合场景的一体化运营管理平台,总部、片区、运营中心(派驻高校),覆盖教学管理、协同办公、课程中心、实训实践、考试竞赛、系统管理六大业务域。核心解决派驻讲师与运营团队的工作量核算、成果申报、履约跟踪、周报例会四条业务主线的线上化与审批闭环,支撑专业共建与云校两条业务线的独立统计与合并核算,服务多所合作院校。

核心技术: Spring Cloud+Spring Security +Spring Boot+MyBatis-Plus+Redis+XXL-JOB+Vue3+noVNC

个人职责:

- 1、参与统一认证与多租户权限底座建设:基于 Spring Security OAuth2 和 Redis 管理不透明访问令牌,支持主动失效及同账号跨租户切换;结合组织树、角色数据范围和 MyBatis-Plus 拦截器,实现租户及组织级数据隔离。
- 2、完成协同办公、教学板块对应板块的 API 接口与前端页面开发。
- 3、设计轻量级配置化审批内核,将流程定义、节点配置、审核记录与业务单据解耦,复用于课时、成果及履约协议等场景;通过

- 状态机、乐观锁和操作幂等机制支持多级审核、驳回重提、批量审核及分阶段撤销
- 4、设计云主机、虚拟机、容器及 SaaS 实验环境统一模型；基于 noVNC 和 WebSocket 反向代理提供浏览器桌面访问，通过短时连接凭证隔离真实实例地址，并实现环境保存恢复和闲置资源回收。
- 5、设计视频与资料的完整上传播放链路，前端分片实现秒传与断点续传、上传完成后异步触发转码切片，记录进度支持断点续播。

华恩供应链(SCM)

后端开发工程师

2024 年 02 月-2024 年 08 月

项目介绍：主导从 0 到 1 开发华恩供应链系统(ERP)，华恩集团成立供应链公司，区别于当前的连锁门店独立运营，将母婴产品售卖给经销商或门店，为合作的子经销商提供销售，供应链实现了基础资料管理、采购管理、库存管理、分销管理和资金管理功能。仓库实现与京东仓库平台对接，将仓库与物流托管与京东。

核心技术：Spring Cloud + Spring Boot + OpenFeign + Mybatis plus + Redis + Mysql + Quartz + RabbitMQ

个人职责：1.基础资料、采购管理、分销管理、商品溯源流转、对接京东等业务的流程设计与开发。

婴幼儿业务系统-婴儿掌上 APP

后端开发工程师

2023 年 02 月 - 2024 年 02 月

项目介绍：婴幼儿业务系统是一项致力于将门店经营数字化的项目，旨在提升门店员工与总部后勤员工的工作效率，加强店铺管理与运营的一体化平台。该系统以业务系统管理平台与婴儿 APP 为核心，完成会员管理、营销活动管理、门店信息管理、基础资料维护、电商平台运营、报表以及订货等重要功能。

核心技术：Spring Cloud +Spring Boot + Nacos + OpenFeign + FastApi+Pandas+XGBoost

个人职责：

- 1、开发婴儿小程序商城、会员回访标签，会员分群，对接算法预测等功能。
- 2、开发会员复购预测模型(分类+回归+推荐):预测未来 1 个月会复购特定品类的的会员及其下次消费的精确日期和商品品牌，并使用 FastApi 开发接口对接现有业务系统。

专业技能

Agent 智能体：

- 1、熟练掌握 LangChain / LangGraph 大模型应用开发框架，掌握 StateGraph、条件路由、Checkpoint、多智能体编排、任务拆解、状态管理与异常恢复机制，具备企业级 Agent 系统落地经验。
- 2、熟练掌握 Agent 工程化核心技术，包括 Function Calling、工具调用容错、提示词模板设计、多轮会话记忆、上下文压缩、意图识别与任务路由，能够独立完成 Agent 服务设计与开发。
- 3、熟练掌握 RAG 全链路建设，掌握文档解析、清洗、语义分块、Embedding、多路召回、RRF 融合、Rerank 精排、引用溯源与评估体系，熟悉 BGE-M3、bge-reranker-v2-m3 等模型应用。
- 4、了解 MCP/Skill 的定位与差异，熟悉 Agent 工具封装、工具注册、参数校验、调用日志与失败兜底机制。
- 5、熟练使用 Claude Code、Codex 等 AI 编程工具提升项目开发效率

全栈开发：

- 1、熟练掌握 Java / Python 双技术栈开发能力，熟悉 Spring Boot、Spring Cloud、MyBatis-Plus、Redis、MySQL、Nacos、OpenFeign，能够完成 AI 服务与业务系统、权限体系、数据平台的集成。
- 2、熟练掌握 FastAPI / Flask Python Web 开发框架，掌握接口设计、异步任务编排、SSE 流式输出、消息重试、幂等控制、超时降级和任务状态回传机制。
- 3、熟悉 RabbitMQ / RocketMQ 消息中间件，掌握异步解耦、延迟任务、重试队列、消费确认、消息幂等与积压处理方案。
- 4、熟练使用 Pandas、Numpy 数据分析，掌握 requests、selenium 爬虫与逆向分析。
- 5、掌握前端基础：HTML、CSS、JS。熟悉使用 Vue2、Vue3、Element-ui、Ant Design 进行前端的开发。

数据库、运维：

- 1、熟练使用 MySQL, Oracle 等关系型数据库，掌握数据库常见性能调优手段。熟练使用非关系型数据库 Mongodb、Redis，熟悉缓存雪崩，缓存击穿等缓存高并发问题的解决方案。
- 2、熟悉 Milvus 向量库部署、集合设计、索引参数调优、分区规划与数据生命周期管理。
- 3、掌握 Git 分支管理、代码回滚、多人协作开发。
- 4、掌握 Linux 常见命令，熟悉 Docker 容器技术。