

简历

基本资料

姓名：徐福洋

工作经验：5 年

性别：男

年龄：30

邮箱：fookhsu@foxmail.com

联系电话：13125701680

求职意向：大模型应用开发

教育经历

吉林大学（985） | 计算机专业/财政学专业 本科 | 2014.09 - 2018.07

- 核心课程：数据结构、操作系统、计算机网络、数据库原理

核心优势

- 深度参与LLM从0到1预训练、指令微调与评测全流程，具备数据清洗、分布式训练及评测体系搭建的完整工程经验。
- 深耕昇腾AI生态，基于CANN/MindSpore与昇腾910实现国产算力高效适配与训练推理加速。
- 精通vLLM等推理框架及模型并行、PD分离部署，能针对业务场景设计高吞吐、低延迟的模型服务架构。
- 融合后端开发、RAG与Agent技术，具备将大模型能力深度集成至业务系统的端到端落地能力。

专业技能

- 模型与智能体**：精通Python及PyTorch，熟练加载与微调LLaMA/Qwen/ChatGLM等主流模型；掌握Prompt Engineering、ReAct流程，熟练运用LangChain/LangGraph构建具备记忆管理、工具调用、多轮对话与任务调度的Agent。
- 检索与评估**：熟悉Milvus向量数据库及Embedding模型，具备语义检索与长期记忆设计经验；掌握RAG全链路调优（文档解析、文本分块、召回策略、重排优化）；了解多模态输入处理；掌握RAGAs等评估工具应用逻辑。

- **后端开发**：熟练掌握Java及Spring生态、FastAPI与SQLAlchemy，熟悉MySQL、Redis、PostgreSQL。
- **部署与效率工具**：熟练使用Docker与Kubernetes完成服务部署与容器化交付；熟练运用Codex、Pi等AI辅助编程工具。

工作经历

北京外企德科人力资源服务上海有限公司 | 软件工程师 | 2022.11 - 至今

- **昇腾生态解决方案智能助手 (2025.03 - 2025.07)**：主导从0到1搭建基于RAG+LangGraph的智能问答系统，服务华为昇腾现场支撑团队
- **GPU物料智能管理 (2024.11 - 2025.02)**：负责智能体的意图识别以及网站API调用集成
- **昇腾生态迁移适配/客户模型底座训练 (2024.01 - 2024.10)**：负责客户昇腾生态迁移适配的技术支持与问题定位及客户模型训练
- **BMC软件开发 (2022.11 - 2024.01)**：参与网卡模块重构，基于skynet框架实现模块化开发

武汉踏浪出海科技有限公司 | Java后端开发 | 2021.03 - 2022.10

- **海外支付三方平台 (2021.03 - 2022.10)**：负责银行接口对接、资金回调链路维护与核心模块性能优化

中国建筑第六工程局有限公司 | 财务 | 2018.07 - 2021.02

项目经验

项目名称：昇腾生态解决方案智能助手 | **项目负责人** | 2025.03 - 2025.07

背景

现场支撑人员面对客户问题时，因专业知识储备不均，需频繁求助研发及周边团队，导致问题响应周期长、重复问题沟通成本高，缺乏统一的知识辅助工具。

方案

- 基于FastAPI+LangGraph+Milvus构建RAG智能问答系统，覆盖文档解析→向量化→混合检索→大模型问答全链路；
- 设计“向量+关键词”混合检索策略，引入查询改写与重排序，优化召回精度；
- 利用Redis缓存高频问答与Session状态，设计异常降级与兜底策略保障服务稳定性；
- 定义召回率 $\geq 90\%$ 、答案准确率 $\geq 85\%$ 的核心考核指标，建立“评估-调优-落地”迭代机制。

成果

- 系统成功上线，检索召回率从67%提升至90%以上，答案准确率达85%以上

- 有效降低了重复问题的沟通成本与周边团队支撑人力，日均问答200次。
- 沉淀标准化知识库接入与运营流程，形成可复用的解决方案

项目名称：GPU物料智能管理 | Agent应用开发 | 2024.11 - 2025.02

背景

研发环境中，开发及测试高度依赖共享的 GPU资源进行模型验证、代码开发及压力测试。虽然拥有一个物料管理平台用于查看机器的实时占用情况，但资源申请与释放仍高度依赖人工操作，存在操作链路长、信息滞后、资源抢占冲突频发等问题。

方案

- Agent 核心通过 LLM 进行意图识别，调用标准的 Tools
- 在提示词中固化“必须先查后占”、“默认时长设定”、“权限自动过滤”等安全规则。
- 当 Agent 收到网站 API 返回的错误时，不会直接报错，而是向用户推荐现有可用资源，提升容错性。

成果

- 将机器申请流程从平均 3-5 分钟（登录网页->筛选->确认->点击）缩短至 30 秒内
- 确保了不同角色的资源池的物理隔离，杜绝了资源抢占导致的任务失败的事故。
- 提高了机器利用率，通过 Agent 定时巡检，自动识别并提醒/释放超期占用的“僵尸任务”，释放闲置算力。

项目名称：昇腾生态迁移适配/客户模型底座训练 | PAE应用工程师 | 2024.01 - 2024.10

背景

客户希望从GPU等传统计算架构迁移至国产昇腾AI生态，但面临环境搭建不熟悉、模型算子不兼容、调试工具链差异大等障碍，迁移周期长且成功率低；同时部分客户需在昇腾算力上从头训练基模，涉及大规模集群配置与分布式训练策略选型，技术门槛更高。

方案

- 基于CANN、MindSpore/PyTorch及MindIE工具链，协助客户进行模型迁移、精度调试与性能调优，精准定位算子适配与环境依赖问题。
- 完成客户在昇腾算力上进行基模的完整训练流程的目标，包括数据预处理与格式转换、分布式训练策略（数据并行/模型并行/混合并行）配置与调优，协助排查集群通信（HCCL）瓶颈与训练过程中loss收敛异常等问题，保障大规模训练任务的稳定高效执行。
- 将高频问题与解决路径总结输出为标准化操作文档与最佳实践指南，降低客户学习成本。

成果

支撑某运营商客户完成昇腾生态迁移落地及基模训练全流程，训练任务稳定性与效率达到预期：

- 周故障率：稳定控制在 1% 以下；
- 平均无故障时间：核心集群硬件达到 4 天，最长无故障间隔达 21 天；
- 集群可用性：周可用率持续超过 99%，最长连续无中断训练时长达到 288 小时（12天）。

项目名称：BMC软件开发 | 软件开发工程师 | 2022.11 - 2023.12

背景

原有BMC网卡模块代码耦合度高、复用性差，面对灵活的硬件定制需求时，开发调整难度大、交付周期长。

方案

- 参与需求文档设计与评审，基于历史代码进行拆分，采用Skynet框架实现模块化解耦开发，重构核心业务逻辑。
- 依据接口文档编写全覆盖测试用例，完成功能验证与异常调试，精准定位并修复代码漏洞及接口异常问题。
- 与硬件团队紧密联调，确保软硬件接口时序匹配。

成果

重构后的模块复用性大幅提升，支撑了后续多个硬件版本的快速适配，开发调试效率提升约 30%，显著降低了新需求的交付周期。

项目名称：海外支付三方平台 | 后端开发 | 2021.03 - 2022.10

背景

公司在东南亚有相关金融业务，需搭建一套安全、高可用的支付服务平台，支撑放款收款、资金转移、充值提现等核心交易链路，日均请求峰值约5万笔，月均流水超千万人民币。

方案

- 基于Spring生态完成核心模块的需求评审与代码编写，采用MySQL+Redis缓存架构应对高频读写，使用Lua脚本保证Redis原子操作，借助RocketMQ保障分布式事务最终一致性。
- 负责多家海外银行请求与回调接口的联调开发、异常监控与日常维护，针对超时、重复通知等异常场景设计幂等与重试机制。
- 优化后端代码结构，使用Postman编写自动化辅助脚本，提升接口自测与联调效率。

成果

支付平台平稳支撑海外业务运行，银行接口调用成功率保持在99.9%以上，资金对账零误差，有效保障了跨境支付业务资金流转的安全性与顺畅性。