



李想_AI 应用开发工程师_3 年

基本信息

姓名：李想	性别：男	年龄：24	政治面貌：中共党员
籍贯：安徽省	电话：16655700207	微信号：16655700207	邮箱：16655700207@163.com

求职意向

工作性质：全职	期望岗位：AI 应用开发工程师	期望薪资：面议
到岗时间：随时到岗	目前状态：已离职	

专业技能

- 熟练使用 **Python** 后端开发：使用 **httpx** 异步请求、**OmegaConf/Settings** 配置管理，能够独立搭建并部署 **Agent / RAG** 后端服务。
- 掌握 **FastAPI** 异步 Web 服务开发，熟悉 **Lifespan** 生命周期、**Dependency** 依赖注入、**Middleware** 中间件、异常处理及 **SSE** 流式输出等机制，具备 **API** 服务工程化开发能力
- 熟练使用 **RAG** 检索增强生成：具备文档解析、切片、向量化入库、混合检索、重排序与无答案拒答等完整链路设计经验，并熟练使用 **RAGAS** 评估框架对 **RAG** 项目进行量化评估与迭代优化。
- 熟练使用 **LangChain / LangGraph** 工作流编排：能够基于 **StateGraph** 构建多节点工作流，实现条件路由、并行执行、**SSE** 流式推送与任务恢复链路。
- 熟练使用主流大模型调用与 **Prompt** 工程：调用 **Qwen**、**DeepSeek**、**GLM**、**GPT** 等模型 **API** 并完成适配，掌握 **Prompt** 设计、**Few-shot** 示例、**CoT** 推理引导、**JSON Schema** 结构化输出约束与多轮上下文管理。
- 熟练使用存储与检索组件：**MySQL**、**MongoDB**、**MinIO**、**Elasticsearch**、**Milvus**、**Qdrant** 等，具备数据建模、全文检索、向量检索与索引构建实践经验。
- 具备 **MinerU** 文档解析及知识库数据加工经验，能够处理 **PDF**、**Markdown** 等多格式文档，完成文档解析、章节切分、长文本递归拆分、短文本合并、表格/图片内容提取及元数据构建
- 熟练使用 **Coze / Dify** 低代码平台：能够基于 **Coze**、**Dify** 快速搭建合同校验、报告校验、审批提醒等 **AI** 智能体，并完成知识库维护、**API** 集成与效果持续迭代。

9. 熟练运用 **vibe coding** 开发模式：日常使用 **Claude Code**、**Codex** 等 AI 编程工具进行开发，掌握任务拆解、上下文管理、规范约束与多轮迭代引导的 AI 辅助开发 workflow，显著提升编码与重构效率。
10. 了解知识图谱与大模型周边工具：接触过 **neo4j** 图数据库与 **graphRAG**，能够使用 **jieba** 分词、**Jinja2** 模板引擎进行文本处理与提示词构建。
11. 了解 **Java** 微服务开发：使用过 **Spring Boot**、**Spring Cloud Alibaba**、**Nacos**、**OpenFeign**、**MyBatis-Plus**、**Seata** 等技术，对 **Redis** 缓存治理、**RabbitMQ** 异步解耦与分布式事务一致性有实践认知。

工作经历

2023.07 —— 2026.09 上海德曜数字科技有限公司 AI 应用开发工程师

项目经历

项目一：德曜问数

技术栈：FastAPI + LangChain + LangGraph + Qwen2.5-MAX + GLM-4 + GPT-4.1 + Jieba + Qdrant + BGE-large-zh-v1.5 + Elasticsearch + MySQL + SQLAlchemy + OmegaConf

项目介绍：基于大模型的 **Text2SQL** 智能数据分析系统，面向企业客户与业务运营人员，通过自然语言提问即可自动生成 **SQL** 并执行查询、返回数据洞察，无需掌握 **SQL** 即可快速获取经营数据。

个人职责：

- 主导 **LangGraph** 工作流设计，构建多节点的 **SQL** 生成状态图：以 **State** 共享全流程数据上下文，覆盖关键词抽取、三路召回、信息合并、表/指标过滤、**SQL** 生成/校验/校正/执行全流程。
- 设计元数据知识库与三路召回合并方案：字段与指标走 **Qdrant** 向量语义检索、字段取值走 **Elasticsearch** 全文检索；合并节点以 `column_id` 统一关联三类召回结果，按 `table_id` 分组补全主外键关系，只给模型当前问题真正需要的表结构与指标信息。
- 设计 **SQL 三层校验防线**：语法层经 **EXPLAIN** 校验可执行性；权限层在生成 **SQL** 前将登录用户与数据表传入**权限审查接口**，获取表级权限标志与行级过滤条件杜绝越权；业务层由 **LLM** 反思比对。
- 设计**成本可控**的生成策略：默认单模型生成 + 自校验，失败自动纠错，连续两次失败才升级为三模型并行生成投票兜底；采用 **jieba 分词** + **LLM 语义扩展**的双重关键词抽取，保证召回元数据的准确性。
- 实现生成失败纠错与**防死循环**：按错误类型区分**重试策略**、设置**最大重试次数**，连续多次修复失败即中断**澄清或转人工**；配合超时重试、备用模型切换、熔断器与按节点降级的多级兜底，避免链路雪崩。

项目成果：

- 500 条评测问句上字段级召回率从 **72% 提升至 94%**。
- SQL** 常见查询准确率 **95%以上**,复杂多表关联查询 **90%以上**。
- 平均查询响应控制在 **500ms 以内**、端到端平均单次查询约 **3s**。

项目二：德曜答疑

技术栈：FastAPI + LangGraph + LangChain + 通义千问 Qwen-Flash / Qwen3-VL-Flash + BGE-M3 + Milvus + Qwen3-Reranker + MongoDB + MinIO + MinerU

项目介绍：面向企业客户及其合作伙伴的 **RAG** 知识库问答系统，覆盖商品、订单、售后、平台规则全链路知识，支撑 2000+ 文档、20 万向量块的多人实时高精度查询。

个人职责：

1. 主导 **LangGraph** 工作流设计，构建文档导入与文档检索各 7 节点的状态图，实现条件路由、与 **SSE** 流式推送。
2. 设计并实现多路检索：**向量检索**、**HyDE 假设文档检索**与**网络搜索**三路并行，通过 **RRF** 倒数排名融合 + **Rerank** 重排序合并结果，对 **Rerank** 得分过低的上下文直接淘汰、全部淘汰则拒答，从检索端抑制幻觉。
3. 采用 **BGE-M3** 混合向量（稠密 1024 维 + 稀疏），**稠密向量**负责语义相似、**稀疏向量**负责精确匹配，解决纯语义检索对专有名词匹配不足的问题。
4. 开发主体名确认机制：**LLM** 提取 + 向量对齐 + 两级过滤 + 延迟回填；设计文档切分策略，按标题边界初切保留语义完整性，再对过长/过短文档精切合并，实现**断崖检测**截断算法动态过滤低质文档。
5. 对接 **MinerU** 解析服务，实现 PDF/Word 文档异步上传、轮询解析与 Markdown 提取全流程，配合滑动窗口限流器控制 LLM 调用速率。

项目成果：

1. 支持 PDF、Markdown 等多格式文档导入，**LangGraph 条件边**根据文件类型自动分发至对应解析节点，把一个普通的文档问答系统做成了比较完整的工程化 **RAG** 系统。
2. 降低文本碎片化：基于 Markdown **标题粗切**，超长章节按段落、句子、标点**递归**二次切分，过短章节按同父标题合并，chunk 长度集中在 600~1500 字，碎片化率控制在 **10%以内**。

项目三：德曜客服

技术栈：FastAPI + LangChain + qwen-plus + SQLAlchemy + aiomysql + httpx + Jinja2 + YAML + Python

项目介绍：面向企业客户及其终端用户的 **AI** 智能客服，支持订单查询、物流追踪、退款申请等固定任务流程，融合高精度 **RAG** 知识问答与闲聊交互，辅以缺参澄清优化体验，四轨道统一调度。

个人职责：

1. 负责**引擎层**架构设计：实现会话生命周期管理与任务、知识、闲聊、澄清四轨道统一调度；DialogueState 拆分 active_task / paused_tasks / active_system_task，用户插话时原任务**压入暂停栈**，支持恢复被打断的业务流程，避免多轮任务互相覆盖。
2. 设计计划层：以 **Jinja2** + PromptTemplate 构建提示词链，注入会话历史、任务列表等 7 类上下文，用 JsonOutputParser 约束 LLM 输出结构化 TurnPlan；TurnPlanValidator 校验 flow 存在性、多任务冲突与槽位完整性，失败进入澄清或拒答，防止 LLM 幻觉出不存在的流程与工具。

3. 开发固定任务轨道全链路：状态修改 → workflow 推进 → 动作执行，覆盖订单查询、物流追踪、退款申请等业务流程；设计双循环引擎，外层捕获、内层推进。

项目成果：

1. 建成一套可复用的电商智能客服多智能体框架，覆盖订单查询、物流跟踪、退款申请、商品/订单/政策咨询等核心场景，业务扩展由改代码转为改 YAML 配置。
2. 项目中支持**多条任务轨道**可以进行“查看是否有物流信息，没有则退款”多轨道操作。
3. 对话状态落库实现**断点续聊**与多任务切换，用户中途打断/切换咨询不丢上下文，提升了客户满意度、一次解决率。

项目四：德曜智检

技术栈：Coze（扣子） + Dify + Qwen 系列大模型 + OCR + 企业微信 API + 邮件服务 + 向量知识库 + MySQL

项目介绍：基于 Coze（扣子）与 Dify 低代码平台搭建的企业 AI 智能审核应用体系，覆盖合同校验、实施交付文档校验与合同审批提醒三大智能体场景，将人工审核流程升级为 AI 辅助处理，大幅降低重复性审查工作量。

个人职责：

1. 基于 Coze（扣子）与 Dify 低代码平台搭建合同校验、实施交付文档校验与合同审批提醒三大智能体应用，完成工作流节点编排、知识库配置与模型参数调优，将人工审核流程升级为 AI 辅助处理。
2. 设计合同校验智能体：通过 LLM 自动抽取合同关键要素（甲乙方、金额、期限、签章等），结合知识库规则比对条款完整性与风险点，实现合同入库前自动校验与风险预警。
3. 开发实施交付文档校验工作流：通过 OCR + LLM 提取实施方案与验收报告中的项目信息、交付项、验收结论与签字签章要素，自动核验数据一致性与必填项完整性，异常文档自动标记退回人工复核。
4. 搭建合同审批提醒智能体：对接企业微信与邮件消息通道，按审批节点自动催办，临期/到期合同自动预警，杜绝超期遗漏；并负责智能体与业务系统的 API 集成、知识库维护与效果迭代。

项目成果：

1. 三大智能体覆盖合同校验、实施交付文档校验、审批提醒全流程，合同入库前自动校验覆盖率 **100%**，临期/到期合同预警覆盖率 **100%**，杜绝超期遗漏。
2. 参照 Coze 分层架构（前端交互层 / 业务逻辑层 / 工具与数据层）组织工作流、知识库与插件，模块高内聚低耦合，知识库与提示词持续迭代，人工重复审查工作量大幅降低。
3. 合同关键信息（甲乙方、金额、期限、签章等）抽取准确率达 **95% 以上**；单份合同审核平均耗时由人工 30 分钟/份缩短至 2 分钟/份以内，重复审查工时减少约 2/3，错误漏审率显著下降。

项目五：德曜审约

技术栈：Python + Flask + MySQL 8.0（PyMySQL） + SQLite + python-docx + pypdf + Pillow + Tesseract OCR + DeepSeek + pytest + Gunicorn + Nginx + HTML / CSS / JavaScript

项目介绍：面向企业合同审批场景的自动审查系统，覆盖审批待办拉取、附件下载与校验、合同多格式解析与扫描件 **OCR**、11 类风险规则审查、审查意见回写审批评论区的完整闭环；内置用户注册与角色权限体系，按公司隔离数据，辅助法务审核而不替代人工决策。

个人职责：

1. 主导全链路 workflow 设计，实现 pending → parsing → reviewing → blocked / done 五态状态机，人工重试支持从解析或审查阶段**断点恢复**，异常不静默丢失。
2. 设计多格式合同解析器：TXT / Markdown / CSV 多编码兼容、DOCX 段落与表格提取、PDF 逐页解析注入页码标记、扫描件走 **OCR**；支持法务逐条复核。
3. 实现 11 类确定性风险规则引擎：正则匹配预付款比例、付款周期、自动续约等风险点，命中即输出证据原文摘录、位置与修改建议，规则以数据库配置，管理界面支持增删启停。
4. 设计规则引擎 + LLM 双轨审查：接入 **DeepSeek** 生成补充摘要与关注点，提示词约束不得改变规则引擎风险等级；构建用户注册与角色权限体系，支持个人用户与公司管理员。

项目成果：

1. **pytest** 集成测试全部通过，覆盖字段提取、规则命中、幂等去重、完整处理闭环、扫描件解析、异常阻塞、回写失败、身份认证与 **REST API** 等场景。
2. 内置 11 类风险审查规则（数据库配置、管理界面可增删启停）与 4 个内置审批示例（高风险 / 低风险 / 扫描件 / 附件缺失），示例全部按预期命中或进入 blocked 状态。
3. 以 7 个标准工具函数封装全流程能力，支持 Agent 与脚本直接调用；实现用户注册与角色权限体系并按公司隔离数据；**DeepSeek** 复核失败时自动降级为规则引擎单轨输出，审批闭环不中断。

个人评价

1. 性格随和、思维敏捷，能快速融入团队并与产品、前端高效协作，沟通表达清晰，善于倾听需求。
2. 热爱编程与 AI 技术，对新技术保持高度好奇心，学习能力强，具备持续学习和独立探索的动力。
3. 工作尽职尽责，实习期间独立负责多个模块从需求到交付，按时保质完成，不回避复杂技术难点。
4. 具备较强的责任心与抗压能力，能快速适应项目节奏，在面对压力时保持稳定高效的产出。