

李美楠_AI 大模型开发工程师_3 年

基本信息

姓名：李美楠	年龄：24	性别：女
籍贯：河北	学历：本科	专业：信息工程
联系电话：15075247372	邮箱：15075247372@163.com	

求职意向

工作性质：全职	期望城市：不限
期望薪资：面议	期望职位：AI 大模型开发工程师
到岗时间：已离职，随时到岗	

专业技能

- 熟练掌握 RAG 检索增强生成流程及应用开发方法，熟悉文档解析、分块切分、Embedding 向量化、多路召回、融合重排、答案生成、来源追溯和效果评测等关键环节。
- 熟练掌握高级 RAG 优化方法与检索前后处理策略，掌握多路召回，HyDE、RRF 融合、Rerank 重排序、bad case 回归优化等方法，并能使用 RAGAS 框架评估检索与生成质量，持续优化效果。
- 熟练掌握 LangChain 大模型应用开发框架，熟悉 Models、Prompts、Output Parsers 等核心组件，能够基于 LangChain 实现链路封装、上下文组装、问答生成、对话系统开发。
- 熟悉使用 LangGraph 构建图结构工作流与复杂 Agent 系统，熟悉 StateGraph、节点/边、Checkpoint、状态定义、状态流转、条件路由、多步骤任务编排与 Plan-and-Execute 等核心机制。
- 熟练使用 Coze、Dify 等智能体平台，快速搭建工作流、Agent、知识库与工具调用链路，并结合 Prompt 工程、API 调用，实现高效率的智能体应用交付。
- 熟悉掌握 PEFT、LoRA、QLoRA 等高效微调方法，并熟悉基于 LLaMA-Factory、Accelerate 等工具链开展模型微调，能够完成行业领域适配数据集构建、训练参数设置、模型微调、离线评测。
- 熟练掌握 Transformer 架构及大模型核心原理，熟悉 Attention、Embedding、位置编码、前馈网络、归一化等关键模块，深入理解 BERT、T5、Qwen 等主流预训练模型的结构特点与应用场景。
- 熟悉深度学习基础原理与神经网络训练流程，理解神经网络结构、反向传播机制、权重初始化、激活函数选择等核心概念，能够使用 PyTorch 完成神经网络模型搭建、训练、验证与调试，并熟悉 Dropout、残差连接、Adam、AdamW 等常见优化技巧与训练稳定性处理方法。
- 熟悉大模型中的关键结构设计与训练优化机制，包括 LayerNorm、RMSNorm 等归一化方式，GELU、SwiGLU 等激活函数，RoPE 位置编码，以及 MHA、MQA、GQA 等注意力机制。
- 熟练掌握 Python 编程语言与工程化开发能力，熟练使用 NumPy、Pandas、Scikit-learn 等常用数据处理与科学计算工具，能够完成结构化数据清洗、转换、缺失值处理、特征整理、数组与矩阵运算等工作。
- 熟悉 Linux 常用系统操作与 AI 应用基础工程组件，能够使用 FastAPI、SQLAlchemy、MySQL、MongoDB、MinIO、Docker、Git 等技术完成 AI 服务开发、数据管理、接口联调、环境部署。

12. 深入理解大模型本地与云端部署能力，熟悉在 Docker 环境以及腾讯云、AutoDL 等平台上 Dify 私有化部署，并能够完成 DeepSeek、Qwen、GPT 类模型的部署、联调与基础服务搭建。
13. 熟悉前沿智能体工程形态与应用趋势，理解 Claude Code 等系统在任务拆解等方面的核心设计思路。

工作经历

2023.07 - 2026.07

北京中发飞询网络科技有限公司

AI 大模型开发工程师

项目经历

项目一 | 项目名称：小警行业监测与风险预警平台

项目背景：面向元器件交易网内部运营、市场和管理团队，建设小警监测与预警平台，用于跟踪行业热点、品牌口碑、竞品动态、突发事件和风险信息，辅助内部进行行业研究与风险预警。项目主要解决人工收集信息分散、跨平台信息整合效率低、热点事件分析周期长、缺乏统一研判视角等问题。系统通过“多模块并行分析 + 讨论协调 + 报告生成”的方式，围绕五维分析框架输出结构化分析报告，支撑管理层和业务团队进行品牌监控、热点研判与风险决策。

技术选型：FastAPI + LangGraph + LangChain + LLM + MySQL + Milvus + SSE

个人职责：

- 负责多 Agent 舆情系统的后端编排层设计与实现，构建“任务接入—并行分析—讨论协调—报告生成”的统一任务主链路。
- 负责私域舆情与公域媒体两个分析模块的接入与启动流程，统一封装各角色模型配置、搜索工具、向量检索、输出目录和进度回调接口，支持模块独立配置与并行调度。
- 负责事件通信层设计与实现，基于进程内发布订阅机制构建事件总线，定义角色进度、章节就绪、研判消息、角色异常等多类事件类型，支持模块间解耦通信与安全分发。
- 负责实时推送链路开发，基于 SSE 实现事件流从事件总线到前端的实时转发，为每个客户端维护独立异步队列，支持角色进度、结果与异常事件的即时推送。
- 负责讨论协调模块接入，订阅私域舆情与公域媒体两个分析模块的章节就绪事件，同维度双源齐备后触发主持人模型进行配对研判与冲突检测，并将历史研判结论作为上下文传递给后续研判过程。
- 负责报告生成模块接入与交付联调，整合主持人研判报告、私域舆情报告与公域媒体报告，调用报告引擎 LLM 围绕主持人裁判主线输出结构化舆情分析报告。

项目成果：

- 完成面向平台内部行业研究与风险预警的多 Agent 舆情系统落地，围绕私域舆情检索、公域媒体检索、主持研判、报告引擎四个角色构建统一分析入口，支撑热点、品牌、竞品和风险事件的交叉研判。
- 基于五维分析框架，实现同维度私域与公域双源章节就绪后自动触发主持人配对研判，形成“分源分析—配对研判—最终裁判”的研判闭环，增强多来源信息综合分析的一致性。
- 系统最终可自动输出包含执行摘要、五维综合研判、核心共识与关键分歧、证据可信度评估、风险与后续建议的结构化报告，并支持网页预览和 Markdown/HTML 双格式导出，明显提升内部研究交付效率。

项目二 | 项目名称：小元交易助手

项目背景：面向元器件交易网的客服与交易服务场景，构建小元交易助手，承接订单查询、物流查询、商品咨询、售后规则问答、退款申请、转人工等高频业务。通过“大模型理解用户意图 + workflows 执行确定性业务 +

RAG 支撑知识问答”的方式，提升平台 7×24 小时服务能力，降低人工客服压力，同时通过规则校验和接口鉴权保障高风险操作的可控性，减少交易纠纷与服务响应延迟。

技术选型：FastAPI + YAML + Qwen-Plus + MySQL + LangChain + httpx+ Milvus + MinIO + RAG

个人职责：

1. 负责小元交易助手主链路设计与后端实现，搭建“意图识别—结果校验—流程执行—响应生成”的统一处理流程，支持任务型对话、知识型问答和人工兜底三类场景。
2. 负责多轮对话状态管理机制设计，基于对话状态聚合根维护当前任务上下文、挂起任务栈、会话历史、槽位信息与聚焦对象，配合 5 类系统流程实现复杂多任务场景下的任务承接与上下文恢复。
3. 负责订单查询、物流查询、退款申请、商品咨询、转人工等 6 类核心流程的 YAML 工作流编排，对接订单、物流、商品等业务接口、实现参数校验、接口调用和异常兜底。
4. 负责知识问答链路设计，构建可扩展的知识提供者架构，实现商品信息、订单与物流信息的实时 API 查询能力，FAQ 知识库和 RAG 检索落地，支撑商品咨询与信息类问答场景。
5. 负责 LLM 输出结果的校验层设计，实现 TurnPlan 的四重内层校验和知识轨道的意图-对象匹配校验，确保大模型只负责意图识别与信息提取，具体业务执行由确定性工作流引擎接管。
6. 负责对话状态持久化与执行链路追踪设计，通过 MySQL 全量存储对话状态结合流程推进器的确定性步骤推进机制，支持会话恢复、执行路径复盘和 bad case 回溯分析。

项目成果：

1. 完成小元交易助手核心系统落地，覆盖 6 类高频客服场景、40+ 个 YAML 流程节点、8 个槽位定义、5 个 Action 节点，形成基于 YAML 声明式配置的可复用客服流程编排能力。
2. 设计并实现 5 类系统流程的自动化编排与自然语言反馈生成，配合挂起任务栈实现多任务间的无缝切换与上下文恢复，保障复杂客服对话场景下的交互连贯性。
3. 通过“LLM 意图路由 + YAML 工作流引擎 + 可扩展知识提供者”的分层混合架构，实现灵活语义理解与确定性业务执行的解耦，新增业务场景仅需添加 YAML 配置与对应 Action，无需改动核心引擎代码。
4. 建立基于对话状态全量持久化的对话观测与复盘机制，完整记录每轮 Turn 的意图路由结果、流程执行路径、槽位变化和 Action 调用结果，支持会话恢复与问题回溯。

项目三 | 项目名称：小智企业产品知识助手

项目背景：面向元器件交易网内部客服和运营团队，建设小智企业产品知识助手，用于统一管理产品手册、规格说明、故障排查文档，解决文档数量多、格式复杂、人工查找效率低、业务答复不稳定等问题。系统通过文档自动解析、结构化切片、多路检索与智能问答能力，让业务人员能够通过自然语言快速获取产品参数、操作说明、故障处理建议和规则依据，提升售前支持效率与内部知识复用能力。

技术选型：FastAPI + LangGraph+ MinerU + Milvus + BGE-M3 + BGE-Reranker-Large + MongoDB + MinIO + RAGAS + SSE + Qwen-Flash

个人职责：

1. 负责小智知识助手整体链路设计与后端实现，基于 LangGraph 搭建“文档导入解析—切片向量化—混合检索—重排生成”的 RAG 全链路，通过 FastAPI 提供导入与问答双服务，支撑内部业务人员自然语言问答。
2. 负责 PDF/Word/Markdown 文档导入与结构化处理能力建设，基于 MinerU 完成复杂 PDF 转 Markdown，调用视觉模型对文档中图片进行语义描述并上传 MinIO 托管。
3. 负责图片语义增强方案设计，基于视觉语言模型对文档中的示意图、操作面板图、故障图示等图片内容进行语义描述生成，将图片描述文本融入 Markdown 文档中参与后续切片与检索。
4. 负责多路召回与重排优化，设计“商品名称确认→稠密+稀疏混合向量检索→HyDE 假设文档检索→RRF 加权融合→BGE-Reranker 精排”的检索链路，提升知识问答的召回完整性与回答准确性。

- 负责切片策略与检索参数调优，采用两级切片方案控制 chunk 粒度与 overlap，引入动态 TopK 断崖检测自适应调整召回数量，并通过商品名称向量匹配的分值阈值引导用户明确查询意图。
- 负责评测体系、观测与稳定性建设，基于 RAGAS 建立 context_recall、context_precision、answer_correctness 等指标评估体系，并结合 SSE 流式推送实现任务进度实时观测。

项目成果：

- 系统设计支持 3000~6000 份产品手册/说明书文档的导入与管理，覆盖 PDF、Word、Markdown 等主流文档格式，支撑客服、运营的日常资料检索需求。
- 基于"商品确认 + 稠密稀疏混合向量检索 + HyDE + RRF + Rerank"的多路召回链路优化后，结合动态 TopK 与断崖检测策略，测试集召回率达到 93%，真实线上问题召回率 85%。
- 完成复杂 PDF 与图片内容的结构化处理，基于 VLM 视觉模型对图片内容生成语义描述并融入文档正文，使原本不可检索的图片信息能够参与向量检索与问答，增强了复杂工业文档场景下的知识覆盖能力。
- 实现 embedding、rerank 与 API 服务解耦，提升了知识服务的稳定性和后续扩容能力。

项目四 | 项目名称：小智知识助手领域微调项目

项目背景：面向小智企业产品知识助手在真实业务中的问答优化需求，围绕电子元器件产品手册、规格说明、故障排查和平台规则等话题，问答中存在的术语理解不足、商品名称识别不稳、引用原文不规范、回答风格不一以及多轮追问承接不稳定等问题。通过构建小智知识助手问答场景微调数据集、规范训练输出协议、建立离线评测与回放验证流程，提升模型在内部知识问答场景下的指令遵循能力、结构化输出稳定性和答案一致性。

技术选型：Qwen3-8B-Instruct + QLoRA + LLaMA-Factory + vLLM + PEFT + Docker + Docker Compose + JSONL + Jinja2 + DPO

个人职责：

- 负责知识助手问答场景微调方案设计，围绕主 RAG 链路中商品确认、问题改写、HyDE 假设文档生成和最终答案生成四个 LLM 调用节点，明确各任务的结构化输出协议与指令遵循规范，并针对答案风格对齐引入 DPO 偏好优化阶段。
- 负责微调数据集建设，基于产品手册原始文档片段、答案质量不佳的 bad case 回流数据，以及业务高频问题模板，覆盖商品确认、术语标准化、知识问答、追问承接、拒答兜底等场景，确保各任务桶样本量均衡，并补充偏好对比样本用于后续 DPO 阶段。
- 负责标注规范、数据协议与数据清洗脚本建设，基于 Jinja2 模板定义各任务类型的训练输入输出格式，统一引用规则和回答风格，并编写清洗脚本清理重复样本、脏样本、空引用样本和伪上下文样本。
- 参与训练方案选型与实验执行，采用 QLoRA 4-bit 量化 + LLaMA-Factory 框架进行 Qwen3-8B-Instruct 指令微调，基于 Docker Compose 管理训练环境，训练日志与 checkpoint。
- 负责离线评测与回放验证体系建设，构建固定评测集与回放测试集，从 RAGAS 五个维度设计评测指标。
- 负责微调模型接入知识助手链路联调，通过 vLLM 部署微调后的 Qwen3-8B-Instruct 模型实例，替换主 RAG 链路中原有的通用 API 调用，实现微调模型与原有检索链路的协同优化。

项目成果：

- 完成知识助手场景专用微调数据集建设，覆盖产品参数、故障排查、来源引用、多轮追问等核心问答类型，累计构建 5000+ 条高质量训练样本，提升了模型对电子元器件术语和产品文档表达的领域适配能力。
- 相比未微调基座模型，微调后模型在知识助手核心测试集上的回答模板遵循率提升至 86%，经 DPO 对齐后，拒答误触发率进一步下降，在商品确认、术语标准化和来源引用规范率等细分指标上表现更稳定。
- 打通"样本数据—LLaMA-Factory 训练实验—离线评测—vLLM 容器化部署"的完整闭环，基于 Docker Compose 实现训练与推理环境的一键启停和配置管理。

项目五 | 项目名称：小数企业经营数据智能问数平台

项目背景：面向元器件交易网的运营和经营分析团队，建设小数企业经营数据平台，主要解决数仓表结构复杂、业务口径分散、分析需求高度依赖数据开发、响应周期长等问题。系统通过“问题理解 + 元数据召回 + SQL 生成 + SQL 校验 + 查询执行”的链路，将自然语言问题转化为可执行 SQL，并结合权限控制和错误修复机制，提升业务自助分析效率与数据使用门槛。

技术选型：FastAPI + LangChain + LangGraph + DeepSeek + Qdrant + Elasticsearch + MySQL + jieba + BGE-large-zh-v1.5 + EXPLAIN

个人职责：

- 1. 负责问数主链路设计与实现，基于 LangGraph 搭建关键词提取 → 检索过滤 → 上下文组装 → SQL 生成 → EXPLAIN 校验 → 查询执行的 Text2SQL 流程，将节点运行进度和查询结果实时返回前端。
- 2. 负责元数据知识库建设，基于 MySQL 维护表、字段、指标、字段-指标关系等元数据表，将字段名称、描述、别名的语义向量化存入 Qdrant，将字段枚举值同步到 Elasticsearch (IK 分词器)。
- 3. 负责关键词提取与召回优化，引入 jieba TF-IDF 关键词提取与词性过滤，对 Qdrant 向量检索结果和 ES 全文检索结果进行合并去重，并通过 LLM 二次过滤实现精筛，控制上下文冗余。
- 4. 负责 SQL 生成、EXPLAIN 校验与自动修复链路设计，在数仓侧执行 EXPLAIN 校验，针对语法错误、字段不存在等场景，利用 LangGraph 条件路由将错误信息回传 LLM 进行最小化修正后重新执行。
- 5. 负责上下文质量控制策略设计，在信息合并节点自动补齐候选表的主外键字段，通过 LLM 过滤节点去除与问题无关的表和字段以控制 Token 消耗。
- 6. 负责提示词工程与链路效果调优，针对关键词扩展、指标过滤、SQL 生成等 7 个环节分别设计专用提示词模板，围绕召回字段冗余、SQL 生成偏差、业务口径不一致等问题持续迭代提示词策略与元数据配置。

项目成果：

- 1. 完成自动化问数系统落地，打通自然语言到 SQL 的完整链路，覆盖订单、商家、品类、指标等常见经营分析场景，以流式进度推送和结果返回方式显著提升交互体验，降低使用数据的门槛。
- 2. 通过构建三路并行召回机制，配合 LLM 二次过滤与主外键自动补齐策略，在保障上下文完整性的同时控制冗余信息，常见单表经营查询 SQL 准确率达到 92%，复杂多表关联查询准确率达到 86%。
- 3. 面向数十张表、百万级数据量的数仓主题域，系统能够稳定支撑日常经营分析和业务自助查询需求，并有效减少表选错、字段选错、字段值拼错等常见问题。
- 4. 建立 EXPLAIN 校验与 LLM 自动修复闭环后，系统在执行前即可拦截大部分语法错误与字段错误，结合提示词约束保障只读安全，增强了问数链路的可控性和可靠性。

自我评价

- 1. 性格随和、善于沟通，工作认真负责，学习新技术能力强，丰富经验。
- 2. 有毅力，爱攻坚，曾坚持每天跑步 5 公里，半年成功减肥 20 斤。