

AI 大模型应用开发工程师三年

基本信息

姓名：林理想 性别：男
年龄：23 岁 籍贯：河南省
毕业院校：南阳理工学院 专业：软件工程
电话：19247152412 邮箱：18836768035@163.com

岗位职责

求职岗位 AI 大模型应用开发工程师 工作时间 2 年
到岗时间 随时到岗 期望薪资 面议

工作经历

2024 年 7 月—2026 年 7 月 也买（上海）商贸有限公司 研发部 | AI 大模型应用开发工程师

- 实现基于 LangGraph/LangChain + FastAPI 构建企业级 Agent 应用，沉淀 YAML 配置化 workflow、状态持久化/中断恢复、SSE 流式输出及 Docker 部署能力；覆盖客服 20+ 场景，咨询自动处理率提升约 70%。
- 构建 MinerU + VLM + BGE-M3 + Milvus 多模态 RAG 全链路，融合 HyDE、MCP 联网检索、RRF 与 Reranker 精排；平均候选数减少约 30%，LLM 输入 Token 降低约 10%。
- 深度参与 NL2SQL 平台建设，设计多路召回，基于 LangGraph 实现 SQL 生成、EXPLAIN 校验与 LLM 自修复；
- 设计 HostAgent + 子 Agent 舆情研判架构，通过事件总线实现私域/公域并行检索、证据对齐、冲突检测与 LLM 裁判，支持多模型热加载；自动生成“5 维度×2 视角”报告。

擅长技能

- 熟练使用 LangChain、LangGraph 开发 RAG、工具调用及多阶段问答应用，掌握分支循环、中断恢复、状态持久化、断点续传和死循环防护。
- 熟悉 Agent 分层记忆体系，能够通过摘要压缩，关键信息提取解决上下文超限，长对话信息遗忘问题。
- 具备 FastAPI 与 LangGraph 异步服务落地经验，能够根据业务场景设计静态 YAML 流程和动态状态 workflow，开发复杂自主决策智能体。
- 熟悉 Agent 记忆设计，多智能体常见框架，MCP，Skill，Harness 工程，Loop Engineering 工程。
- 设计断崖算法降噪，RAG 自定义分层分块，滑动窗口限流，多模态处理，RAGAS 量化评测。
- 熟悉智能体核心架构及任务编排模式，能够完成任务拆解、工具调度、状态管理、结果校验和业务流程闭环。
- 熟练掌握文档解析、数据清洗、Chunk 切分、Embedding、索引构建、检索召回、结果重排及答案生成等 RAG 全链路技术，具备企业私有知识库建设经验。
- 掌握 BM25 与向量混合检索、问题拆分、HyDE、多路召回、RRF 融合及 Rerank 精排等检索优化方法。
- 熟练使用 MinerU 完成 PDF 文档结构化解析及自定义 Chunk 切分，熟悉 Milvus、Qdrant 的基础使用，能够完成 Collection 设计、TopK 检索等常见能力实现。
- 掌握 Prompt 模板化、配置化及热更新机制，能够通过指令约束、结构化输出、结果校验、自动重试和降级策略治理模型幻觉、重复输出及格式异常。
- 掌握 Function Calling 与 MCP 协议，能够将 HTTP 业务接口封装为标准化 AI 工具，实现大模型与企业业务系统的数据及能力集成。
- 熟练使用 Dify、Coze 搭建 Workflow、Agent 和 RAG 应用；熟悉 Claude Code、Codex 等 Vibe Coding 工具。

项目经历

项目一：也买酒智库——企业级酒类多模态 RAG 知识平台

项目背景

针对企业大量文档检索不准，格式复杂，多模态内容丢失等痛点，通过 Langgraph 框架构建也买酒企业级 RAG 知识库平台。平台以多模态 RAG 为核心，打通文档上传、解析入库、混合检索、重排序和流式问答链路，实现企业知识“上传即检索”；同时通过级联检索优化兼顾回答质量与 Token 成本。

技术栈

Python、LangGraph、LangChain、FastAPI、Milvus、MongoDB、MinIO、BGE-M3、Docker、BGE-Reranker-Large、MinerU、MCP

核心功能

导入侧：

- 1.知识入库流水线：基于 LangGraph 编排 Ingestion Pipeline，完成文档上传、MinerU 解析、Markdown 转换、Chunk 切分、实体抽取、向量化及 Milvus 入库。
- 2.多模态内容解析：使用 VLM 对酒标、产品图片及文档插图生成 Caption，并建立图文关联，使图片信息可以参与召回和答案生成。
- 3.设计多级存储架构：MinIO 对象存储管理原始文档、Milvus 管理向量索引、MongoDB 管理任务状态和历史对话，各存储组件职责清晰解耦。

检索侧：

- 1.三级置信度设计：专有名称反问消歧，会话记忆结合关键词对齐 Query 改写
- 2.设计多路召回+级联融合策略：原始查询混合向量检索 + HyDE 假设性文档增强检索 + MCP 联网搜索三路并行，配合 RRF（倒数排名融合）算法对多路结果进行合并，弥补单一检索方式的覆盖盲区。
- 3.精排与上下文控制：通过 BGE-Reranker-Large 对候选文档进行 Cross-Encoder 精排，并根据相邻分数的 Score Gap 动态截断低相关结果，有效降低 token 消耗。

项目亮点

- 1.多模态 Ingestion Pipeline：将 MinerU 文档解析、VLM 图片理解、Chunking、实体抽取和双路向量化拆分为独立节点，通过 LangGraph 统一管理节点状态及异常重试。
- 2.自定义断崖检测：进行统一归一化之后进行动态截断取崖 TopK
- 3.三级置信度设计：用户问题置信度判断，智能分流

项目效果

- 1.文档处理由人工解析、切片和录入调整为自动化 Pipeline，实现酒类资料“上传即入库、入库即可检索”，降低知识维护和更新成本。
- 2.三路召回：RAGAS 评估精准率从 70%提升到 82%
- 3.通过 RRF 融合+断崖截断策略，有效过滤低相关候选，减少噪音，平均召回候选数减少约 40%，在保证召回质量的同时降低 LLM 输入 Token 消耗约 20%,RAGAS 评估准确率从 82%提升到 92%。

项目二：也买酒智能客服 Agent 平台

项目背景

基于也买酒电商业务建设 AI 智能客服平台，解决重复咨询量大、订单与物流数据分散、多轮业务办理依赖人工客服等问题。项目采用 Agent + RAG + Workflow 架构，将知识问答、实时业务查询和多步骤任务办理统一编排，自定义三轨道覆盖智能选酒、订单查询、物流追踪及退款申请等场景，实现意图识别、多轮对话、任务编排及智能问答一体化，显著降低人工客服压力与运营成本。

技术栈

Python、FastAPI、LangGraph、LangChain、MySQL、OpenAI API / Qwen、Docker、YAML Workflow、Qdrant、Elasticsearch、Jinja2

核心功能

- 1.意图识别与任务路由：基于 LangGraph 构建 Agent 状态图，对用户问题进行意图分类，并路由至知识问答、商品推荐、订单查询、物流追踪或退款处理流程。
- 2.配置化工作流引擎：设计 YAML Workflow，通过节点、条件分支和上下文变量描述业务流程，支持自定义工作流的导入，同时降低新增场景对核心代码的侵入。
- 3.业务工具调用：将订单、物流、退款及商品服务封装为标准化 Tool，使用 httpx 异步调用内部 API，完成实时数据查询和业务状态同步。
- 4.客服知识检索：使用 Qdrant 进行语义向量检索，结合 Elasticsearch 全文检索，为酒款信息、品牌产区、饮用建议及售后政策提供 Hybrid Search。
- 5.多轮任务状态管理：通过槽位填充逐步收集订单号、退款原因、商品信息等必要参数，并将会话上下文和任务状态持久化至 MySQL。
- 6.任务恢复与异常处理：支持业务流程中断恢复、接口异常兜底及对话上下文续接，避免用户在复杂业务办理过程中重复提供信息。

项目亮点

- 1.覆盖智能选酒、订单管理、物流追踪、退款处理、会员权益及常见问答等 20+ 高频业务场景。
- 2.常见咨询自动处理率提升约 70%，用户平均等待时间缩短约 50%。
- 3.YAML 配置化工作流支持快速新增业务流程，系统维护效率提升。

项目三：也买酒智能问数平台（NL2SQL）

项目背景

面向采购选品、品类运营、渠道经营和仓储管理等角色，解决企业数据表多、字段口径复杂、业务人员依赖研发人工编写 SQL 等问题。项目采用元数据驱动的 Text-to-SQL 方案，通过 Schema Linking、工作流编排、EXPLAIN 预校验和 SQL 自修复，将自然语言问题转换为可执行查询并返回结果解释。

技术栈

Python、FastAPI、LangChain、LangGraph、MySQL、Qdrant、Elasticsearch、SQLAlchemy、Docker、HuggingFace Embedding（bge-large-zh-v1.5）

核心功能

- 1.辅助构建元数据管理中心：对酒类电商业务数据源进行结构化治理，梳理订单事实表与商品、品牌、产区、渠道、会员、仓库及时间等维度表的字段映射、主外键关系及业务语义，定义核心经营指标的口径与计算逻辑。
- 2.Schema Linking：使用 Qdrant 进行向量语义召回，结合 Elasticsearch IK 分词完成关键词精确检索，从元数据中定位候选表、字段和指标。

-
-
- 3.NL2SQL 工作流：基于 LangGraph 编排关键词提取、元数据召回、精排去重、Prompt Context 组装、SQL 生成、校验和查询执行等节点。
 - 4.SQL 校验与修复：执行前通过 MySQL EXPLAIN 进行语法及执行计划预校验，校验失败后进入 LLM Error Reflection 分支，根据数据库错误信息自动重写 SQL。
 - 5.结果解释：通过 SQLAlchemy 执行查询，将结果转换为结构化数据，并由模型生成自然语言摘要，帮助业务人员确认结果是否符合原始查询意图。

项目亮点

- 1.宽召回与精筛选机制：通过 Qdrant 语义召回和 Elasticsearch 全文检索扩大候选 Schema 覆盖范围，再进行精排、去重和上下文裁剪，减少无关表字段进入 SQL Prompt。
- 2.SQL Self-Correction 闭环：将 EXPLAIN 预校验、错误诊断、SQL 重写和再次验证编排为条件分支，使 SQL 从一次性生成调整为可校验、可修复的执行链路。

项目效果

- 1.元数据治理与 Hybrid Retrieval 提升了表名、字段别名和指标口径的匹配能力，Schema Linking 召回率提升约 8%。
- 2.通过上下文裁剪、SQL 预校验和自动修复机制，NL2SQL 端到端生成准确率提升约 10%。
- 3.单次数据查询由人工编写 SQL、汇总分析的平均 15 分钟，缩短至自然语言交互秒级出数，减少重复提数工作。

项目四：也买酒多智能体品牌舆情研判平台

项目背景

基于酒类品牌声誉管理和选品需求，构建多智能体协同的 AI 深度舆情研究平台。针对品牌事件、商品评价、真伪争议、价格波动及竞品动态等场景，支持通过自然语言触发多 Agent 协同研究，自动完成私域用户评论挖掘与公域媒体信息检索，由研判主持人 Agent 进行证据对齐与冲突裁决，最终生成五维深度舆情分析报告，帮助运营团队快速掌握舆论态势、识别潜在风险并制定应对策略。

技术栈

Python、FastAPI、LangChain、LangGraph、MySQL、Milvus、BGE-M3、jieba、Pydantic、SSE

核心功能

- 1.研究任务拆解：设计 HostAgent + 子 Agent 多智能体协同架构，基于发布-订阅事件总线实现 Agent 间异步解耦通信，支持私域检索 Agent 与公域检索 Agent 并行研究、主持研判 Agent 异步消费章节就绪事件。
- 2.实现 InsightAgent 私域检索管线：集成 MySQL 结构化查询 + Milvus 向量检索 + BGE-M3 语义聚类，支持评论数据分词、重排序与多维度证据调拨，基于 LangChain 结构化输出控制研究计划生成。
- 3.实现 MediaAgent 公域检索管线：封装 Tavily 多搜索引擎适配层，通过计划-搜索-总结循环模式自动生成五维度公域舆情分析报告。
- 4.构建 HostAgent 研判编排引擎：基于 LangGraph 实现章节解析，证据配对，LLM 裁判，记录归档的状态图决策流，引入维度配对存储（PairStore）实现跨事件累积配对与去重，LLM 主持人对齐两方 Agent 分析进行共识提取、冲突检测及证据可信度评估。
- 5.设计全局契约层与角色注册表，实现多 Agent 的独立 LLM 配置管理与热加载机制，支持不同角色按需绑定不同模型（Kimi K2、Qwen3.5 等）。
- 6.实现按角色路由的日志分离机制，异步报告落盘及中间状态持久化，SSE 事件流进度推送。

项目亮点

- 1.发布-订阅架构：通过发布-订阅事件总线和 Fan-out/Fan-in 调度模式，使 InsightAgent、HostAgent 与 MediaAgent 保持异步解耦，避免多 Agent 串行阻塞。
- 2.定义五维舆情研究框架（事件背景、热度传播、情感观点、平台差异、深层原因），为每个维度独立设计 Insight/Media 双通道分析目标，确保私域与公域分析视角互补。
- 3.主持研判环节实现私域与公域证据交叉验证，有效识别数据源偏差和媒体议程偏差，报告结论置信度显著提升。

项目效果

- 1.单次任务可自动生成覆盖 5 个研究维度×私域、公域 2 类视角的完整报告，减少资料检索、观点整理和报告编写等人工环节，人工介入率降低约 80%。
- 2.私域与公域 Agent 并行执行后，相比单 Agent 串行检索方案，单次舆情研究效率提升约 60%。
- 3.通过跨来源证据配对和 LLM 裁判，能够识别用户评论样本偏差、媒体议程偏差以及不同数据源之间的观点冲突，提升报告结论的可信度。

项目五：也买酒 Coze 智能客服助手

项目背景

为提升也买酒电商平台的智能化服务能力，基于 Coze 低代码 AI 平台搭建智能客服助手，面向消费者及运营人员提供酒款咨询、智能选酒、订单查询、退换货政策及会员权益等智能问答服务。项目依托 Coze Workflow 等能力，将酒款手册、商品详情、品牌产区资料、平台规则及售后政策等业务资料统一构建为知识库，降低人工客服压力，加速 AI 应用在酒类电商业务中的落地。

技术栈

Coze、Workflow、Prompt Engineering、Python、FastAPI、Milvus、BGE-M3、MinerU、

个人职责

- 1.基于 Coze 低代码 AI 平台搭建酒类电商智能客服助手，设计覆盖酒款咨询、智能选酒、订单查询、退换货政策、物流追踪、会员权益及饮用建议等核心业务场景。
- 2.负责酒类电商知识库建设，对商品详情、品牌产区资料、平台规则及售后政策等 PDF/Word/Markdown 非结构化资料进行解析、清洗及入库，结合向量检索提升知识可检索性。
- 3.基于 Workflow 编排客服业务流程，实现意图识别、知识检索、条件分支路由（如订单查询 vs 退换货）、回复生成及异常兜底等完整问答流程。
- 4.编写并持续优化 Prompt，提升模型在酒类电商下的意图理解精确度、酒款推荐合理性及上下文连续对话能力。

项目成果

- 1.基于 Coze Workflow 实现配置化客服流程，加快 AI 应用开发与迭代周期。
- 2.建立统一电商知识库，知识检索效率提升，常见售后咨询自动处理率提升约 65%，有效降低人工客服日常重复性工作。

自我评价

熟悉大模型应用、智能问答、知识库及业务系统的设计与开发，具备较强的需求分析、问题定位和项目落地能力。工作认真负责，学习能力强，能够快速掌握新技术并应用于实际项目。具备良好的团队协作和沟通能力，能够承受一定的工作压力，适应加班及出差安排。本人踏实肯干、吃苦耐劳，对 AI 技术保持热情，希望在工作中持续提升专业能力，为团队和公司创造价值。