

毛昊晗

AI应用开发工程师

☎ 18279321379

✉ 18279321379@163.com

👤 23岁

📅 2年工作经验

教育经历

天津大学

本科

2021/09 - 2025/07

专业技能

Python 后端与工程化

- 熟练掌握 Python，熟悉 FastAPI、SQLAlchemy，具备模块化后端及异步任务开发经验。
- 熟悉 PostgreSQL、Redis、Celery、RabbitMQ、MQTT 等工程组件及 Linux、Git、Docker，具备异步任务、消息队列、事件驱动架构及容器化部署经验。

AI Agent 与大模型应用

- 熟悉 LangChain / LangGraph，具备 Multi-Agent、Workflow、Tool Calling、MCP 等 Agent 应用开发经验。
- 熟悉 Prompt Engineering、结构化输出及“规则引擎 + LLM”分层架构，关注 Agent 循环控制、工具权限及 AI 输出可追溯性。

RAG 与知识库工程

- 熟悉 RAG 全流程：MinerU 文档解析、Chunking、Embedding、Hybrid Search、Reranking。
- 熟悉 Elasticsearch、pgvector 检索方案及 Neo4j 知识图谱建模，具备向量检索与图谱协同检索实践经验。

模型应用与工程化

- 熟练使用 Codex、Claude code、Cursor 等 AI 编程工具。
- 熟悉 Qwen3 等开源模型的工程化应用，具备本地部署与推理服务接入经验。
- 了解 PyTorch、Transformers 及 vLLM 推理部署。

工作经验

江西从容科技有限公司

大模型应用开发工程师

2025/07 - 2026/08

项目经历

社区智慧养老综合服务平台

核心开发

2026/02 - 2026/08

项目简介

面向社区居家养老场景构建 AI 智慧养老综合服务平台，围绕老人、家属、网格员及社区管理人员，实现安全监护、风险预警、服务调度、事件处置及家属触达闭环。基于 Event-Driven Architecture + LangGraph Agent + MCP + RAG 构建智能养老协作体系。

技术栈

FastAPI、SQLAlchemy、PostgreSQL、Redis、MinIO、MQTT、RabbitMQ、Celery、LangGraph、MCP、Qwen3-30B-A3B、BGE-M3、BGE-Reranker-v2-M3、pgvector、SSE、Docker

核心工作

- 基于 FastAPI + SQLAlchemy 构建老人档案、健康管理、设备管理、事件中心及服务工单等核心模块；通过 JWT + RBAC 实现多角色权限控制。
- 基于 MQTT 接入跌倒、SOS、生命体征等设备事件，通过 RabbitMQ 实现事件异步分发与业务解耦；结合事件归档、消息重试及 DLQ 提升事件处理可靠性。
- 基于 LangGraph Supervisor 构建风险评估、健康分析、用药管理及紧急响应 Agent，实现不同事件的动态路由与流程编排。
- 通过 MCP 封装老人档案、健康指标、历史事件及服务工单等业务能力，并在 Tool 层进行身份、角色及数据权限校验，实现 Agent 受控调用。
- 采用 Qwen3-30B-A3B 分级模型架构；确定性风险判断由规则引擎处理，LLM 负责意图理解、信息抽取及复杂分析，高风险操作通过 Human-in-the-Loop 进行人工确认。
- 基于 MinIO 存储健康文档，结合 MinerU、BGE-M3、pgvector 及 BGE-Reranker-v2-M3 构建 RAG 检索链路，通过 Metadata Filtering 限定老人数据范围，并结合 Citation 实现回答依据追溯。

项目成果

- 打通 IoT 事件 → Agent 分析 → 风险决策 → 任务派发 → 人工处置 → 家属通知 → 事件归档 的完整业务闭环。
- 建立消息重试、事件状态管理、超时升级及人工兜底机制，提升高风险事件处理的可靠性与可追溯性。
- 构建 Event-Driven + Agent + MCP + RAG 一体化架构，实现 AI 从知识问答向风险分析、业务协同及受控任务执行延伸。

HealthFlow 健康管理智能协作平台

核心开发

2025/10 - 2026/01

项目简介

面向体检中心、慢病管理机构构建 AI 健康管理智能协作平台，围绕“健康数据 → 风险分析 → 健康计划 → 随访跟踪”形成健康管理闭环。基于 Agentic RAG + LangGraph Workflow 实现健康分析、知识问答、计划生成及随访任务协同，并通过 Human-in-the-loop 对高风险建议进行人工审核。

技术栈

FastAPI、SQLAlchemy、PostgreSQL、Redis、Celery、LangGraph、LangChain、Qwen3-14B、BGE-M3、BGE-Reranker-v2-M3、pgvector、Docker

核心工作

- 基于 FastAPI + SQLAlchemy 构建健康档案、体征指标、用药管理、健康计划及随访任务等核心业务模块。
- 设计 Router + Specialist Agent 架构，根据用户请求动态选择数据查询、风险分析、健康计划等不同处理流程。
- 基于 LangGraph + Tool Calling 构建 Agent Workflow，将健康数据查询、风险计算、知识检索及任务创建封装为标准 Tool。
- 基于 BGE-M3 + pgvector 构建健康知识库，结合全文检索、向量检索及 Metadata Filtering 实现混合检索，并返回 Citation 作为回答依据。
- 设计 规则引擎 + LLM 协同机制，由规则引擎处理指标阈值及风险评分，LLM 负责语义理解、知识关联及健康计划生成。

- 引入 Human-in-the-loop + Celery，对高风险建议进行人工审核，并将报告生成、随访提醒等耗时任务异步处理。

项目成果

- 完成 健康数据、RAG 知识库、Multi-Agent 及业务 Workflow 的一体化，实现从健康分析到计划执行的业务闭环。
- 建立 规则引擎 + LLM + Human-in-the-loop 的 AI 决策机制，明确模型与业务规则的职责边界，提升健康建议的可解释性与可控性。
- 实现 Agent 状态追踪、Tool 调用记录及检索证据留存，支持复杂任务执行过程的审计、问题定位及结果复盘。

Aceso 医药智能知识平台

核心开发

2025/07 - 2025/12

项目简介

面向药企研发团队构建企业级研发知识智能平台，统一管理实验报告、检测报告、研究记录及医学文献等多源研发资料，围绕研发知识检索、实体关联、实验分析及知识治理等场景，基于 Hybrid RAG + Graph RAG + Agent 构建智能知识协作能力，提升研发资料检索及历史知识复用效率。

技术栈

FastAPI、SQLAlchemy、PostgreSQL、MinIO、Elasticsearch、Neo4j、LangGraph、Qwen3-30B-A3B、MinerU、BGE-M3、BGE-Reranker、Redis、Celery

核心工作

- 基于 FastAPI + SQLAlchemy 构建研发项目、报告、知识库及智能问答等核心服务，结合 PostgreSQL 管理业务数据与知识版本，使用 MinIO 实现研发原始文档统一存储。
- 基于 MinerU 构建研发文档解析 Pipeline，针对实验报告复杂版面及跨页表格进行结构化解析与重建，结合 Structure-aware / Table-aware Chunking 保留实验上下文及关键数据关系。
- 基于 Elasticsearch + BGE-M3 + BGE-Reranker 构建混合检索能力，将关键词、向量及实验指标 Metadata Filtering 结合，支持研发文本、实验参数及检测指标的联合检索与精排。
- 基于 Neo4j 构建研发知识图谱，通过实体标准化、别名消歧及 Entity-First Routing，将 CAS、Batch_ID、Experiment_ID 等关键实体转换为检索约束，协同 Elasticsearch 实现 Graph RAG。
- 基于 LangGraph + Qwen3-30B-A3B 构建研发知识 Agent，实现 Query Rewrite、Intent Routing、Tool Calling、Evidence Validation 及 Citation Generation，并针对低置信度问题设计检索兜底机制。
- 建立知识版本与证据治理机制，将关键结论与文档版本、页码及 Chunk 建立证据关联，通过 STAGING + Shadow Evaluation 控制知识版本发布。

项目成果

- 建立 RAG 多维评估体系，覆盖检索、排序、证据覆盖、生成准确性与引用可靠性，并基于 Badcase 分析持续优化检索链路。
- 建立 RAG 评估集与 badcase 分析流程，实现 recall@5 从 61% 提升至 94%。
- 构建 文档解析 → Hybrid/Graph RAG → Agent → 证据验证 → 知识治理完整链路，提升研发历史资料检索、知识关联及分析效率。