

王小龙

电话：13834384624

邮箱：wangxiaolong_0523@163.com

性别：男

求职意向：大模型算法工程师



教育经历

2020.09 - 2024.06

太原科技大学

电子信息工程 | 本科

专业技能

- 熟练 Vibe Coding 工具 (Superpowers + Openspec + GStack + Claude Code + Codex)
- 熟练 Agent 系统范式 (ReAct - Reflection + Supervisor + Stateful Agent + Plan-and-Execute)
- 熟练 Agent 系统框架 (LangChain + LangGraph + OpenClaw + Hermes + Agent SDK+ Dify)
- 熟练 Agent 工具编排 (Skills + MCP + Function Calling + Tool Use)
- 熟练 RAG 系统全链路搭建：文档解析 (Mineru)、语义分块、混合检索 (BM25 + HNSW/FAISS)、多轮对话上下文管理、质量评估 (RAGAS)、调优迭代
- 熟练 多模态 AIGC 模型：文生图 (GPT-Image-2)、文生视频/图生视频 (Wan2.1 / Wan2.2)
- 熟练 数字人系统全链路搭建：TTS (GPT-SoVITS)、ASR (FunASR)、唇形同步 (SadTalker)
- 熟练 Prompt Engineering (CoT + Few-shot)、Context Engineering、Harness Engineering
- 熟练 大模型微调与部署 (SFT + LoRA + LLaMA-Factory + Swift + vLLM + SGLang + RLHF)
- 熟练 数据库使用 (MySQL + PostgreSQL + Redis + Milvus + Elasticsearch + Neo4j + OSS)
- 熟练 Python 后端工程 (FastAPI + Pydantic + WebSocket + SSE)
- 熟练 AI 基础工程 (Transformer + PyTorch + Hugging Face Transformers)
- 熟练 日常开发 (Docker + Git + Linux + Conda)

工作经历

2024.05 - 至今

麦道 (深圳) 数据科技有限公司

大模型算法工程师

- 从 0 到 1 构建考研培训智能知识库问答系统，优化文档解析、语义切分、混合检索、精排与幻觉控制全链路，MRR 从 0.78 提升至 0.89，用户满意度 88%，投诉率降低 65%，减少人工客服工作量 60%
- 从 0 到 1 构建 2000 个领域三元组对 BGE Embedding 进行微调，Recall@5 从 0.87 提升至 0.93
- 设计 6 智能体协作架构，基于 LangGraph StateGraph 实现 9 阶段研究状态机，事实准确率从 82% 提升至 90%，顾问人均日产报告数从 2 份提升至 8 份，单份报告平均覆盖 20+ 条有效来源
- 设计 Query → Retrieve → Reason → Reflect → Rewrite 五节点 Agent 流程，实现多步推理与自检纠偏，Top-5 召回率 85%，修正成功率 78%

- 接手并重构 **Text2SQL 系统**，通过动态 **Schema 剪裁 + 意图对齐 + 语义缓存闭环**，**SQL 生成准确率**从 75% 提升至 93%，系统已部署上线
- **主导 ASR 与 TTS 微调**：基于 **LoRA 微调 Whisper-Medium**，准确率从 72% 提升至 91%
- **主导微调 GPT-SoVITS** 实现音色克隆，原流程含人工录制+剪辑+配音，自动化后全流程 10 分钟内完成，制作成本降低 70%

2023.07 - 2024.04

深圳趣客汇信息科技有限公司

NLP算法工程师

- **主导构建企业级 FAQ 语义问答系统**，设计**向量检索+LLM兜底双路召回架构**，独立完成训练数据构建与清洗pipeline，构建**数据反馈闭环**持续迭代模型效果；系统上线后 **FAQ 命中率达 87%**，替代 40% 重复性人工咨询，显著降低客服运营成本。
- **独立负责电商商品知识图谱系统全链路建设**，涵盖 **BiLSTM-CRF/BERT实体识别、关系抽取、Neo4j 图存储及自然语言转 Cypher 问答**，设计离线/在线双评估体系验证效果；**NER 整体 F1 达 88%**，商品语义检索效率提升 60%，支撑商品搜索与智能问答场景落地。
- 基于 **LoRA 对 Qwen-7B 进行领域微调**，采用**多卡并行训练**缩短迭代周期，结合 **INT8 量化压缩模型**体积，通过 **vLLM** 完成生产环境部署并接入 **FAQ 问答链路**；推理成本降低约 50%，在**高并发**场景下保障服务稳定运行。

项目经历

2025.11 - 至今

Multi-Agent智能研报系统

大模型算法工程师

项目描述：为考研培训机构顾问构建的多智能体深度研究系统，将**院校分析、政策解读、竞品研究**自动转化为**结构化研究报告**，支持**追溯分析、实时流式输出与图表生成**，替代**人工检索整合流程**。

技术栈：Python · FastAPI · LangGraph · Multi-Agent · Milvus · PostgreSQL · SSE · BGE-M3 · ECharts

工作内容：

- 设计并实现 6 智能体协作架构：先定义抽象 **BaseAgent** 基类，封装 LLM 调用、**JSON 容错解析**、SSE 推送、指数退避重试等工具，基于开闭原则通过继承重写实现 **ChiefArchitect**、**DeepScout**、**DataAnalys t**、**CodeWizard**、**LeadWriter**、**CriticMaster** 六个专职 Agent，并通过 **AgentRegistry** 注册表统一管理，共享 **ResearchState**。
- 构建假设驱动研究流程：**ChiefArchitect** 生成最多 5 个可证伪假设大纲，**DeepScout** 并行执行多路搜索并对每条事实标注支持/反驳/证据不足，动态更新假设置信度；**CriticMaster** 对质量评分未达到阈值的报告触发智能路由，按问题类型分别回退至补充搜索或文字修订，最多迭代 3 轮。
- 实现三级搜索降级链：**Bocha (主) → Serper (备) → 本地 Milvus 知识库 (兜底)**，基于策略模式封装统一搜索接口，支持运行时切换；本地向量检索基于 **BGE-M3** 嵌入，**HNSW** 索引，支持动态路由至不同知识库集合。
- 设计并实现对话记忆层：基于 **ChatMessage** 管理短期会话上下文，超过 10,000 Token 后通过后台任务调用 **LLM** 自动压缩对话，提取摘要、关键洞察、用户偏好和主题标签，持久化至 **PostgreSQL LongTerm Memory**，并将其向量化写入 Milvus；新请求按用户维度召回 **Top-3** 相关记忆注入 **Prompt**，实现长对话压缩、跨会话记忆召回与个性化上下文增强。
- 基于 **LangGraph StateGraph** 实现 9 阶段研究状态机，结合 **Checkpoint** 将完整 **ResearchState** 快照持久化至 **PostgreSQL**，支持任意阶段断点恢复与前端续跑；同时实现手写异步状态机版本，基于 **asyncio.Q**

ueue + FastAPI SSE 实现毫秒级全链路实时流式输出，解决 LangGraph astream 节点级粒度无法满足逐步推送的问题。

项目成果：

- **评估指标**：基于 RACE 框架进行**多维度**评测，**事实准确率（Factuality）**从 82% 提升至 90%，**幻觉率**小于 5%。
- **业务价值**：院校分析报告生成时长从 2-4 小时压缩至 30 分钟左右，顾问人均日产报告数从 2 份提升至 8 份，单份报告**平均覆盖 20+ 条有效来源**。

2025.04 - 2025.11

RAG智能知识库系统

大模型算法工程师

项目描述：从 0 到 1 构建面向考研培训业务的智能知识库问答系统，处理 5000+ 份多格式文档（PDF/Word/扫描件），服务 200+ 名课程顾问，日均处理 300+ 次查询，响应时间在 2 秒之内。

技术栈：Python · FastAPI · Milvus · Elasticsearch · Redis · XGBoost · Deepdoc · Embedding · RRF · BGE · bge-reranker · MinerU · LayoutLMv3

主要工作：

- **文档解析 Pipeline**：基于 Deepdoc (LayoutLMv3 + paddleocr) 实现版面分析，保留标题层级、表格结构、页码和 bbox 坐标；针对无边框分数线表和专业目录表接入 MinerU TabRec，无边框表格识别率从 62% 提升至 97%；设计扫描件分档预处理 pipeline（模糊检测 → 去噪锐化 → 超分 → OCR 校验），扫描件准确率从 73% 提升至 94%；整体解析准确率从 82% 提升至 97%。
- **语义感知切分**：训练 XGBoost 层级分类器（特征：编号模式、字体大小、缩进、页面位置、上下文），识别招生简章/复试细则/调剂公告的章节层级，准确率达 94%；按章节 → 小节 → 段落递归切分，大表格按语义行组拆分并复制表头；overlap 按句子边界截取，语义截断率从 23% 降至 4%；chunk 携带学校、专业代码、年份、页码、章节路径等 metadata，支持元数据过滤和引用溯源。
- **混合检索架构**：Milvus 向量检索 (bge-large-zh-v1.5) 与 Elasticsearch BM25 并行执行，维护学校简称、专业别名、考试科目等考研领域词典；LLM 意图识别动态调整检索权重（精确型提高 BM25、语义型提高向量），RRF 算法融合排名，MMR 去重；整体 MRR 从 0.78 提升至 0.89，Top-5 召回率 93%。
- **BGE 微调**：构建 2000 组教育领域三元组，hard negative 选取同校不同专业、同专业不同年份、学硕/专硕混淆等易混样本微调 BGE，Recall@5 从 0.87 提升至 0.93。
- **精排与幻觉控制**：bge-reranker-large Cross-Encoder 精排粗召回 Top-20，batch 推理 + INT8 量化将延迟从 300ms 降至 80ms；生成侧 Prompt 约束仅依据检索片段回答，后处理校验引用编号与来源 chunk 对应关系，无法对应的结论降级为"不确定"；答案准确率 94%，投诉率降低 65%。
- **工程优化**：FastAPI 异步接口 + Redis Cluster（会话状态、热点 query 缓存、检索结果缓存）+ 分布式 Milvus + Elasticsearch，向量检索与 BM25 并行执行；SQLAlchemy 连接池；系统支持 100+ QPS，P99 延迟从 350ms 降至 150ms。

项目成果：

- **检索质量**：MRR 从 0.78 提升至 0.89，Top-5 召回率 93%，答案准确率 94%。
- **业务价值**：用户满意度 88%，投诉率降低 65%，减少人工客服工作量 60%。

2024.12 - 2025.04

React-Reflection智能答疑系统

大模型算法工程师

项目描述：面向考研备考咨询场景，构建 7×24h 智能答疑系统，覆盖择校、招生简章、历年分数线、政策 FAQ 等高频问题；基于 RAG 与 Agent 推理机制，实现多步推理、引用溯源与自检纠偏。

技术栈： LlamaIndex · Milvus · BGE-M3 · BM25 · Hybrid Search · ReAct · Reflection · FastAPI

主要工作：

- **Agent 流程设计：** 设计 **Query → Retrieve → Reason → Reflect → Rewrite** 任务流，将问答拆解为意图识别、知识检索、推理生成、反思复核、答案重写 5 个节点，提升复杂问题回答稳定性。
- **检索增强优化：** 基于 **Milvus**、**BGE-M3** 与 **BM25** 构建混合检索链路，结合 **LlamaIndex** 对招生简章、政策 FAQ、分数线表格进行结构化切分，Top-5 证据召回命中率达 **85%**。
- **Reflection 自检纠偏：** 从答案完整性、引用覆盖度、逻辑一致性评估回答质量，自动触发二次检索与重写，纠偏后回答修正成功率达 **78%**，幻觉率控制在 **6%** 以内。
- **Memory 多轮问答：** 构建上下文记忆模块，支持围绕同一院校的分分数线、专业目录、复试比例等连续追问，多轮问答通过率达 **82%**。

项目成果：

- **评估指标：** 系统任务完成率达 **88%**，引用准确率达 **90%**，平均响应时间稳定在 **2 秒** 以内。
- **业务价值：** 覆盖 **85%** 常见考研咨询问题，人工介入率下降 **30%**。

2024.09 - 2024.12

智能问数系统

大模型算法工程师

项目描述： 面向考研市场场景，接手并优化原有 **Text2SQL** 系统，针对复杂查询准确率低、缺乏安全校验、全量 **Schema** 传输耗 Token 等问题进行重构；通过**动态 Schema 剪裁**、意图对齐与歧义澄清、Prompt 重构及语义缓存闭环优化，将高频场景 SQL 生成准确率从 **65%** 提升至 **93%**，系统已部署上线。

技术栈： Python · Text2SQL · BGE-Embedding · Few-shot Prompting · Redis · PostgreSQL

主要工作：

- **动态 Schema 剪裁：** 基于 BGE 计算 Query 与表结构语义相似度，从数十张表中动态召回 **Top-3** 目标表注入提示词，降低 Token 损耗并减少幻觉。
- **意图对齐与歧义澄清：** 构建**业务术语词典**，将最近、业绩等高频表达映射为明确业务口径，并设计前端反思追问机制锁定真实意图。
- **Prompt 重构与 Few-shot 优化：** 重构包含字段类型、描述、样例、主外键信息的 **Metadata Prompt**，并强制动态注入 **Limit 限制**，避免全表扫描。
- **语义缓存与反馈闭环：** 基于 **Redis** 搭建 **2 小时语义缓存链路**，降低重复调用成本；建设查询日志与反馈表，结合 **Badcase 分析脚本持续迭代 Few-shot 样本**。

项目成果：

- **评估指标：** 高频场景 SQL 生成准确率由 **75%** 提升至 **93%**，动态 Schema 剪裁显著降低 **Token 消耗**，Redis 语义缓存命中后响应降至 **100ms**，支持核心指标 **30 秒** 自动化图表输出。

2024.05 - 2024.09

数字人系统

大模型算法工程师

项目描述： 自主开发考研培训场景的**多模态数字人**视频自动化生成系统，整合 **ASR**、**文本校对**、**TTS**、**SadTalker** 唇形同步完整流程，将考研政策文档、院校招生简章一键转化为**数字人讲解视频**。

技术栈： Python · Whisper-Medium · LoRA · GPT-SoVITS · TTS/ASR · SadTalker · RTX 4090

主要工作：

- **ASR 语音识别微调方面，**针对原生 **Whisper-Medium** 对推免、调剂、复试线等考研专业术语识别准确率仅 **72% 的问题**，基于魔塔社区 **3970 条** 音频数据，在单张显存为 **24G** 的 **RTX 4090** 上使用 **LoRA** 增量微调，准确率从 **72%** 提升至 **91%**，**字错率**降至 **9%**，训练 Loss 从 **2.8** 收敛至 **0.23**。

- **TTS** 语音克隆与韵律优化方面，主导微调 **GPT (15 轮)** 与 **SoVITS (12 轮)** 双模型，分别优化发音节奏和音色风格；采集 **100** 条内部高质量音频，经降噪和采样预处理后微调，消除 **AI 音**，10 字以内短文本响应 **200ms**，微调前音色相似度低、AI感明显，微调后通过内部听感评估达到可商用标准。

项目成果：

- **评估指标：**ASR 准确率 **91%**，字错率 **9%**，TTS 短文本响应 **200ms**，原流程含人工录制+剪辑+配音，自动化后全流程 **10** 分钟内完成，制作成本降低 **70%**，支持批量生产院校解读、政策 FAQ 等系列标准化讲解视频。

2023.12 - 2024.04

FAQ问答机器人系统

NLP算法工程师

项目描述：面向公司内部员工及客户的智能问答系统，覆盖业务流程、产品使用、政策规范等高频咨询场景。

构建 **3000+** 条 **FAQ** 向量知识库，采用**精确匹配优先、LLM 兜底生成**的双路策略。

技术栈：Python · FastAPI · bge-large-zh-v1.5 · Milvus · Redis · PostgreSQL · LLM

主要工作：

- **FAQ 知识库构建：**清洗整理 **3000+** 条历史问答数据，使用 **bge-large-zh-v1.5** 对文本编码生成 **1024 维** 向量并存入 **Milvus**；**PostgreSQL** 存储原始问答对及分类、更新时间、置信度阈值等元数据。
- **双路召回策略：**以语义检索为主路、关键词匹配为兜底；相似度大于等于 **0.85** 时直接返回 **FAQ 原文**，低于阈值时调用 **LLM** 基于召回上下文生成回答，并标注 **AI 生成与知识库原文**来源。
- **多轮上下文管理：**基于 **Redis** 维护会话上下文，**TTL 30 分钟**，支持追问理解与跨轮指代，解决单轮问答语义断裂问题。
- **FastAPI 服务化：**封装问答接口、FAQ 管理接口和命中率统计接口，支持 **SSE** 流式输出，实现 **LLM 回答**实时推送。

项目成果：

- **评估指标：**FAQ 命中率 **87%**，平均响应时间 **500ms** 以内。
- **业务价值：**替代约 **40%** 重复性人工咨询，高峰期显著降低客服压力，系统可用性达生产标准。

2023.07 - 2023.12

电商平台知识图谱智能检索系统

NLP算法工程师

项目描述：面向**电商平台 B 端商家**，构建数据标注 → 命名实体识别 → 关系抽取 → 图存储 → 智能问答全链路商品知识图谱系统，实现从非结构化商品描述文本到可查询知识网络的自动化构建，**NER 整体 F1 达 88%**。

技术栈：Python · PyTorch · BiLSTM-CRF · BERT · Neo4j 4.4 · py2neo · Cypher · FastAPI

主要工作：

- **语料构建与标注：**对商品标题、详情页、规格参数等文本进行数据清洗与BIO格式标注，构建覆盖品牌、型号、规格、类目、属性等多类实体的训练语料，词表规模5000，标签集100类。
- **BiLSTM-CRF 实体识别：**设计 **Embedding (100维)** → **BiLSTM (Hidden 256维)** → **CRF** 解码架构，在商品语料上训练，**NER 整体 F1 达 88%**，品牌、型号类实体识别准确率超 **90%**。
- **知识图谱构建与存储：**设计商品本体节点标签与关系，通过 **py2neo** 将抽取结果批量写入 **Neo4j 4.4**；针对多跳关联查询建立复合索引，查询响应小于 **0.5秒**。
- **自然语言问答：**结合实体识别与意图分类，将"XX品牌有哪些型号/规格"等典型问句自动转换为 **Cypher** 查询语句，实现端到端问答。

项目成果：

- **评估指标：**NER 整体 **F1 88%**，多跳查询响应小于 **0.5秒**，问答意图识别准确率 **92%**。

- **业务价值**：商品检索效率相较人工翻查提升约 **60%**，支持 B 端商家批量商品入库与智能选品推荐。

自我评价

3 年 AI 应用工程经验，专注 **RAG** 与 **Multi-Agent** 系统从 0 到 1 落地。主导构建的 **RAG** 知识库系统 **MRR** 达 **0.92**，**Multi-Agent** 研报系统将顾问日产报告从 2 份提升至 15 份。覆盖 **RAG 全链路**、**Agent 架构**、**LoRA 微调**与**多模态数字人**四个落地方向，具备交付生产级AI系统的完整工程能力。