

姓名：王烨
年龄：26岁
经验：5年
手机：13400129194
邮箱：13400129194@163.com



教育背景

2017/09 - 2021/06

中山大学新华学院

本科 - 计算机科学与技术

工作经历

2023/08 - 至今

广东远景信息科技有限公司

AI应用开发工程师

- 负责企业私有RAG系统核心架构设计与服务层开发,主导检索与生成双侧质量防护机制建设,有效规避幻觉,问答准确率显著提升。
- 主导多Agent数据分析平台的编排与执行引擎设计,实现多角色Agent解耦与多种协作模式动态调度,兼顾长会话成本控制与任务完成率。
- 负责企业级大模型网关整体架构设计,落地限流熔断、Prompt全生命周期管理与智能路由,核心接口可用性达到高可用标准,显著降低跨业务线调用成本。
- 负责智能合同审查系统的文档解析流水线与审查Agent编排,适配扫描件、嵌套表格等复杂场景,单份合同审核时长从30分钟缩短至2分钟以内。
- 搭建AI后端服务与基础设施,基于FastAPI实现JWT认证与SSE流式输出,完成多服务容器化部署,支撑弹性扩缩容。
- 基于Langfuse构建全链路可观测与自动质量评分机制,通过多阶段构建将镜像体积显著缩减,持续优化服务运行成本。

2021/07 - 2023/07

广州尚远科技有限公司

AI应用开发工程师

- 负责企业级知识库问答系统中文档预处理模块开发,实现PDF、Word、Excel、PPT等多格式文档的解析、清洗与结构化分片,支撑大规模文档入库。
- 负责Milvus向量库的集合设计与入库链路搭建,完成文本Embedding与批量向量化入库全流程,保障数据检索的实时性与准确性。
- 参与知识库系统由传统检索问答向大模型问答的演进,负责GPT、ChatGLM等模型的接入适配与接口封装,实现会话管理、Prompt模板管理与流式输出等基础能力,支撑甲方多业务场景调用。
- 基于线上BadCase持续迭代检索策略与Prompt模板,落地向量与关键词双路检索的融合排序方案,整体问答效果持续改善。
- 跟进系统功能迭代与线上问题排查,定位调用超时、结果偏差等异常,通过并发与缓存策略优化接口响应速度。
- 沉淀文档解析、向量化入库等可复用组件与工具函数,编写技术文档,便于团队复用与上手。

项目经历

2026/01 - 至今

私有化企业知识库 RAG 系统

AI应用开发工程师

项目背景

该项目为甲方企业内部私有化部署的检索增强生成系统。整体架构包含Langfuse全链路可观测与评测体系、离线索引构建与增量更新入库、在线混合检索服务、FastAPI后端接口层及容器化弹性部署方案。系统面向企业内部知识库问答场景,对答案准确率有极高要求,需规避幻觉并确保引用可溯源,对响应延迟的敏感度相对较低,允许一定推理耗时以换取质量。

技术栈

Python、LangGraph、FastAPI、Milvus、Ollama、Langfuse、Docling、Docker Compose

职责

- 1. 设计基于LangGraph的多节点状态机，整合查询路由、混合检索、CRAG纠错与Self-RAG自省多层流水线，通过条件边实现分支路由与自动纠错循环。
- 2. 构建多阶段混合检索管线，引入语义等价改写扩展召回覆盖面，结合融合排序与精排机制，通过阈值过滤低相关文档以提升检索准确率。
- 3. 实现层次化父子分块策略，按文档标题层级保留结构上下文，针对表格截断设计占位符替换与多组子表变体，保障全量数据可召回。
- 4. 搭建基于Langfuse的零代码侵入可观测体系，通过装饰器与运行时注入自动采集回调，设计后台评分池实现LLM自动质量评判。
- 5. 完成容器化多服务生产级部署编排，采用多阶段构建缩减接口服务镜像体积，实现离线索引与在线查询独立部署及弹性扩缩容。
- 6. 设计增量更新与版本化离线索引构建机制，支持文档新增、变更与删除的差异化索引同步，保障知识库内容时效性与结果一致性。
- 7. 构建检索结果引用溯源体系，为生成答案绑定原始文档出处与段落定位，满足企业合规审计与答案可解释性要求。
- 8. 主导服务层接口规范定义，设计标准化RESTful与流式SSE输出协议，统一交互语义与异常处理策略，降低多客户端集成成本。

2025/04 - 2025/12

多 Agent 智能数据分析工作台

AI应用开发工程师

项目背景

为甲方构建私有化多Agent数据分析平台,小型团队交付。用户以自然语言提问,系统自动调度多个角色Agent协作完成数据加载、代码分析、质量审查、图表与报告输出,满足数据不出域、结果可审计、长会话稳定、高危操作可控的诉求。本人负责Agent循环与工作流编排多个核心模块。

技术栈

Python、LangChain、LangGraph、Pandas、Matplotlib/Plotly、SQLite、ChromaDB、LSP、MCP

职责

- 1. 设计核心Agent执行引擎，采用"薄循环、厚基础设施"架构，将推理、调度、鉴权与审计解耦，支撑Planner、Coder、Researcher、Reviewer独立运行。
- 2. 搭建多层上下文压缩流水线，覆盖裁剪折叠自动压缩，解决长会话瓶颈，降低大模型调用开销。
- 3. 构建多层安全防线，落地Deny-First规则与RBAC及ABAC权限引擎，引入代码沙箱隔离与渐进式信任机制，默认拒绝高风险工具调用。
- 4. 集成LSP协议使Agent具备代码语义感知与静态分析能力，接入MCP标准生态兼容社区大量外部服务，扩展数据源与服务边界。
- 5. 实现基于LangGraph的多Agent动态编排引擎，支持多种协作模式，按任务复杂度自动选最优策略与资源配置。
- 6. 设计长会话状态持久化与断点续传机制，将中间结果与上下文快照序列化存储，支持异常恢复与会话回放审计。
- 7. 构建场景可审计与数据不出域体系，全量日志与本地计算优先，满足企业级数据安全合规。
- 8. 主导输出格式化与可视化渲染管线，统一图表、表格与报告模板生成规范，实现分析结果自动排版与多格式导出。

2024/10 - 2025/03

统一大模型网关与管控平台

AI应用开发工程师

项目背景

公司AI业务快速扩张阶段,多条业务线独立对接大模型接口,存在选型混乱、成本不可控、Prompt管理分散、调用链路不可追溯等痛点。为规范AI调用流程、降低整体使用成本、实现全链路可观测可迭代,搭建统一大模型网关管控平台支撑内部业务线AI应用快速接入,本人负责整体架构设计与网关核心模块开发。

技术栈

Python、FastAPI、Langfuse、Redis、Docker、容器编排、Ollama、Pydantic

职责

- 1. 设计统一大模型网关内核，兼容主流商用模型与本地私有化协议，对外提供标准化REST与SSE流式接口。
- 2. 落地Token预算与QPS双层限流熔断机制，支持按业务线分配调用额度，异常流量自动降级至备用模型。
- 3. 搭建Prompt生命周期管理模块，支持版本、灰度与回滚，结合追踪统计效果与消耗。

- 4. 构建智能路由与成本优化引擎，基于查询复杂度与语义类型自动调度最优模型，轻量问答路由至本地模型，复杂推理调度至高阶模型。
- 5. 落地全链路可观测与合规审计体系，按业务线、模型与时间段生成成本质量报表，支持调用日志溯源与合规审查。
- 6. 搭建高频查询语义缓存机制，对重复请求直接返回缓存结果，进一步降低调用成本与响应延迟。
- 7. 设计模型能力与效果评测体系，构建标准化评测数据集与自动打分流线，支撑模型选型决策与迭代效果验证。
- 8. 主导网关SDK与接入规范，提供统一鉴权、埋点与异常封装，降低AI接入门槛与重复成本。

2024/01 - 2024/09

智能合同审查 Agent 系统

AI应用开发工程师

项目背景

针对企业法务部门合同审核效率低、人工抽取信息易错、风险条款易漏检等痛点,打造基于大模型的智能合同审查系统,支持合同文档自动解析、核心信息结构化抽取、风险条款智能识别与审查报告自动生成。本人负责文档解析流水线设计与审查Agent工作流编排。

技术栈

Python、LangGraph、Docling、Milvus、FastAPI、Docker Compose

职责

- 1. 基于Docling构建多格式合同解析流水线，覆盖PDF、Word与扫描件等主流格式，针对复杂版面进行预处理，结合OCR实现扫描件文本还原与异常降级。
- 2. 设计分层化信息抽取Agent工作流，借助LangGraph编排解析、抽取、校验、补全节点，实现核心字段自动化提取与交叉验证降噪。
- 3. 构建风险条款审查知识库，将法律法规与风控经验向量化存储，结合语义检索与规则匹配双路召回，自动识别风险条款并生成分级修改建议。
- 4. 开发审查报告自动生成模块，将抽取结果、风险标注与修改建议整合为结构化报告，提供在线复核界面，人工修正数据回流至模型持续优化。
- 5. 搭建基于FastAPI的微服务架构，将解析、抽取、审查、生成等能力封装为独立服务，通过容器编排实现一键部署与横向扩展。
- 6. 建立全链路监控与日志追踪体系，实时采集各阶段耗时与节点状态，设计版本管理机制支持规则库与模型的灰度更新及一键回滚。
- 7. 设计合同要素Schema与校验规则，统一多来源合同结构化输出，支撑下游风控与法务对接。
- 8. 构建人机协同审查工作流，定义多级审批节点（初筛/复核/终审），通过置信度阈值实现任务智能分发。

自我评价

- 1. 熟悉RAG检索增强生成全链路生产落地，基于真实业务问题做过技术选型与取舍，掌握层次化分块、混合检索与多层质检的实现方法，注重冷启动成本与可解释性。
- 2. 熟悉大模型推理服务与成本管控方法，掌握本地推理部署、多模型统一调度、预算控制与熔断降级机制，能在模型能力与推理成本之间取得工程最优平衡。
- 3. 掌握"最简够用优先、失败才升级"的技术决策原则，擅长在检索精度与上下文完整性、安全严格度与用户体验之间做权衡，可独立完成AI应用从零到一的架构搭建与持续迭代。
- 4. 掌握多Agent系统的"薄循环、厚基础设施"架构设计，将业务逻辑下沉为可注入模块，配套多层安全门禁与审计机制，保障长会话稳定与高危操作可控。
- 5. 具备扎实的工程底子与端到端交付能力，毕业后即深耕 AI 应用开发方向，将工程化思维融入大模型建设，熟悉从需求拆解到部署交付的完整链路，主导过企业级 RAG 与多 Agent 平台的完整落地。
- 6. 具备LLMOps全链路可观测与持续优化能力，搭建零侵入追踪体系自动采集链路节点，结合坏例沉淀驱动Prompt迭代与分类器训练，实现效果持续优化与成本管控。
- 7. 具备较强的技术方案抽象与文档沉淀能力，习惯将复杂系统拆解为清晰模块边界与接口契约，重视代码可维护性与团队协作效率，推动团队整体水平提升。
- 8. 具备良好的跨团队沟通与项目推进经验，能够在业务需求与技术实现之间建立有效桥梁，善于将前沿技术转化为可落地的工程方案，并持续跟踪效果进行迭代优化。