

求职意向：大模型应用工程师

年龄 22 岁

性别 男

工作年限 2 年经验

电话 15822389715

邮箱 quanbone@163.com

学历 本科



个人优势

- 约2年 AI 应用经验，具备RAG与多Agent系统落地经验，曾在电力行业完成复杂业务场景智能化改造从知识库构建、混合检索到LangGraph编排、FastMCP工具封装及容器化部署的完整链路
- 擅长搭建可生产运行的智能体解决方案，聚焦解决大模型幻觉、工具调用异常、多轮会话指代歧义、检索精度不足等落地痛点
- 持续跟进 Agent 前沿技术（harness、Loop Engineering、dsh等），具备需求拆解、方案落地与跨团队协作能力

技能特长

AI模型与应用

- 掌握大模型 API（DeepSeek / Qwen）与 Prompt Engineering，具备结构化输出设计能力
- 掌握 Pydantic结构化输出，用于意图识别与工具参数约束
- 熟练运用 Claude Code / Cursor / Trae等AI工具,具有Vibe Coding经验能力，工程项目开发提效5倍+

RAG与知识库

- 掌握 RAG 全链路：文档解析、父子块语义分块、BGE-M3 双路向量
- 掌握 Milvus 混合检索（稠密+稀疏）与 BGE-Reranker 精排及消融取舍，在RAG项目中完成权重调优与消融
- 熟悉BM25-FAQ 快路径与直接检索 / HyDE / 子查询 / 回溯四策略自适应调度

Agent与工具调用

- 掌握 LangGraph 编排：意图 LoRA 优先 + LLM 兜底 → Workflow / 受限 ReAct / RAG 兜底
- 掌握 三层容错（重试→降级→兜底）、双层记忆系统设计
- 有基于Qwen2.5-7B进行意图分类任务的微调与部署经验。
- 熟悉 MCP 工具解耦、工具白名单绑定与调用链路追踪

Python与后端工程

- 掌握 FastAPI、WebSocket 流式输出、SSE、异步编程；
- 熟悉 Redis 会话缓存、MySQL 数据存储、Docker 容器化部署

工作经历

天津安捷物联科技股份有限公司 AI应用开发工程师

2025-01 ~ 2026-08

项目经历

电力行业 Agent 智能问答系统 AI应用开发

2025-12 ~ 2026-08

技术栈

Python / LangGraph / MCP / DeepSeek / LoRA / Milvus / BGE-M3 / FastAPI / WebSocket / Redis / MySQL

项目背景

固定 RAG 流水线只能回答知识查询，难以覆盖电量/告警/账单等需多步工具调用与计算的运维问题。项目将固定流水线升级为可自主选工具、可联网检索、可执行受控写操作的 Agent 系统，面向电力数据采集公司的账单解读、告警处置与节电建议场景。

核心职责

- 分层意图路由编排

1. 实现分层路由逻辑：FAQ/BM25 命中直接秒级返回；通过意图路由分流，业务场景走 Workflow，知识类或失败场景回退 RAG，复杂任务进入受限 ReAct 执行；

2. 完成意图 LoRA 微调：基于 13 类业务意图训练 Qwen2.5-7B，实现高置信短路直接进入 Workflow，低置信回退大模型推理；调优 BM25 阈值，增加黑名单、冲突词规则，解决 BM25 误截胡问题。方案经导师 review 后落地。

- A2A 多智能体& MCP

1. 协作搭建 Orchestrator 调度器，根据意图向专家 Agent 派单；复杂分析、月报类任务支持多路扇出并行执行并合并结果，简单查询直接单任务执行；

2. 基于 FastMCP 封装 Power、Billing、Knowledge、Compute 四类专家，实现工具白名单管控；独立实现 Knowledge 模块全套 6 个工具，完成 A2A 客户端、专家服务、灰度桥、扇出结果合并逻辑；

Power/Billing/Compute 由另一名大模型同事负责，后端同事负责 MCP 服务接口与 Docker Compose 部署。

• **稳定性保障&兜底**

1. 协作落地三层容错机制：异常重试最多 2 次、策略降级、系统兜底；对写类操作禁止静默重试；Workflow 执行失败自动回退 RAG；后端同事负责 Redis/MySQL 接口对接；
2. 搭建双层记忆架构：Redis 存储短期会话对话；Milvus 存储跨会话摘要做长期记忆，缓解多轮指代歧义与上下文超长问题；前端同事负责 Vue 3 对话界面与 WS 工具进度展示。

项目成果

- 上线后日均咨询180+，覆盖 12 类查数/分析工作流
- 评测对比传统 RAG，综合答题得分提升22.9%；查数类 Workflow 题型得分由 38 分提升至 78-80 分；FAQ/BM25秒级，Workflow 3-7s，RAG 10s
- 意图 LoRA 模型验证集 / 测试集准确率 92% / 88%；高置信短路可覆盖 47% 请求，精确率≈1.0
- 故障注入测试全部 5 组异常场景系统不崩溃；长期记忆直测召回 100%，摘要压缩比 71.1%。

电力行业 RAG 智能问答系统 AI应用开发 2025-07 ~ 2025-11

技术栈

Python / FastAPI / Milvus / BGE-M3 / BGE-Reranker / DeepSeek / MySQL / Redis / LangChain

项目背景

电力数据采集公司日常运维中面临大量高频重复咨询（电费账单解读、异常告警排查、节电优化建议），传统人工客服响应慢、知识传递不一致。需要构建一套基于私有技术文档的智能问答系统。

核心职责

• **双路知识库建设**

1. 对电力技术手册、FAQ 做清洗结构化；FAQ 数据存入 MySQL，搭配 Redis 缓存与进程内 BM25 检索；文档侧使用 BGE-M3 生成稠密 + 稀疏向量存入 Milvus；方案经导师 review 后落地；
2. 实现父子块分块方案：子块用于召回，父块作为生成上下文输入；完成 800 条原始 FAQ 清洗、去重、筛选得到 400 条高质量语料。

• **RAG优化 & 自适应策略调度**

1. 实现 Milvus 稠密-稀疏加权混合检索，接入 BGE-Reranker 重排，支持重排开关用于成本控制；
2. 微调 BERT 区分通用 / 专业问题，专业问题在直接检索、HyDE、子查询、回溯策略之间自适应选择；四策略编排与生成 Prompt 由另一名大模型同事主责，本人参与联调。

• **闭环迭代质量保障**

1. 归集业务实测 Bad Case 构建 RAGAS 标准化回归测试集，开发自动化批量复测流程；
2. 与团队协作优化分块规则与检索权重：持续迭代优化分块规则、检索权重；业务约束 Prompt 由另一名大模型同事主责，后端同事负责接口与缓存层对接。规避版本迭代带来问答效果退化。

项目成果

- 内部上线后日均查询50+；语料覆盖电价规范、设备运维手册、告警/故障处置、营业与工单等文档
- 原先人工翻文档约20-30分钟缩至高频/概念问 秒级；完整 RAG 约十余秒
- 混合检索与精排链路，解决电力术语语义漂移导致召回不准的问题；RAGAS 忠实度 91.7%、上下文精确率 93.3%

基于 Dify 的电力运维智能问答系统 AI应用开发 2025-05 ~ 2025-06

技术栈

Dify / Chatflow / Rerank

项目背景

电力运维内部高频咨询依赖文档与FAQ，直接自研RAG链路周期时间长。为快速验证可行性，选用Dify低代码平台搭建Chatflow原型，以最低成本检验知识库问答能否覆盖日常咨询。

核心职责

- 协作配置 Chatflow 流程，导入规程文档与 FAQ 知识库；调整切片参数，开启重排优化召回效果；
- 组织内部试用，归集 150 条真实业务咨询样本，定位系统能力短板。

项目成果

- 原型对文档、FAQ 类常规咨询覆盖约 80%；业务数据查询类问题通过率为 0，推动后续自研RAG+Agent方案。

教育背景

河南城建学院 数据科学与大数据技术 (本科) 2022-09 ~ 2026-06