

许芳诚



AI Agent架构师 / 研发工程师

离职 3359205563@QQ.COM

19357544130 (微信: 18289872681) 杭州主城区

自我评价

2 年 AI Agent 架构与研发经验，**专注跨境电商场景的架构设计与工程落地。从运行时底座到上层业务应用逐层负责并线上验证**，Agent Loop、多语言 RAG、LLM 工程、SFT/DPO 微调与多模态检索均为生产环境实践；前端、服务端、数据与运维均可独立承接，带 10 人研发团队，与产品、运营高效对齐。深耕家具、家居、母婴品类跨境全链路业务（售前至售后），跑赚才算落地。**做事风格：只带 A、B、C 方案上桌供决策，不找借口、不讲理由。**

个人优势

Agent 核心技术

- Agent 运行时架构**：模型无关 Harness 底座设计、LLMProvider / Tool 双抽象、注册表模式、Loop Engine 自主决策循环、MCP 协议多 Agent 协作
- Agent 编排**：LangGraph 多阶段工作流、SubGraph 拆分、Checkpoint 持久化、astream_events 流式事件
- 多语言 RAG**：HNSW 混合检索、Int8 量化压缩、base-rerank / Cross-Encoder 精排、pgvector / Viking DB、多语种知识库
- 大模型工程**：LLM 网关与模型路由、Prefix Caching / KV Cache、TTFT 首字延迟压缩、Token 配额计量
- 模型微调**：QLoRA / LoRA、SFT 监督微调、DPO 偏好对齐、LLaMA-Factory、多语言微调
- 多模态**：三模态统一向量 (text/image/video)、OCR (RapidOCR) + VLM (qwen-vl)、ASR + LLM 视频摘要
- RTC 实时语音**：ASR 实时情感捕获、TTS 声音复刻、FEC 前向纠错、高丢包环境无感知恢复
- 数据工程**：全链路 ETL、9 级噪声过滤、三重脱敏引擎、多格式训练数据导出

全栈工程

- 前后端一体化**：React 19 交互界面、FFmpeg.wasm 浏览器内音视频处理、SSE / ReadableStream 流式渲染；Python / FastAPI 服务端、SQLAlchemy 2.0、PostgreSQL、asyncio 并发
- 云原生**：Docker 容器化、阿里云 Serverless (FC / SAE) 弹性部署、灰度发布与秒级回滚
- 稳定性与可观测**：LangSmith / structlog / request_id 全链路追踪、SlowAPI 限流熔断、健康检查与优雅关闭

工作经验

杭州陆遥科技有限公司

AI AGENT 架构师 / 研发工程师 • 2024/06 - 至今


公司主营家具、智能家居定制与母婴用品跨境出海，核心覆盖日本及东南亚市场，布局亚马逊、TikTok、SHEIN、Temu 等全球渠道。作为 AI Agent 架构师，负责 AI 技术在跨境电商全链路的架构设计与工程落地，从 0 到 1 搭建跨境 AI 能力体系。

- AI 系统架构建设：**主导搭建 DataBase 数据资产平台、AI Infra、Agent Runtime 引擎三大基础设施，支撑客服、内容生产、B 端生意等多业务 Agent 快速接入；负责 LLM 路由、向量检索、多模态、SFT+DPO 微调等技术选型与落地。
- AI 应用研发与业务价值：**主导多语种智能客服、直播切片、内容生产、素材库、B 端工作台等应用研发，覆盖需求到上线全链路；构建「多源采集 → DataBase 治理 → AI 消费 → 效果回流」飞轮，累计处理百万级日/越/泰语料，日常承接 3000+ 咨询、大促日 10000+，人工成本下降、转化率提升。
- 团队管理与跨部门协作：**带领 6 人左右研发团队（前后端 / 数据 / Agent），负责任务拆解、技术评审与人才培养；对接产品、运营、供应链、销售等部门推进需求与上线，确保技术落地与业务目标对齐。

项目架构

跨境 AI 生态系统架构图

数据驱动 · AI 赋能 · 业务闭环 · 持续进化



项目经历

项目一：Agent Runtime 引擎 —— Harness 解耦架构与自进化决策引擎

AI AGENT 架构师 / 核心研发 · 2024/07 - 至今

从零设计并实现模型无关、工具可插拔的 Agent 运行时底座，支撑家具/家居/母婴品类日/越/泰多语种 C 端客服售前导购与售后履约场景下的自主决策与话术迭代，**替代传统「规则+流程编排」的僵化范式。核心解决模型绑定深、工具扩展难、跨境售前售后话术迭代周期长三大工程痛点。**

- **Harness 解耦底座设计**：采用 LLMProvider + Tool 双抽象 + 注册表模式解耦模型、工具与决策引擎——新增模型仅需实现 chat() 适配器、新增业务能力（查库存物流、算优惠、退换货、商品推荐）仅需登记 Tool，核心循环零改动；tool_call/tool_result 协议与主流 Function Calling 同构，配置驱动支持离线 Mock 与生产热切换，跨模型迁移成本趋近于零。
- **Loop Engine 自主决策循环**：构建「观察问题 → 推理意图 → 选择工具/话术 → 执行 → 观察反馈 → 再决策 → 终止/转人工」闭环，决策权交给模型、意图识别隐式融入工具选择，移除独立分类模块；支持单步多工具并行（同时查库存、算运费、推商品并调取售后政策），工具异常转为 observation 由模型自主纠错而非中断，提升售前售后复杂场景应变能力。
- **运行护栏与兜底机制**：内置最大对话轮次 + 执行超时双重护栏，高风险动作（报价、退款、赔付承诺）自动触发二次确认，超过运行边界自动转人工兜底，保障 C 端营销客服 7×24 小时服务稳定性与合规性。
- **对话式教学与话术自进化**：业务专家通过「买家问题 + 金牌售前/售后回答 + 策略说明」对话式录入，LLM 自动归纳营销策略注入系统提示词，修改即时生效无需重新发版。服务时通过向量 Top-K 召回历史优质 C 端话术样本做语义参考，支持买家换问法/相似意图自动命中，答不上自动转人工，主管点评式纠偏可一键固化为新话术。
- **提示词分层治理**：设计「业务铁律 > 营销策略 > 召回话术」三层提示词架构，将不能泄露进货价、不能超平台规则承诺等合规要求置于最高优先级，适配日本、东南亚多市场合规要求。
- **上下文工程**：以「预算账户」而非「容器」模型管理上下文窗口，追求信噪比最大化、规避 context rot：工具调用噪声剥离、营销策略语义压缩、历史对话按需检索三重管理，分层压缩 + 关键客户事实外部存储双写兜底，长对话保持决策清晰。

项目二：AI Infra 智能基础设施平台 —— 智能体能力即插即用、SDD 产研高效协同

AI AGENT 架构师 / 核心研发 • 2024/10 - 至今

面向多品类跨境出海的 AI 规模化落地，主导设计并落地五层治理架构：将 N×M 混乱直连分解为供应商、网关、能力、质量、协议五道清晰分层，让新业务接入告别重复造轮子；并将“验证左移”方法论注入 AI 研发，构建人机协作工程飞轮。

- **L1-L2 供应商治理与统一网关**：确立全量云端 API、不自建 GPU 的供应商路线，归档能力代差与调用量盈亏两条失效条件；密钥全量收编至统一密钥库，业务侧只持虚拟凭证。网关将 N 个业务方对 M 家供应商的两两直连收敛为 N→1→M 单层收口，以逻辑模型名解耦两侧，模型切换仅改一行路由配置、业务零改造；配套三级配额、RPM/月度双限与三连失败自动熔断切主备，网关额外开销毫秒级。
- **L3 共享能力层**：把知识库、工具调用、用户长期记忆、任务编排沉淀为四大共享服务，业务线只写自己的业务逻辑、不再各自重建一套：知识库按业务线与角色隔离、过期内容自动退役，避免过时的物流政策继续误导买家；工具统一按风险分级（R1/R2/R3），业务可自助接入但执行权始终在平台侧，越权动作一律拦下；用户长期记忆沉淀买家偏好与历史，让每个 Agent 都「认识」同一个买家，并支持按买家一键删除、出具合规报告；长任务中途可接续、重复提交不会造成重复扣款，规避资损与客诉
- **L4 质量护栏**：把评测集当资产管理，建立知识、模型、Agent 三层评测，提示词或模型任何变更先自动回归再上线——一次降本换模中，正是评测发现总均分只跌 3 分、投诉安抚却跌 12 分，据此按场景分流，平台侧整体调用成本降低约 30% 且核心质量持平；沿请求链路设置输入、检索、执行、输出四道强制护栏，业务无法绕过，误拦率 < 0.1%
- **L5 协议层**：统一对接标准——Agent 和系统各接一次即可互通，不必两两对接，N×M 次降到 N+M 次。
 - **MCP** 用于对接 ERP/OMS/WMS/物流等企业系统——各系统 Owner 自建 Server 并自维护，一次接入、所有 Agent 共享，对接从 3 周压到 3 天；

- **A2A** 用于跨 Agent 协作，如客服 Agent 直接委托物流 Agent 查件——能力名片声明可被调用的能力，有状态任务支持长任务查询与续跑，身份链两跳校验防跨团队越权；
- **AG-UI** 用于人机交互——双向事件流把长任务的中间状态实时推给前端，进度可见、可随时打断纠偏；
- **A2UI** 用于动态生成「安装预约」「补发登记」等业务表单——Agent 只输出白名单约束下的结构描述、不写代码，前端按白名单渲染，新增表单免前端排期。
- **SDD 研发驱动**：作为研发负责人，我从 0 到 1 创立并在团队推行这套 AI 研发流程，把人机协作拆成上下文、意图、执行、门禁四层。
 - **上下文层** 上下文即代码：研发约定与禁区写进 AGENTS.md / .cursor/rules、SOP 封装为 Skills，与代码同仓同版本、走 PR 演进；上下文的读者从「新员工」变成「每个 Agent 会话」，因此坚持人工维护、不自动生成；
 - **意图层** Spec 驱动开发：确立 Propose → Apply → Verify → Archive，评审对象从代码前移到 Spec，Spec 与实现同 PR 合入（人审意图与架构、AI 校验实现一致性），归档 Spec 增量沉淀为活规范库；
 - **执行层** 并行编队：单人多任务用 git worktree 物理隔离、互不覆盖；**多人并行靠三道防线——独立性检查 Skill 读代码仓库与两份 Spec 出可行性报告（文件互斥 / 接口稳定 / 范围有界），判定不合适即改串行，AGENTS.md 公共内容改动触发人审**，剩余冲突合并时人工解决；主干走 Trunk-Based 短分支、每日合入；
 - **门禁层** 三层校验：提交需过人审 Spec、AI Reviewer 初审、自动化门禁全绿三层分工；质量上推行 Evals-as-Test——prompt、评测集、脚本全部进 git，改 prompt 必跑回归，与 L4 共用评估底座。

项目三：多语种智能营销客服 —— RAG 与微调驱动的 C 端售前售后一体化系统

AI AGENT 架构师 / 核心研发 • 2024/07 - 至今

主导多语种营销客服从 0 到 1，构建 RAG + 微调 + 实时语音三位一体的智能客服，用买家母语覆盖日、越、泰市场，承接四大平台及独立站 WhatsApp、Telegram、LINE 的售前导购、订单转化与售后履约全链路，**多店铺多平台会话聚合。日常承接 3000+ 咨询、大促日服务 10000+。**

- **多语言 RAG 知识库**：基于优质 C 端对话构建日/越/泰知识库，标识符切片避免语义截断；**HNSW 混合检索 + Int8 量化（存储降 75%）+ base-rerank 精排（检索提速 4 倍），安装步骤、材质认证、物流时效、A-to-Z 索赔等高频问题秒级命中；**
- **响应速度优化**：固定片段排序、合并 System Prompt 触发 Prefix Caching / KV Cache，TTFT 从 15s 压至 2s 内；
- **SFT + DPO 两阶段微调**：以火山方舟为平台、豆包为基座做 LoRA 微调——**金牌客服售前转化与售后安抚对话做 SFT，「成单 vs 流失」「投诉化解 vs 升级」做 DPO 偏好对齐，风格一致性盲评从 2.2 提升至 4.8；选 DPO 跳过奖励模型，有限数据下更稳，云端精调免自建 GPU。**
- **售前售后工具调用**：Tool 注册机制对接 ERP/OMS/WMS——售前查库存、汇率换算、关税消费税与运费试算、关联推荐，售后查订单物流、发起退换货 / 补发 / 安装预约；执行按 R1/R2/R3 分级：查询直执行、写操作带幂等键防重复、退款赔付强制二次确认或转人工。
- **多平台聚合与本地化合规**：各平台与独立站社媒会话聚合到同一工作台，日/越/泰与中文双向实时翻译，按市场时区切换保障 24 小时回复时效；**平台规则写入提示词铁律与输出护栏（禁站外引流、禁私留联系方式、承诺不越红线）**；并承接邀评、差评预警挽回、弃购催付，投诉实时转人工。
- **实时语音与多模态应答**：ASR 捕获情绪 + TTS 声音复刻，FEC 前向纠错 + Jitter Buffer 在约 30% 丢包下自动降级、通话不中断；**接入素材资产库按「文字 + 商品图 ≤3 + 演示视频 ≤1」混排**，售前配场景图与认

证、售后定位安装视频锚点，日本重认证、东南亚重视频。

- **业务效果与闭环**：咨询转化率提升约 30%，**替代约 60% 人工客服、年节省人力成本约 50 万美金，售后首次解决率提升、投诉升级率下降，带动 GMV 增长约 200 万美金**；对话回流 DataBase 成为微调语料与画像源头，形成「DataBase 治理 → SFT+DPO 微调 → 客服上线 → 对话回流」闭环。

项目四：跨境内容生产平台 —— LangGraph 编排的素材与直播切片流水线

AI AGENT 架构师 / 核心研发 • 2024/10 - 至今

负责商品图文生成、**TikTok 直播切片与智能上品三条产品线，为 TikTok、小红书、Ins、SHEIN、Temu 持续产出日/越/泰多语种素材**，解决纯人工产能跟不上、纯 AI 批量生成质量不可控、上什么品靠运营拍脑袋的问题。

- **上品策略 Agent**：对接 DataBase 实时看板，自动汇总竞对上新、平台热点、品类单价、优惠力度等指标，结合公司主推方向与库存情况，批量生成上品策略并分发给产品运营。
 - **数据输入**：竞对上新、平台热点、品类单价区间、优惠力度、库存水位
 - **策略输出**：推什么品、切什么卖点、配什么优惠、上哪个渠道
 - **人工审核**：运营批量通过、单品微调或驳回，采纳后经 MCP 工具层调平台 OpenAPI 一键下发上品
 - **进入生产**：过审商品进入素材流水线，优先 AI 批量生成多语种图文素材
- **监控预警 Agent**：持续追踪已上架商品的表现数据，自动发现问题并生成整改建议，推给对应运营处理，确认后回传策略 Agent 执行新一轮调整。
 - **监控维度**：点击率、转化率、差评率、投诉量、库存风险、合规红线
 - **自动处置**：触及安全合规或平台规则红线的商品立即自动下架，触发自动化整改
 - **整改建议**：效果类问题生成换卖点、改素材、调优惠、暂停推流等建议，人工确认后回传上品策略 Agent
- **LangGraph 批量生成与人在环**：过审商品由 AI 批量并发生成日/越/泰三语文案与素材，运营只在结果上审核把关；以 LangGraph 编排为可控工作流——SubGraph 将选题规划、本地化文案、配图与视频生成拆为独立编排单元，PostgreSQL Checkpointer 持久化状态，任意节点可回滚与增量重试；结果不满意时提供三档纠错——出图 / 出视频最多 3 次单独重生成、回退到指定节点重跑、从首节点重跑整条，AI 保产能、人把质量关。
- **流式生成体验优化**：集成 LangGraph astream_events 监听 on_chat_model_stream 捕获 Token 级实时流，前端 ReadableStream 逐字渲染，感知 TTFT 降低 60%。
- **多模型动态路由**：标题、卖点等简单任务路由轻量模型，长描述与品牌文案路由旗舰模型，with_structured_output + Pydantic Schema 强约束结构化输出，推理成本降低 40%。
- **多平台并发生成**：asyncio.gather + run_in_executor 并发生成多语种多平台素材，指数退避重试应对下游抖动，耗时缩减 70%，一套商品资料 10 分钟输出日/越/泰/英四平台版本。
- **直播切片端到端**：「上传 → 转写 → 精彩片段识别 → 文案生成 → 切片导出」全流程自动化，后端 FastAPI + Groq Whisper 转写、DeepSeek 摘要，自动识别产品演示、下单引导、买家答疑等高光点并配文案；6 小时超长直播按约 6000 Token 分批 + 双向重叠去重，跨片段不遗漏。
- **端侧转码降本**：针对 2.5GB 录像上传慢、转码贵的痛点，前端 React 19 + FFmpeg.wasm 浏览器内转码（WORKERFS 零拷贝挂载，输出 16kHz / 单声道 / 64kbps MP3），压至约 30MB 再上传，体积降低 99%，等待从分钟级降到秒级。

- **任务队列与进度可观测**：基于 PostgreSQL 实现轻量任务队列，Task Runner 后台协程串行抢占、崩溃自动重置；SSE 读库推送进度、数据库为唯一进度源，断线可续、多端一致；配套限流、熔断降级与健康检查。
- **生成即沉淀**：素材自动写入全品类素材资产库并打好标签，供 C 端客服 RAG 检索与 B 端工作台随单调用，形成「内容生产 → 资产沉淀 → 客服 / 销售 / 运营复用」闭环；素材生产一次、全公司复用，产出效率提升约 10 倍，带动 GMV 增长约 100 万美金。

项目五：全品类素材资产库 & B 端智能生意工作台 —— 三模态资产与业务系统对话式协同

AI AGENT 架构师 / 核心研发 • 2024/09 - 至今

构建两大赋能系统：素材资产库统一管理商品图、场景图、安装视频、直播切片与营销文案，提供跨模态检索；B 端工作台面向销售、供应链、门店运营、产品运营四类角色，同一入口按角色呈现不同能力，打通各业务系统，集对话式作业、经营看板、批发获客与销售考核于一体，让一线人员“问一句就能查货、做单、跟单、算账”。

- **三模态统一检索**：文字（标题/描述/FAQ）、图片、视频共用 rag_assets 表（pgvector 1024 维 + HNSW），一条 SQL 跨品类跨模态召回；向量化 retrieval text（标题/描述/标签/口播/OCR 拼接）而非媒体文件本身，与买家咨询、B 端提问天然对齐。长视频按 ASR 时间戳分段入库、media_url 带 #t= 锚点直达对应步骤；应答按「文字必发、商品图 ≤3、演示视频 ≤1」智能混排，隐私红线内容自动返回打码版 URL。
- **双路召回增强**：家具尺寸材质、母婴认证等核心标签由人工维护、保证基础召回；离线经 OCR（RapidOCR）识别说明书、VLM（qwen-vl）补全产品细节、ASR + LLM 提取直播口播卖点，重写 retrieval_text 后召回相似度从 0.38 提升至 0.71；按 (source_table, source_id) UPSERT 幂等写入，素材可反复回扫更新。
- **分角色对话式作业**：经 MCP 工具层对接 ERP、OMS、CRM、WMS、TMS/海外仓、卖家后台、广告与财务系统，自然语言即可查库存报价、跟订单物流、看广告 ROI、核账单扣费；模型只出意图、执行权始终在平台侧——查询类直执行，下单/改价/建工单等写操作注入幂等键，退款/政策特批强制挂起主管确认；操作表单由 Agent 按白名单动态生成，新业务表单不占前端排期。
- **经营看板**：工作台内嵌经营看板，数据经 DataBase 统一接入、实时流分钟级更新，展示各渠道上品表现、点击转化、库存水位与差评舆情；按角色 ACL 过滤可见范围。
- **B 端批发获客客服**：承接独立站/App 企业买家与分销商询盘，技术底座与 C 端客服同源（多语言 RAG、微调话术、多模态混排），定位商机获取而非即时成交——多轮识别目标市场、经营品类与采购量级，按需输出供应链优势、品类目录与合作案例；识别批发意向或高价值客户后路由至对应销售经理，CRM 建档并回写画像与会话纪要，线索不依赖人工盯盘。
- **销售培训与考核**：产品参数、认证、安装维护、物流政策、拿货规则与金牌话术沉淀为分层培训知识，支持随岗问答与 **AI 模拟客户对练**；设试用期/月度/季度/年度四类考核，**AI 按产品专业度、需求把握、销售策略、本地化表达、合规红线** 自动出题评分、主管复核计入结果，高频错题回流培训重点，形成「培训 → 对练 → 考核 → 补强」闭环。
- **素材联动与按角色分权**：报价、做方案、回复客户时自动带出商品图、安装视频与多语种营销文案，一键转发；按角色裁剪工具与数据权限——销售见客户与报价、供应链见采购与库存、门店见发货与安装、产品运营见数据与看板，ACL 按 user groups 过滤、无权返回 denied。
- **数据回流与双向赋能**：工作台查询、操作、获客会话与对练数据沉淀回 DataBase，C 端优质话术回流 B 端对练语料，素材库同时供 C 端客服与内容生产复用，形成「素材资产 → B 端经营 / C 端服务 → 数据回

流 → 资产迭代」闭环；四类角色在同一入口办完原本跨 5-6 个系统的事，步骤压缩约 80%、单笔从 15 分钟降到 1 分钟内，新人独立上岗从 2 周缩短到 4 天。

项目六：DataBase 数据资产平台 —— 跨境多源数据治理与训练飞轮

AI AGENT 架构师 / 核心研发 • 2024/10 - 至今

DataBase 是跨境 AI 体系的数据底座：统一接入四大平台、ERP/OMS/CRM/WMS/TMS 等业务系统及广告舆情数据，经清洗、脱敏、标注加工为可训练、可检索、可分发的数据资产，双向供给 AI 应用与存量业务系统，并沉淀用户画像回流 Agent 记忆与推荐系统，驱动数据飞轮。

- **多源采集与治理流水线**：搭建「多平台采集 → 清洗治理 → 质检审核 → 多下游供给」流水线，通过平台 OpenAPI + 爬虫接入亚马逊、TikTok 客服数据，并汇聚独立站与 WhatsApp / Telegram / LINE 私域对话，以 CDC/定时同步/适配层对接 ERP/OMS/CRM/WMS/TMS 等业务系统，并纳入广告投放、Review 与社媒舆情数据，支撑百万级日增量处理。9 级噪声过滤丢弃广告、系统通知等无效数据；买家隐私信息正则脱敏，进货价、佣金率设为硬红线并做清洗/写入/导出三重脱敏；LLM 自动完成意图分类、质量分、优质 Q&A 提取等预标注，经运营主管人工审核后入可信数据源。
- **业务系统融合互通**：治理后的商品、库存、订单、知识数据通过 API + 消息队列回写 ERP/CRM/WMS 与客服系统，AI 侧产生的工单、客户标签、质检结果同步回写，存量系统无需改造即可“用上 AI”；接口老旧或无 API 的系统以适配层 + 增量同步隔离差异，新老应用共用同一份可信数据源。
- **标签体系与实时看板**：沉淀商品、客户、会话三类标签，分别覆盖品类材质认证、画像生命周期价值分层、意图质量风险等维度，供客服、推荐、工作台、广告投放复用；基于 CDC 实时流构建大促与经营看板，咨询量、转化率、库存预警、差评舆情分钟级更新，看板实时指标同时作为推荐 Agent 与推流上品 Agent 的在线决策依据；数据按店铺/角色做多租户隔离与分级分类管理，满足跨境数据出境合规。
- **画像驱动服务与复购**：融合对话、订单、浏览、售后数据构建多语种用户画像（品类偏好、价格带、语言市场、生命周期）；画像结构化后回流 L3 记忆服务——客服开场即知买家背景，主动说出「您上次看的婴儿床已经出新色了」；同步推荐系统生成个性化话术与商品组合，驱动复购与关联销售；
- **多格式供给与飞轮闭环**：审核数据按需分发——JSONL 供客服 SFT+DPO 微调、CSV 写入 RAG 知识库、问答对供 B 端工作台对练，Embedding 写入向量库并提炼为结构化知识文档；直播切片、素材资产、售前售后对话、B 端工作台数据持续回流，画像随交互迭代反哺记忆与推荐，形成「采集 → 治理 → AI 与业务系统消费 → 画像与效果回流」的螺旋飞轮。

教育经历

琼台师范学院

本科 IN 计算机科学与技术 • 2021/09 - 2025/06 • GPA: 前 20%