

谢 平

姓 名：谢 平
籍 贯：四川眉山
年 龄：24

联系方式：15520955863（微信同号）
邮 箱：xp1937634927@163.com
工作年限：3 年



专业技能

- 1、熟练掌握 LangChain、LangGraph Agent 编排框架，熟悉 StateGraph 状态编排、ReAct Agent 实现、interrupt 人工确认机制；对 OpenClaw 等多智能体编排框架有调研了解。
- 2、熟练掌握 Milvus、Chroma 向量数据库，熟悉 Dense/Sparse 混合检索与 BGE-Reranker 重排序链路，可搭建带部门权限隔离的企业级 RAG 检索增强生成系统，支撑 Agent 应用。
- 3、熟悉 MCP 工具协议，掌握 Streamable HTTP 与 SSE 通信机制，能够自定义 FunctionToolAgent，完成工具封装、权限管控与业务系统对接。
- 4、熟练掌握 Dify、Coze 低代码平台，可完成 RAG 知识库构建、Agent 工作流编排与业务应用定制化开发。
- 5、熟练掌握 Prompt 工程、输出解析器 OutputParser、Chains 组件开发，熟悉模板优先、温度控制等防幻觉策略，具备网络运维类行业 Agent 完整项目落地经验。
- 6、了解 LoRA、p-tuning 等参数高效微调与模型压缩技术，项目实战落地 LoRA、QLoRA；具备 BERT 意图分类微调实战经验，能够结合 RagAS 完成大模型与 Agent 应用效果评估与 Bad Case 迭代优化。
- 7、熟练掌握 vLLM 私有化推理部署，可完成 Qwen2.5 等开源模型内网落地，实现 OpenAI 兼容接口对接，适配隔离内网 Agent 工程化场景。
- 8、熟悉 PyTorch 深度学习框架与 BERT、Transformer 等主流模型，具备深度学习模型训练与微调实践；了解 CNN、RNN、LSTM 网络结构以及逻辑回归、K-Means、XGBoost 等机器学习算法原理。
- 9、熟悉 Claude Code、Codex 等 AI 编程助手，能够借助工具高效开展 Agent 应用代码编写、调试与重构工作。

工作经历

- | 2024.09 - 2026.08 | 上海蕊云电子科技有限公司 | AI 大模型开发工程师 |
|--|--------------|-------------|
| <ol style="list-style-type: none">1、负责私有化 AI Agent 与 RAG 系统后端开发，基于 LangChain/LangGraph 完成智能体状态编排，实现 interrupt 人工审批、异常降级能力，落地多智能体网络排障 Agent、智能财务报销 Agent 两类行业智能体。2、搭建双通道企业 RAG 知识库问答系统，实现部门级权限隔离，通过混合检索、重排优化检索精度，支撑企业内部文档问答业务。3、基于 vLLM 完成 Qwen2.5 等开源模型内网私有化部署，封装安全代理层实现设备凭据托管、命令白名单、全链路审计，满足隔离内网项目交付。4、开展模型微调工作，完成 BERT 意图分类微调 (F1=93%)、大模型 QLoRA 领域微调，优化意图识别与领域问答效果。5、引入 RagAS 建立自动化评估体系，收集线上 Bad Case 持续迭代 Prompt、检索策略与数据集，降低幻觉、提升系统稳定性。6、基于 FastAPI+Docker 完成整套系统容器化交付，面向工厂客户完成项目私有化落地，处理上线后的各类业务适配与问题调优。 | | |
| 2023.09 - 2024.08 | 达观数据有限公司 | NLP 算法工程师 |
| <ol style="list-style-type: none">1、负责达观数据 IDP（智能文档处理）平台与“曹植”垂直大模型的训练语料生产，人工精细化标注银行电汇申请书、可行性研究报告、财务报表、采购合同等通用文档。2、设计各类文档的标签体系（“汇款人名称”、“合同金额”、“审计意见”等）与标注规范，保障标注质量与一致性。3、标注完成后参与模型训练与评估，跟踪准确率、召回率指标；测试模型生成结果，记录误读问题并反馈研发团队迭代优化。 | | |

项目经历

- 项目一：多智能体协同网络故障排障 Agent（客户定制·私有化交付）** 2026.01 - 2026.07
- 项目背景：**针对客户工厂网络故障排查依赖资深工程师经验、人工逐设备取证与交叉验证耗时极长、经验无法沉淀复用等痛点。本项目基于多智能体协同架构搭建了「编排大脑 + 多执行 Worker」AI 排障体系：由 AI 动态编排排查流程，实现故障自动取证、交叉验证、拓扑溯源、根因收敛与知识沉淀闭环，全程可视化、人在回路可控；整体内网私有化部署，适配客户工厂生产内网隔离公网要求。

技术栈: LangGraph (多智能体编排 + interrupt 人工确认) | LangChain | vLLM + Qwen2.5-14B (私有化推理 + AWQ 4bit 量化) | Milvus + BGE-M3 + BGE-Reranker | Ansible-Runner / Netmiko | BERT (故障意图识别微调) | FastAPI | WebSocket/SSE (可视化看板) | Docker

项目架构: 编排大脑 Core Agent (故障意图解析→任务调度→数据取证→交叉验证→根因推理→知识沉淀, 条件路由动态编排) → 按需调度 Worker Agents (数据采集/日志分析/拓扑溯源/合规校验, 经安全代理只读取证) → 排障看板 (SSE/WebSocket 实时推送推理过程/执行进度/取证链路) → 知识沉淀闭环 (新规则与案例经人工确认后入库, 人在回路)。

个人角色与职责:

- 1、主导设计「Core 编排大脑 + 多 Worker 执行智能体」协同框架: 拆解故障意图解析、任务调度、数据取证、交叉验证、根因推理、知识沉淀六大节点, 条件路由实现动态排障流程编排, 摒弃固定规则树。
- 2、实现编排大脑 Core Agent: 完成故障语义解析、排查路径动态决策、多源数据交叉验证、故障等级分级与事实/疑点分层输出。
- 3、实现人在回路可控机制: 高危故障判定、新规则入库、结论输出三处设 interrupt 人工审核节点, 保障 AI 决策可控。
- 4、参与 Worker 编排与知识闭环设计: 配合完成多 Worker 的 Agent 编排逻辑, 参与排障规则与案例的沉淀闭环 (经人工确认后入库)。
- 5、参与私有化落地与看板联调: 配合 vLLM 量化离线部署与排障看板, 排障全流程透明可追溯。

项目成果: 构建对标行业方案的多智能体排障体系, 模拟工程师式排查逻辑, 实现「定位设备-多点取证-交叉验证-拓扑溯源-根因收敛」全流程自动化, 可适配未知复合型故障; 排障全程可视化透明化, 看板实时展示推理过程与取证链路; 故障定位由小时级缩短至分钟级, 降低 80% 以上人工重复取证与日志筛查工作量; 排障经验自动沉淀, 知识库持续增长; 全量数据本地留存, 满足政企等保与数据不出厂要求。

项目二: 智能财务 Agent

2025.07 - 2025.12

项目背景: 针对中小企业财务报销流程繁琐 (纸质/Excel 填单、人工核对发票、审批跟踪耗时)、财务重复性劳动多的痛点, 设计并实现了一款轻量化智能财务报销 Agent。系统将报销功能嵌入企业微信/钉钉内部功能模块, 员工直接以企业身份使用、免额外注册登录, 一句话发起报销、上传发票, 由 Agent 自动完成发票识别验真、预算/标准校验、审批流转、凭证生成与进度通知, 替代人工填单与核对, 实现报销全流程自动化, 平衡功能完整性与落地轻量化。

技术栈: LangChain / LangGraph | 大模型 API (DeepSeek / 通义千问) | 发票 OCR API (合合信息) | 发票验真 API | 企业微信 / 钉钉内部应用接入 (免登鉴权) | FastAPI | 现有 ERP 对接 (API / RPA) | PostgreSQL

项目架构: ① 用户交互层: 嵌入企业微信/钉钉内部功能模块 (员工以企业身份免登录使用) → ② 智能处理层: 意图识别 (LLM) → 发票 OCR+验真 → 规则校验 (预算/标准) → 审批流管理 (2-3 级) → 凭证自动生成 → 进度通知 → ③ 数据与系统层: 现有 ERP/财务系统 (API 对接) / 历史报销库 / 公司制度库

个人角色与职责:

- 1、设计轻量化财务 Agent 整体架构: 三层结构 (企业微信/钉钉交互层 / 智能处理层 / 数据与系统层)。
- 2、实现一句话报销: 将报销功能嵌入企业微信/钉钉内部功能模块, 员工免登录以企业身份发起自然语言报销, LLM 意图解析 (出差类型、费用明细、关联事前申请), 自动反馈补件提示。
- 3、对接发票 OCR 与验真 API: 上传发票照片/PDF 自动提取金额、税号、抬头, 自动核验真伪、排查重复报销。
- 4、实现预算/标准自动校验与审批流: 报销时自动比对预算余额和费用标准, 自动发起审批 (2-3 级), 超时自动催办。
- 5、实现凭证自动生成与进度通知: 审批通过后自动生成记账凭证对接财务系统, 通过企业微信/钉钉推送审批与到账状态。
- 6、完成系统部署落地: 对接公司现有财务/ERP 系统, 完成报销全流程联调上线, 处理上线后的业务适配与问题调优。

项目成果: 报销流程由平均 2-3 天缩短至分钟级; 财务处理效率提升约 50%; 发票验真/查重有效防控税务风险; 员工免额外注册登录、以企业身份直接使用, 审批与到账进度实时推送、减少人工咨询; API 调用月成本可控 (约 ¥500-2,000); MVP 4-6 周落地。

项目三: 企业内部知识库智能问答系统

2024.10 - 2025.6

项目背景: 本项目面向本部员工规模 200- 300 人, 针对企业内部文档分散、员工检索效率低、部门数据权限难管控等痛点, 本项目设计并实现了一款面向企业内部的知识库智能问答 Agent。系统将工程手册、财务制度、人事流程等多部门资料统一沉淀为可检索的知识库, 员工通过自然语言提问即可快速获取精准、可信、有原文依据的答案, 并实现公共资料全员可见、部门资料仅本部门可查的分级权限管控。帮助员工高效解决日常查询难题、缩短知识查找路径, 同时有效规避越权访问风险, 赋能企业信息化团队。

技术栈: LangChain | Milvus (分级隔离) | BGE- M3 (混合检索) + BGE- Reranker | MySQL + BM25 | Redis | BERT (意图识别) | PaddleOCR | DeepSeek | RagAS | FastAPI + JWT (分级权限) | Docker

项目架构: 双通道检索 (MySQL+BM25 结构化 FAQ / Milvus 向量) → BGE- M3 混合检索 → BGE- Reranker 重排 → LLM 生成带引用; 检索层强制部门过滤 (JWT 分级权限: 公共或本部门); BERT 意图识别路由。

个人角色与职责:

- 1、构建企业分级知识库: 划分公共区 (员工手册 / 报销 / 考勤等全员资料) 与部门区 (工程 / 财务 / 人事 / 市场 / 行政 / 采购), 清洗多格式文档 (Word/PDF/ 扫描件 PaddleOCR), 按 “可见性 + 部门→类型→主题” 分层索引, 结构优先切分 + 命令块保护 (父块 800 / 子块 250)。
- 2、实现分级权限隔离: 知识打标签区分 “公共 / 部门”, 公共资料全员可见、部门资料仅本部门可查; JWT 携带权限维度, 检索层强制拼接过滤条件 (公共或本部门), 即使诱导查询也返回空, 杜绝越权访问。
- 3、搭建混合检索链路: BGE- M3 生成稠密 + 稀疏向量写入 Milvus, 按部门分区与标量过滤, WeightedRanker 加权融合召回, BGE- Reranker 对 Top- K 重排提升精度。
- 4、微调 BERT 意图分类模型 (F1 93%), 实现 “通用闲聊直答 / 专业咨询检索” 双路由分流; 实现 HyDE、子查询、回溯等检索策略按复杂度动态路由。
- 5、融合 MySQL+BM25 结构化 FAQ (阈值 0.85) 优先命中直接应答, 答案强制带原文引用; FastAPI + WebSocket 流式接口, Redis 缓存热点问答, RagAS 量化评估 (忠实度 / 相关性均 ≥0.90) 并持续调优。

项目成果: 服务企业 200- 300 名内部员工; 意图识别 F1 达 93%; 检索找到率从关键词搜索的 40% 提升至 85%+, 自动应答率超 80%, 人工答疑压力降低约 50%; 上线实测跨部门检索全部返回空、无越权访问; 查制度 / 手册 / 报表由分钟级缩短至秒级。

项目四：基于 NLP 的 OCR 智能结构化抽取与后处理优化

2023.10 - 2024.08

项目背景: 达观数据 IDP 平台服务于金融、制造、物流等行业的文档自动化处理。实际落地中, OCR 对模糊/倾斜/低质量文档识别准确率仅约 85%, 财务数据、专有名词的识别误差导致信贷审核、合规审查需大量人工校验; 同一份文档需抽取 20+ 类实体且存在长距离依赖, 人工处理单份平均耗时 15 分钟; 新客户标注样本稀缺, 传统方案下单个新客户文档类型的模型训练周期长达 4 周。基于此启动 NLP 后处理优化, 目标是通过 NLP 算法提升 OCR 精度与结构化抽取效率。

技术栈: Python | PyTorch | BERT / RoBERTa / LayoutLM | BiLSTM-CRF | Global Pointer | 依存句法分析 | Few-shot Prompting | 达观 IDP/OCR 平台

项目架构: ① 数据层 (OCR 文本 + 版面坐标 + 2 万+份标注语料) → ② 算法层 (BERT MLM 语义纠错 → Global Pointer/BiLSTM-CRF 实体抽取 → 依存句法关系抽取 → LayoutLM 多模态理解) → ③ 输出层 (结构化 JSON/Excel → RPA 自动填表 / 业务系统对接)

个人角色与职责:

- 1、参与设计 OCR+NLP 融合的文档结构化 Pipeline, 承担 NLP 后处理模块的开发与优化。
- 2、实现 OCR 语义纠错模块: 基于 BERT 掩码语言建模对误识别的财务数据、专有名词做上下文推理与字符预测, 关键字段准确率从 85% 提升至 96%+。
- 3、参与文档级多实体联合抽取模型训练与调优: 采用 Global Pointer / Span-based 方案抽取 20+ 类实体 (汇款人/账号/金额/合同金额/付款节点等), 解决嵌套实体与跨段落实体依赖问题, F1 达 92.3%。
- 4、负责实体关系抽取与小样本适配: 通过依存句法分析识别实体间语义关系 (“合同金额→500 万元”等); 基于 Few-shot Prompting 与迁移学习, 将新场景冷启动周期从 4 周压缩至 1 周。
- 5、完成 LayoutLM 多模态文档理解模型部署与验证, 优化跨页表格、复杂版式结构化效果; 建立 “标注-训练-测试-优化” 闭环, 定期整理 badcase 反馈标注团队。

项目成果: 核心实体抽取 F1 达 92.3%、关键字段纠错准确率 96%+; 单份文档处理从人工 15 分钟缩短至 3 秒以内; 覆盖文档类型从 12 种扩展至 30+ 种, 支撑银行信贷审核、投行文书质控、合规审查等 30+ 业务场景; 新场景冷启动周期从 4 周压缩至 1 周, 显著降低客户标注成本。

教育背景

2020.10 - 2024.06

学 校: 成都理工大学工程技术学院

专业: 电子科学与技术

学历: 本科

个人评价

- 1、具备完整 AI 大模型应用开发实战经验, 深耕私有化 Agent 与企业级 RAG 系统, 熟练使用 LangChain/LangGraph 完成智能体编排落地, 擅长隔离内网环境下大模型工程化交付。
- 2、具备网络运维行业 Agent 落地经验, 能够从业务痛点出发完成流程设计、安全管控、异常降级、审计留痕等生产能力设计, 有效解决大模型幻觉、意图识别、工具调用稳定性等工程问题。
- 3、熟悉非结构化文档处理、向量检索体系、模型微调与自动化评估, 能够独立完成从知识库构建、Agent 开发到容器化私有化交付全流程。