

谭健

26岁 | 杭州 | 大模型/智能体开发 | 3年经验 | 随时到岗 | 面议 | 13867115384 |
13867115384@163.com | 杭州电子科技大学信息工程学院 (23届/计算机科学与技术/学信网可查)

专业技能

大模型应用开发: 熟练掌握 RAG 系统全流程架构与落地, 涵盖多格式文档解析、敏感信息脱敏、文本分块优化, 基于 BGE-M3 实现语义检索 + BM25 混合检索, 掌握 LLaMA Factory LoRA 轻量化微调, 适配下游任务并提升准确率 15%。

智能体 (Agent) 开发: 熟练基于 LangGraph/LangChain 构建生产级 Agent, 掌握状态管理、节点编排, 实践 Supervisor 多智能体协同架构, 熟练运用 ReAct 推理范式与工具调用, 设计熔断降级等策略保障高并发场景稳定性。

模型与工具栈: 熟练使用 Qwen2.5、BGE-M3 等模型选型调参, 掌握 Function Calling 等交互机制; 熟练部署调优 Milvus/FAISS 向量数据库, 了解模型压缩技术, 熟练使用 Ollama 实现本地高效部署推理。

工程化与部署: 熟练使用 FastAPI 构建高性能 API 服务, 基于 Docker 实现容器化部署, 结合 Nginx 实现反向代理与负载均衡; 搭建 Jenkins CI/CD 流水线, 具备 Redis 缓存、异步任务处理、集群负载均衡经验, 支撑高并发场景。

Python 开发与编程能力: 熟练使用 Python 进行全栈开发, 熟练运用装饰器、异步编程、并发编程等特性; 熟练使用 Numpy、Pandas 进行数据清洗与处理, Matplotlib/Seaborn 完成数据可视化; 掌握各类开发与接口调试工具, 了解 Dify/Coze 低代码平台, 可快速构建应用原型并迭代。

数据处理与数据库: 熟练使用 MySQL 数据库, 掌握索引优化、SQL 调优、事务管理; 熟练使用 SQLAlchemy/peewee 完成持久层开发; 熟练使用 Redis 完成缓存设计、分布式锁、延迟队列、布隆过滤器等高级应用, 提升系统响应速度与稳定性。

系统与运维能力: 了解 Linux 系统常用命令与 Shell 脚本编写, 可独立完成服务部署与日志排查; 搭建大模型应用全链路监控体系, 涵盖性能、质量、安全监控, 具备向量数据库集群故障排查、数据备份恢复能力, 保障系统 7×24 小时稳定运行, 熟练运用 Prometheus+Grafana 等监控工具。

机器学习与深度学习基础: 熟悉 BERT、LSTM、GRU、Transformer 等深度学习模型及架构原理, 了解 Attention 机制; 掌握 PyTorch 深度学习框架, 可独立完成模型训练、微调与部署; 了解随机森林、GBDT、FastText 等传统机器学习算法, 具备 NLP 相关任务落地经验。

工作经历

2023.07 - 2026.09

重庆壹步信息技术有限公司

大模型 | 智能体应用开发

- 负责后端系统整体架构设计与核心代码实现, 基于Python搭建多智能体协作架构, 开发RESTful接口, 主导维修、家园共育、资讯检索等核心业务模块开发, 保障系统高可用、高扩展。
- 聚焦AI智能应用落地, 负责RAG系统全流程开发、多智能体构建及模型轻量化微调, 搭建智能问答与混合检索架构, 适配垂直领域场景, 提升智能模块精准度与响应效率。
- 负责数据库与缓存系统设计运维, 设计MySQL表结构、分库分表及数据同步方案, 利用Redis实现高频数据缓存, 处理数据库故障排查与数据备份, 保障数据安全高效。
- 优化系统性能与并发能力, 采用分布式锁、异步解耦解决高并发问题, 搭建容器化部署、CI/CD及全链路监控体系, 保障系统7×24小时稳定运行, 提升响应速度与运维效率。
- 参与SSE流式通信体系与 MCP工具服务建设, 建立标准化流式契约保障端到端传输可靠性, 设计渐进式 MCP迁移方案, 实现分布式授权与用例稳定身份管理。
- 对接业务需求与外部服务, 集成各类SDK及协议, 适配多端场景, 封装基础框架、搭建API文档与监控体系, 支撑团队协同, 推动业务数字化转型。

项目经验

ATC智能测试平台

智能体应用开发

项目描述:

该项目面向猫超质量保障业务, 构建 AI 智能体平台, 解决测试用例编写耗时长、业务知识沉淀难、AI 生成内容不可控、效果无法量化等痛点。依托多智能体与 RAG 检索能力, 实现业务文档解析、测试用例自动生成、效果评测、指标监控全链路能力, 支撑业务团队快速产出标准化测试用例。

技术框架：

Python, LangGraph, FastAPI, MySQL, Redis, MCP, 百炼大模型

核心职责：

负责 A2A 交互模块设计与代码实现，搭建长意图异步、短意图同步双链路，结构化澄清交互字段，提升智能体追问的可控性。

主导领域知识库与 RAG 召回链路开发，接入业务文档并构建增量更新，实现文档解析、元数据管理与多级检索，优化召回精度。

主导平台子智能体设计，基于 ReAct 多角色智能体协作框架，搭建经验记忆与 EKB 知识库注入能力，完成测试任务自主规划。

参与测试用例生成引擎开发，基于 LangGraph 构建状态机，通过 Function Calling 完成多意图路由，双循环策略平衡生成质量与响应速度。

参与 SSE 流式通信、MCP 工具服务模块开发，构建标准化流式契约，实现分布式授权，管理用例唯一身份标识。

参与可视化看板与指标体系建设，开发用例差异高亮、批量管理功能，搭建 LLM 用量监控看板，量化 AI 生成质量指标。

项目成果：

平台落地后，将业务文档转化测试用例的周期由小时级压缩至分钟级，大幅降低测试人员手工编写用例成本。

通过 RAG 知识库与子智能体协同，提升 AI 生成用例的业务贴合度，降低内容幻觉，保障用例覆盖完整性。

建立全链路指标监控体系，实现模型调用用量、生成质量指标可视化，便于持续迭代优化智能体能力。

啄木鸟维修内部智能报价系统

大模型应用开发

项目描述：

该项目是为啄木鸟维修内部客服以及维修师傅团队开发的一套维修智能报价解决方案。系统核心目标是解决传统维修人工报价流程中价格不透明、标准缺失、主观随意、易滋生乱象、效率低下、供需错配等问题。通过引入多智能体协作架构，将复杂的维修服务拆解为故障检测、配件耗材、工时费用、上门服务等多个专业化报价单元，实现了从客户故障需求输入到完整维修报价单生成的全流程自动化，适配全国维修师傅上门服务报价场景。

技术框架：

Python, LangChain, LangGraph, FastAPI, MySQL, Redis, MCP (Model Context Protocol)

核心职责：

负责系统后端整体架构设计与核心代码实现，采用LangGraph构建多智能体协作 workflow，明确各智能体职责与执行顺序。

基于LangChain开发故障识别、配件匹配、工时核算、上门定价六个核心智能体，封装其业务逻辑与决策过程，确保报价精准性。

使用FastAPI开发RESTful接口，供前端客服界面、维修师傅端APP调用，处理报价请求的状态跟踪与结果返回。

集成MCP协议，使智能体能够对接啄木鸟维修供应链、合作配件商的实时数据与服务，确保维修报价的准确性与时效性。

项目成果：

系统上线后，将啄木鸟维修单平均报价时间从原来的30-60分钟缩短至5分钟以内，客服及师傅工作效率提升约90%。

通过自动化校验与多智能体协同，有效减少了人工报价导致的漏项、错算、乱加价问题，维修报价差错率显著降低。

生成的报价单内容详尽、统一，包含清晰的故障说明、费用构成，提升了啄木鸟维修服务专业度与客户满意度，降低投诉率。

车友头条AI智能资讯与检索系统

大模型应用开发

项目描述：

针对车友头条“汽车行业今日头条”定位，负责核心AI检索与资讯智能分发模块开发，覆盖8000+内容来源的多格式文档（图文、视频脚本、车型参数）解析与高效检索，优化用户资讯获取效率，同时支撑新车发布、评测导购、用车技巧等全场景内容服务，适配千万级用户高并发访问需求，助力产品实现“个性化内容推荐”核心目标。

技术框架：

Python、RAG系统、BGE-M3、LLaMA Factory LoRA、Milvus/FAISS、FastAPI、Docker、Nginx、Redis、Prometheus+Grafana

核心职责：

负责RAG系统全流程架构设计与落地，实现多格式文档（PDF、Word、图文链接）解析、用户敏感信息（手机号、位置隐私）脱敏及文本分块优化。

基于BGE-M3模型搭建语义检索+BM25混合检索架构，通过LLaMA Factory LoRA轻量化微调适配汽车领域场景。

使用FastAPI构建检索与推荐API服务，基于Docker容器化部署，Nginx实现反向代理与负载均衡，搭建Jenkins CI/CD流水线。

集成Redis缓存热点资讯与检索结果，设计缓存更新策略，提升系统并发处理能力。

搭建系统全链路监控体系，基于Prometheus+Grafana实现性能、质量、安全全方位监控，负责Milvus向量数据库集群故障排查与数据备份恢复。

项目成果：

- 有效解决资讯内容碎片化、检索精准度低的问题，提升资讯检索的便捷性与准确性。
- 将资讯检索准确率提升15%，检索响应时间缩短至100ms内，优化用户资讯获取体验

大模型应用开发

掌通家园智能问答系统

项目描述：

针对掌通家园家长高频咨询痛点（如入班、课程、收费等），传统FAQ准确率低、知识更新慢，增加老师沟通负担，因此开发HomeEduRAG智能问答系统（嵌入APP），依托RAG技术提升答疑效率与家长体验，减轻老师压力。

技术框架：

Python + Milvus + BERT + Sentence-BERT + BGE-M3 + Qwen2.5-7B + LoRA + RagAS + OCR + FastAPI

核心职责：

- 构建掌通家园专属RAG知识库，清洗整理园所各类文档，累计构建50万+条家园共育数据；
- 完成园所资料预处理，包括文本加载、去噪、智能分块及多模态内容处理；
- 搭建Milvus向量数据库，设计多集合存储策略，实现各类知识的隔离管理与高效检索；
- 基于BERT实现掌通家园场景意图识别（4类核心意图），F1-score达90%；
- 搭建完整RAG流程，实现意图路由、Prompt拼接及贴合园所场景的精准回答生成，支持上下文感知与格式化输出。

项目成果：

- 嵌入掌通家园APP，自动应答率超80%，老师答疑压力降低50%，提升工作效率；
- 提升家长咨询准确率与满意度，获园所及家长认可，减少家园沟通矛盾；
- 支持知识库动态更新，适配多规模园所，具备高可扩展性与私有化部署能力。

法律知识情报 RAG 分析系统

项目描述：

律师 / 法务在案件办理、合规审查时，需人工翻阅法条、判例、合同文本等资料，单案信息检索耗时超 10 分钟；内部案卷、规章、客户资料分散在不同部门，第三方法规库、裁判文书网数据与内部业务数据割裂。构建 RAG 系统整合多源法律数据，支持快速、精准的法律信息查询与推理。

技术框架：

RAG、LangChain、Milvus、BGE-M3、FastAPI、uvicorn、PyTorch、Transformers、BERT、Redis、MySQL、RapidOCR、DashScope API、RagAS、定时任务调度

核心职责：

- 整合内部案卷 / 合同 / 规章（PDF/DOCX/PPT/ 图片）和第三方法规库、裁判文书 API 数据，使用 RapidOCR 处理扫描案卷，ChineseRecursiveTextSplitter 进行父块（1200 字符）+ 子块（300 字符）分层切分，BGE-M3 向量化，支持跨数据源检索，查询准确率达 92%。
- 设计 BM25 快速匹配（Redis 缓存，命中率 85% 以上）+ 向量语义检索（稠密 + 稀疏向量）的混合架构，通过 RRF 算法融合结果，BGE-Reranker 重排序，复杂案件法条 / 判例召回率提升 35%，平均响应时间从 5 秒降到 2 秒内。
-
- 基于 BERT 实现查询分类（法条检索 / 判例匹配 / 合同审查 / 合规咨询），根据分类结果自动选择直接检索、子查询分解、HyDE、回溯检索等策略，关键法律问题准确回答率提升 22%。
- 实现文档上传审核模块，自动提取元数据、OCR 识别、内容合规性评估，审核周期从 2-3 天缩短到 1 天；构建第三方法规数据同步模块，定时任务调用 API / 爬取数据，清洗去重标准化后批量入库，支持增量更新。
- 构建法律领域专业术语词典（法条编号、罪名、案由、司法解释条目），在文本预处理和向量化阶段进行实体识别和标准化，专业术语识别准确率从 70% 提升到 95%，检索准确率提升 25%。

项目成果：

覆盖 90%+ 律师 / 法务日常工作场景，90% 高频法律问题实现毫秒级响应，信息检索效率提升 10 倍，法律数据覆盖率达 85% 以上，用户查询满意度 88%，成为团队核心案件办理与合规审查工具。