

赖奕铮

求职意向：大模型应用开发工程师 | 24 岁 | 大学本科 · 全日制统招
手机 17779772178 · 邮箱 kccakee@163.com · 微信 17779772178



职业技能

LLM 应用：熟练搭建**企业级多 Agent**，**企业级 RAG** 知识库，掌握 **LangChain / LangGraph** 多智能体编排与 **MCP、A2A** 协议，熟练使用 **harness**

LLM 高级：掌握 **vLLM** 推理框架、**LoRA** 微调、全量微调、**Prompt Engineering**、**VibeCoding**，能够本地/云端部署大模型

NLP：关键词提取、序列标注、文本分类、文本生成、词向量训练

深度学习：熟悉 **CNN / DNN / RNN / LSTM / GRU** 等常见模型算法，熟悉 **PyTorch**

编程语言：**Python**，熟练使用 **Coze / Dify** 等多种开发平台，具备良好编程规范

数据库：**MySQL**、**Redis**、**Neo4j**

工程工具：**PyCharm**、**VScode**、**Codex**、**Claude Code**、**Cursor**；掌握 **Linux** 常用命令与操作

工作经历

广州中科易德科技有限公司 | 算法工程师（NLP / LLM 方向） | 2022.7 – 2026.08

职责 | 负责企业 AI 应用的技术选型与工程落地，对接业务需求并推动上线

- 搭建企业级多智能体系统，完成智能选品和智能文案产线推送，实现降本增效
- 参与客服智能化项目，负责意图识别与文本分类模块的模型训练、评估与迭代
- 推动企业级 RAG 知识库检索方案落地，完成混合检索与重排序调优，提升长尾问题召回
- 基于 Python / FastAPI 完成服务封装与部署运维，参与内部 AI 工具链建设
- 与业务方、产品及后端团队协作，输出技术方案文档与验收标准

项目经验

项目一 • ArgosLG - LangGraph 多智能体编排 + 电商知识图谱的智能选品系统

项目背景 选品长期依赖运营人工经验，商品、评价、市场趋势等数据割裂，决策周期长达 **5~6 天**、人员臃肿、结论不可追溯；亟需一套以统一事实底座驱动的自动化选品流水线，让结论可溯源、可复用、可审计

职责	多智能体模块负责人：独立负责 LangGraph 编排层 (Supervisor / Planner / Critic) 、 MCP 工具层建设与 A2A 跨框架对接
技术栈	Python · LangGraph · Multi-Agent (MCP · A2A) · Neo4j (GraphRAG) · FastAPI
项目详情	- 编排层 (Supervisor / Planner / Critic) ：Planner 把选品需求拆成「市场调研 → 竞品分析 → 价格监控 → 决策推荐」四类子任务，路由至 4 个对应专用 Agent【抓取 Agent/分析 Agent/评估 Agent/汇总 Agent】并行执行；Critic 结合图谱证据复核，不合格自动回炉重试 - 工具层与互操作：基于 MCP 接入 Neo4j 官方 / 社区 Server，并自研商品中心 / 评价洞察 / 价格监控 3 个数据 Server (20+ 工具) ；既有运营系统按 A2A 协议接入，实现 Agent 间任务分发与结果汇聚 - 知识底座：Neo4j 构建商品-类目-属性-评价知识图谱 (10 万+ 实体) ， Agent 经 Cypher + 向量检索 (GraphRAG) 获取事实，输出结论附证据链
项目成果	10 并发下首字延迟仅 500ms ，能够在 2QPS 下稳定运行； 降本 ：选品周期由 5~6 天缩短至 3~4 小时，项目组人员由 15 人缩减至 5 人； 增效 ：每周期选品量由 100~120 件提升至 250~290 件；新品类接入无需重训模型，Checkpoint 持久化支持断点续跑 + Human-in-the-Loop 审批，FastAPI 流式返回推理过程

项目二 · MuseFlow - 多智能体电商营销内容生产线

项目背景	电商上新与活动期素材需求量极大——详情页文案、主图卖点、种草笔记、短视频脚本、客服话术，人工与外包单条成本 3~5 元、周期 6 天，上新节奏被素材卡住；且质量不稳定，广告法极限词、平台规则踩雷导致下架与罚款时有发生。需要一条能批量产出、能过合规、能看效果的内容生产线
职责	内容生产线负责人：独立负责多智能体编排 (卖点挖掘 / 多风格生成 / 合规审核 / 效果复盘) 、 MCP 数据接入、风格库与 Prompt 迭代
技术栈	Python · LangGraph · Multi-Agent (MCP · A2A) · RAG (素材与评论检索) · Prompt 工程 · FastAPI · MySQL · Redis
项目详情	- 多智能体分工：卖点挖掘 Agent (从商品参数、用户评论、竞品页面抽取差异化卖点) → 多风格生成 Agent (按渠道与人群分别产出详情页 / 主图 / 笔记 / 脚本多版本) → 合规审核 Agent (广告法极限词与平台规则校验，不通过自动退回重写) → 效果复盘 Agent (回传点击与转化，沉淀高转化风格库) - 数据与工具层：经 MCP 统一接入商品中心、评论库、素材库与投放系统；生成侧用 RAG 检索历史高转化素材作 few-shot 参考，风格与卖点口径保持一致 - 防编造与合规：Critic 复核 + 主数据事实校验 (价格、参数、库存只从主数据取，不允许模型编造) ，违规与幻觉素材拦截率 98%

- 交付与并发：FastAPI 异步任务队列 + 批量生成接口，支持一次提交整档活动素材；Checkpoint 断点续跑，长任务失败不用重来

项目成果 30 并发下首字延迟仅达到 300ms，能够在 6QPS 下稳定运行；降本：单条素材成本由 3~5 元降至 0.5~0.8 元，按 50000 条/年 折算年节省 12.5 万元；日产素材由 100 条提升至 300 条，上新周期缩短 4 天；增效：高转化风格复用使素材点击率与转化率提升 45%，违规素材上线前拦截率 98%，素材运营人力由 33 人降至 12 人

项目三 · SageRAG - 本地 RAG 知识库智能客服

项目背景 企业知识分散在 2000~3000 文档中，员工查一个问题平均耗时 10 分钟，且答案口径不一、同一问题不同人说法不同；数据安全要求不允许调用外部 LLM API，通用 SaaS 问答无法落地。需要一套全链路本地化问答系统：数据不出内网、答案可溯源

职责 项目负责人：独立负责文档解析分块、混合检索与 Rerank、RAG 评估体系、服务化与增量更新

技术栈 Python · 向量检索 (BM25 + Embedding) · Rerank · FastAPI · harness

项目详情

- 检索链路：PDF / Word / Markdown 多格式解析与语义分块，BM25 + 向量混合检索加重排序，兼顾关键词命中与语义召回
- 生成链路：构建「召回 → 重排 → 生成 + 引用溯源」全链路，支持多轮记忆与问题改写，回答附原文出处
- 评估闭环：基于 harness 搭建 RAG 评估集（忠实度 / 答案相关性 / 引用准确率），形成「改一版 → 跑评估 → 看指标」的回归闭环，检索参数与 Prompt 迭代不再依赖经验试错

项目成果 降本：标准问答耗时由 10 分钟 缩短至 5 秒，知识库维护人力由 6 人降至 3 人；增效：覆盖 6 个部门、日均问答 400 次，长尾问题召回率相对基线提升 12%，端到端回答准确率 91%、平均响应 300ms 以内；全链路本地部署、数据不出内网，支持知识库增量更新与索引同步

项目四 · Lumen - 电商语句分析

项目背景 客服日均会话 4000 次，意图分类与质检长期依赖人工抽检，人工抽检覆盖率仅 24%、判定口径不一、成本高；多模型方案各自为政、缺少统一对比基准。需要一套「数据处理 → 模型训练 → 统一评估 → 模型压缩 → LLM 赋能」的平台：把人工抽检升级为全量自动质检，且在无 GPU 环境下低成本可用

职责 主导开发：双任务标签体系、多模型训练与统一评估、模型量化压缩、LLM 分析模块与推理服务

技术栈 Python · PyTorch · BERT / FastText / TF-IDF · FastAPI · MySQL · LLM · Prompt 工程

- 项目详情**
- 统一基准：意图识别 + 客服质检双任务（12 类意图 / 4 类质检标签），统一清洗与切分逻辑，使 TF-IDF、FastText、BERT、LLM 在同一基准上可比，模型选型有据可依
 - 模型压缩：横向评估四条技术路线的精度与部署成本，对 PyTorch 模型做量化，对齐无 GPU 的线上部署约束
 - 输出可靠性：LLM 分析模块经可信 JSON 校验，拦截格式错误与标签越界，满足生产可用要求
 - 工程交付：FastAPI 封装推理服务（鉴权 / 限流 / 容错），配套 EDA 面板与终端工具，降低实验与部署门槛

项目成果 **降本**：质检覆盖率由人工抽检的 **24%** 提升至全量，单条会话质检耗时由 **1 分钟** 降至 **3 秒**，标注与质检人力由 **10 人** 降至 **3 人**；**增效**：以 $\leq 4.4pp$ 的 F1 损失换取 CPU 推理提速 **3.41 倍**（无 GPU 环境达成可用吞吐）、单位推理成本显著下降，LLM 分析模块格式合法率 **99.5%+**、标签越界率 **<0.5%**；平台已用于企业级的意图分类与客服质检

语言能力

英语六级 / 雅思 6.0 / 熟练阅读英语文本

教育背景

计算机科学与技术 | 广州商学院（本科） | 全日制统招 2020.09 – 2024.07

自我评价

- 具备良好的技术抽象与逻辑分析能力，善于从业务痛点中提炼技术方案
- 坚持高质量编程习惯，熟练掌握配置驱动、模块化设计与自动化评估流程
- 技术好奇心强、自驱力高，能快速跟进 LLM、模型量化蒸馏等前沿技术并转化为工程落地成果
- 具备良好的团队协作与技术沟通能力，能准确对接业务方与上下游研发