

郭旭哲

AI Agent 开发工程师 | 2 年 AI Agent 相关经验

18909265983 | wxxwk_xz@163.com

专业技能

Agent 框架与编排: 基于 LangGraph 的 Supervisor 多 Agent 编排 (任务路由 · asyncio.gather 并行调度 · 5s 超时降级)

Agent 协议与状态: MCP 协议 (Streamable HTTP) · MCP 协议工具封装 · 会话状态持久化 (LangGraph Checkpointer)

RAG 检索增强: 混合检索 (稠密向量 + BM25 稀疏) · OpenSearch BM25 · ChromaDB / PostgreSQL(pgvector) 向量库 · bge 系列嵌入 (bge-m3 / bge-small-zh) · Cross-Encoder / Reranker 重排 · 父子块切分 · Query 改写

LLM 与 Prompt 工程: DeepSeek / 通义千问 · Few-shot · 任务分解与结构化 Prompt · Prompt 工程 · Tool Calling (Function Calling) · 结构化输出 · LLM-as-Judge 评估 · Human-in-the-Loop 审批流

深度学习与机器学习: 特征工程、XGBoost; RNN 及其变体、Transformer; 集成学习、正则化与 Dropout; 注意力机制与掩码; 了解 PyTorch、LoRA、PEFT

工程化能力: Python · FastAPI · Pydantic · Docker · Langfuse 可观测性 · RESTful API

数据存储与测试: Redis · MySQL · PostgreSQL · SQLAlchemy 异步 ORM · Pytest (核心链路测试用例) · RAGAS 评估

工作经历

2024.07 - 2026.08 合肥来点酷计算机技术有限公司 Agent 开发工程师

1、参与公司 3 个核心 AI 项目 (RAG 检索增强、大模型 Agent 应用方向) 的研发, 其中 2 个已上线客户生产环境稳定运行、1 个完成试点验收交付; 负责设备告警、历史工单与维护知识向可检索、可调用、可测试 Agent 能力的转化, 重点承担设备知识 Agent、混合 RAG 检索、MCP 工具层、评测与可观测性建设, 参与 LangGraph 主控与自然语言报障链路方案评审;

2、对接业务需求, 协同前后端完成方案评审与联调交付。

教育背景

2021.09 – 2025.06 青海民族大学 通信工程 本科 (统招)

项目经历

通信运维 Agentic 故障诊断与设备知识助手平台 | Agent 开发工程师 2025.09 – 2026.08

技术栈:

Python · FastAPI · LangGraph · MCP · Tool Calling · DeepSeek/通义千问 · bge-m3 Embedding · OpenSearch BM25 · PostgreSQL/pgvector · RRF · Cross-Encoder Reranker · Redis · Langfuse · RAGAS · Pytest · Docker

项目背景:

面向第三方通信运维服务商与 NOC 值班团队, 针对告警来源分散、现场描述非结构化、历史工单难复用、设备手册检索成本高等痛点, 建设集自然语言报障、活动告警关联、Agentic 智能诊断、设备知识问答于一体的智能运维平台。系统按单区 600-1200 个小区搭建容量模型, 围绕告警治理、知识检索、工具安全、质量门禁完成生产级工程设计, 支撑值班人员高效完成故障初诊与设备知识查询。

主要职责:

- 1、参与自然语言报障与告警关联链路设计，负责实体抽取 Schema 定义、自动关联门槛评测与效果调优；高置信自动关联，低置信转人工确认。
- 2、独立负责设备知识 Agent 与生产级混合 RAG 检索：定义能力边界与统一输出契约，落地多轮澄清、无答案拒答、源文引用、型号/软件版本硬过滤；基于 OpenSearch BM25 与 PostgreSQL/pgvector 双路召回，RRF 融合 + Cross-Encoder 重排，覆盖版本过滤、索引切换、超时降级与引用追踪。
- 3、负责 RAG 链路工程化与知识发布流程：实现 Embedding 离线缓存、向量索引启动自检、元数据一致性校验、增量索引更新、知识撤回失效与发布前质量门禁。
- 4、主导 MCP 工具层工程化与安全治理：统一 Tool Schema 参数校验、接口白名单、超时重试、错误语义、幂等键与审计字段，定义统一 ExpertResult 契约；落地 HumanGate 人工安全闸门与高危意图识别，落实网元高危写操作不向 Agent 暴露的生产约束。
- 5、搭建 Langfuse 全链路埋点与 RAGAS 评测体系，制定检索/重排/工具/生成/Agent 节点观测规范，维护 Golden Set 与 Bad Case 回放机制；参与 LangGraph 主控架构方案评审与公共节点联调，参与状态图、Checkpoint 会话恢复与租户 RLS 的业务方案评审。

项目成果：

- 1、设备知识问答链路：混合检索 Recall@5 达 92.5%，MRR 0.85；生成忠实度 Faithfulness 0.90，文档引用有效率 97.0%；高风险问题拒答准确率 94.0%；非缓存场景问答 P95 耗时 4.7 秒，缓存命中 P95 低于 300ms。
- 2、工具与安全治理：封装 6 类核心工具，工具选择与参数正确率达 96.0%；支撑多 Agent 并行取证，Agent 首轮并行取证 P95 耗时 17.8 秒；首期高危网元写操作零暴露，满足生产安全合规要求。
- 3、质量与可观测体系：建成离线评测与 Bad Case 闭环迭代机制，核心指标退化拦截率 100%；全链路埋点覆盖检索、工具、生成核心节点，问题定位效率显著提升。
- 4、规模与稳定性（生产承载）：支撑 10 万+条历史工单检索、3000+篇设备知识库（设备手册/告警码/排障 SOP）；日均处理进入 Agent 诊断的告警事件 500+ 条、知识问答 200+ 次；系统服务可用性 99.9%。
- 5、团队整体业务收益：项目告警压缩率 78.6%，高门槛自动告警关联（最高分 ≥ 0.65 且候选分差 ≥ 0.10 ）精确率 91.5%，故障诊断 Top1/Top3 准确率 68%/86%；故障初步定位耗时从 11.6 分钟降至 5.1 分钟，定位效率提升 56%。

通用型通信网络技术支持知识库 RAG 系统 | Agent 开发工程师 2024.11 – 2025.09

技术栈：

LangChain · FastAPI · ChromaDB · bge-m3 · BM25 · Docker

项目背景：

面向运营商/国网运维工程师的智能问答系统，融合 FAQ 智能分流与 RAG 检索增强，解决设备故障处理方案查询难、手册更新快、案例分散等痛点。

主要职责：

- 1、负责运维手册、设备故障案例等原始文档的数据清洗与预处理，包括格式标准化、编码转换、特殊字符过滤；
- 2、负责 FAQ 知识库构建与维护，整理 150+ 条常见故障问答对，构建独立于知识库的语义相似度评测集；
- 3、负责文档切分策略设计，对长文档进行父子块双层切分，保障上下文完整性与检索精度，结合 Query 改写优化召回效果；
- 4、负责 ChromaDB 向量库的初始化与数据入库，监控向量嵌入质量，处理入库异常与重复数据；
- 5、引入 RAGAS 评估框架，对检索质量（Context Precision/Recall）和生成质量（Faithfulness）进行评测，指导检索阈值与切分策略调优；
- 6、编写 Pytest 测试用例，覆盖 FAQ 检索、向量检索、API 接口等核心功能。

项目成果：

- 1、FAQ 智能分流覆盖 65%常见问题，平均响应时间从 2.3s 降至 0.3s；
- 2、RAGAS 评估驱动调优后，Recall@5 由 75% 提升至 89%，Faithfulness 由 0.78 提升至 0.87；
- 3、文档解析成功率达 96%，向量库支持热更新，运维手册更新无需重启服务。

技术栈:

Dify · RAG · Prompt Engineering · RESTful API

项目背景:

面向通信设备运维工程师的智能技术支持客服系统，基于 Dify 平台快速搭建 RAG 知识库问答管线，实现设备故障诊断、维护方案查询、技术案例推荐等常见技术咨询的自动解答，降低专家热线压力。

主要职责:

- 负责通信设备维护手册、历史故障案例库等原始技术文档的收集、清洗与格式标准化，完成向量化入库前的数据准备；
- 负责分段式向量知识库构建，优化文档切分策略，设备型号+故障码作为元数据过滤，处置方案作为向量化文本，提升检索命中率；
- 负责多轮对话 workflow 设计，实现上下文理解与意图识别逻辑；
- 对接运维工单系统 API，实现故障案例的自动匹配与结构化回复功能；
- 通过 Prompt 工程优化大模型输出质量，统一回答格式，引用来源+固定输出字段+无答案兜底策略，降低无效输出。

项目成果:

- Top-1 命中率由 78% 提升至 85%，可无需转人工直接回答的常见咨询占比达 80%+；
- 平均响应时间从 3 分钟（人工咨询）缩短至 3 秒（系统自动回复），实现常见咨询自助分流；
- 建立知识库动态更新机制，支持维护手册版本更新后同步入库。

自我评价

- 2 年 AI Agent 与 RAG 应用开发经验，熟悉 LangGraph 多智能体编排、混合检索、工具调用与质量评测全链路，具备生产级工程落地能力。
- 通信工程专业背景，熟悉网络告警、拓扑、工单领域语义，能够将运维知识转化为可检索、可评测的 Agent 能力。
- 重视可观测性与数据驱动优化，习惯通过 Bad Case 闭环迭代产品效果，关注生产安全与权限边界。