

陈帅文

男 | ☎ 15893567588 | ✉ shuaiwen.chen@outlook.com

3年工作经验 | 求职意向：AI应用开发工程师

专业技能

AI 框架与模型：LangGraph· LangChain· BERT· Transformer· PyTorch· BGE-M3· Reranker

LLM应用工程：RAG· Multi-Agent· Prompt Engineering· Milvus· BM25· Coze/Dify· Workflow编排

后端与工程：Python· FastAPI· PostgreSQL· Docker· WebSocket· SQLAlchemy

个人优势

大模型应用开发能力：具备LLM应用系统完整研发经验，熟悉RAG、Agent、Workflow等大模型应用技术体系，能够完成从模型接入、知识增强、智能体设计到业务系统落地的完整开发流程。

Agent智能体开发能力：熟悉LangGraph等Agent开发框架，掌握StateGraph状态管理、节点编排、任务拆解、工具调用及多Agent协作机制，具备复杂业务流程智能化设计与实现能力。

RAG知识增强与应用构建能力：掌握Embedding向量化、Milvus向量数据库、BGE-M3混合检索、BM25置信度路由、Reranker重排序以及Prompt优化等关键技术，具备企业级知识问答系统开发经验。

机器学习与深度学习基础扎实：熟悉PyTorch与Transformer模型结构，具备BERT模型微调、文本分类及模型评估调优的完整工程实践。

AI工程化开发能力：熟练使用Python、FastAPI进行AI服务开发，掌握Docker容器化部署及数据库接口设计，能够完成AI应用从算法验证到生产部署的工程闭环。

项目经历

基于Multi-Agent的GMP偏差调查智能辅助系统

AI模型应用开发工程师

2026.02-2026.07

内容：

项目背景

- 制药企业生产偏差需依据FDA、EU GMP、NMPA等法规完成偏差分级、根因分析、影响评估、CAPA制定及调查报告编制，传统流程高度依赖QA专家，存在调查周期长、知识分散、分析标准不统一等问题。系统面向制药企业QA调查场景，通过Multi-Agent协作与RAG知识增强实现偏差调查流程自动化，辅助完成从偏差分类、根因分析到报告生成的完整调查流程。

项目内容与职责

- 基于 LangGraph StateGraph 构建五 Agent 分层架构，每个 Agent (Classifier / RootCause / Impact / CAPA / Report) 编译为独立子图 (subgraph)，通过 Orchestrator 主图统一调度，实现节点级独立测试与单子图降级，任一子图失败不影响已完成阶段结果
- 设计严重程度驱动的条件路由 (conditional_edges)：ClassifierAgent 输出 Critical / Major / Minor 后路由至三条不同深度执行路径；RootCause 节点置信度低于 0.5 时触发重分类循环，回退清空旧分类并重新调用 ClassifierAgent，防止错误分类沿图传播污染后续节点
- 构建双层 RAG 知识库架构：L1 静态层收录 ICH Q7-Q12、FDA、EU GMP、NMPA 等监管文档约 200 份；L2 动态层通过 /supplements API 接收调查员贡献的企业知识，实时向量化写入 Milvus，系统随使用持续增强；
- 设计三层容错机制：tenacity 自动重试 (指数退避) → Agent 级保守降级 (Classifier 失败默认 Major, Impact 失败默认高风险) → 系统级结构化错误返回，无 500 崩溃，已完成节点结果完整保留

业绩：

- 调查周期从传统 5-20 个工作日压缩至 2-4 小时，效率提升约 **30-60 倍**，单次调查人工介入时间从数天降至约 30 分钟
- L2 动态知识库将企业历史调查经验沉淀为可检索资产，有效解决 QA 专家离职导致的知识流失问题，预计减少 **60%** 以上重复性调查工作量
- 私有化部署方案消除数据出境风险，直接打通制药企业合规审批通道，对比 SaaS 云端方案具备显著竞争优势
- 系统覆盖 FDA / EU GMP / NMPA 全套法规体系，单次调查自动生成符合监管格式的完整报告，降低因文档不合规引发 Warning Letter 的风险

Compliance Audit Agent 财务合规审计系统

AI模型应用开发工程师

2025.06-2025.11

内容:

项目背景

- 会计师事务所每年需审计大量上市公司年报，初级审计员人工翻阅数百页报告识别合规风险，耗时数天且易遗漏。系统面向中小会计师事务所，自动化完成风险初筛，将人工工作量从"全量翻阅"压缩为"对结论做判断"，通过 Human-in-the-loop 保留专业判断兜底，规避 AI 误判进入正式报告的法律风险

项目内容与职责

- 基于 LangGraph 实现 ReAct 自主决策循环，PlannerAgent 每步通过 LLM 输出结构化 AuditPlan (action_type + action_target)，动态规划提取哪张财务报表、检查哪个合规领域，执行路径运行时生成，适应不同行业公司的审计重点差异，避免固定路由的无效覆盖
- 设计五节点 ReAct 图 (load_context → plan → execute → evaluate → report)，execute_action_node 根据 AuditPlan 动态调度三个子图 (DataExtractor / RuleChecker / CrossValidator)；子图调用加 asyncio.wait_for 120s 超时保护，失败时写入 unavailable_tools 状态并注入 Planner Prompt，防止 LLM 反复规划已失败工具
- RuleChecker 子图内嵌 RAG 检索，将财务数据与 Milvus 向量库中的会计准则条文 (CAS、IFRS) 进行语义匹配，使用 BGE-M3 混合检索 + Reranker 精排；检索服务不可用时自动降级为 LLM 参数化知识，并在报告 audit_completeness 字段中标注"准则检索不可用，结论基于模型知识"，保证透明度
- 实现 Human-in-the-loop：高风险发现触发 LangGraph interrupt_before 暂停图执行，通过 WebSocket 推送结构化发现供审计师决策 (confirmed / rejected / investigate)；双重超时兜底——WebSocket 层 30 分钟无响应自动注入 investigate，后台 watchdog 定时扫描 DB 中 paused 超时任务恢复执行，防止任务永久阻塞

业绩:

- 审计初筛耗时从人工 3-5 天压缩至约 2-3 小时，审计师人工介入时间降低约 **90%**，从全量翻阅年报转变为仅对 3-5 个高风险结论做判断
- Human-in-the-loop 机制将 AI 定位为"发现工具"而非"裁判"，高风险发现经人工确认后入报告，在提升效率的同时规避误判法律风险，满足注册会计师签字合规要求
- 支持同一套系统审计多家上市公司，帮助中小会计师事务所以现有人力承接更多审计项目，直接提升业务产能

RAG企业内部知识库

AI模型应用开发工程师

2025.01-2025.06

内容:

项目背景

- 企业内部知识分散在制度文档、产品手册、运维 SOP、培训资料、FAQ 等不同载体中，存在检索效率低、关键词搜索不精准、复杂问题定位困难、多轮追问缺乏上下文支撑等问题。为提升企业内部知识复用效率与员工自助问答体验，基于 RAG技术搭建企业内部知识库问答平台，统一接入结构化 FAQ 与非结构化文档知识，实现企业知识的智能检索、语义问答与多轮会话支持。

项目内容与职责

- 负责企业内部知识库 RAG 平台的整体方案设计与核心后端开发，搭建 FastAPI + WebSocket + MySQL + Redis + Milvus +DashScope/Qwen 的问答服务架构。

- 设计并实现 FAQ 快速问答 + RAG 语义问答 双路由机制，高频标准问题优先走 MySQL + Redis + BM25，复杂问题自动回退到 Milvus + Embedding + Reranker + LLM 链路。
- 负责知识库构建流程开发，支持 PDF、Word、PPT、Markdown、图片 等多格式文档解析，并结合 OCR、父子块切分、向量化入库 完成企业知识沉淀。
- 负责检索增强与会话能力建设，基于 BGE-M3 混合检索 + BGE Reranker 重排 + BERT 意图识别 提升召回质量，并实现 多轮上下文记忆 与 WebSocket 流式输出。

业绩：

- 设计并实现 2 条核心问答链路：FAQ 快答链路 + RAG 语义问答链路
- 实现 4 种检索增强策略：直接检索、HyDE、子查询检索、回溯问题检索。
- 支持 最近 5 轮会话历史 持久化，并提供 WebSocket 流式输出 能力，满足企业内部多轮知识问答场景。
- 覆盖企业内部超 500 份业务文档，FAQ 快答链路响应 < 500ms，语义问答准确率较纯关键词搜索提升约 40%；通过双路由机制降低 LLM 调用成本约 30%，上线后员工知识检索耗时降低约 60%。

基于Transformer的法律文本智能分类系统

自然语言处理算法

2024.07-2024.12

内容：

项目背景

- 法律文本专业术语密集、语义复杂，传统关键词匹配方法无法理解深层语义，人工案件分类成本高且效率低。系统基于预训练语言模型对案件文本进行自动分类，实现类别预测与辅助分析，将人工分类工作转化为模型自动处理，显著提升法律文本处理自动化水平。

项目内容与职责

- 基于 Transformer 架构构建中文文本分类模型，采用 BERT-Base-Chinese 预训练模型 + Linear 分类头方案，针对 8 类案件分类任务设计 768 维语义特征表示与 Linear(768, 8) 分类头，通过 PyTorch 完成模型训练、微调与推理全流程
- 基于混淆矩阵分析 8 类主要误分类场景，构造典型样本与易混淆样本 100+ 条，定位模型误判原因并针对性优化训练数据，提升分类稳定性
- 完成 Tokenizer → BERT Encoder → Linear 分类层 → Softmax → 类别映射全流程一致性验证，GPU 环境下单条文本推理耗时控制在 50ms 以内，支持批量输入及 Top-3 候选类别输出
- 基于 FastAPI 封装模型预测服务实现接口化部署，前端展示预测类别、置信度及 Top-K 概率分布，覆盖正常输入、异常输入、批量请求等测试场景，完成从模型训练到业务应用的完整闭环

业绩：

- 将人工逐条审阅案件文本的分类工作转化为模型自动预测，支持 8 类案件秒级识别，显著降低法律文本人工处理成本
- 系统输出类别预测、置信度及 Top-3 候选结果，为法律从业者提供可解释的辅助决策依据，减少因分类错误导致的案件处理偏差
- 大模型数据增强方案将训练样本扩充至 **37.5 万条**，覆盖复杂边界场景，提升模型在专业法律语义下的泛化能力，支撑系统在真实案件文本环境中的稳定运行
- 模型在测试集上达到 Accuracy **91.13%**、Precision **91.57%**、Recall **91.11%**、F1-Macro **93.6%**，验证模型在复杂法律语义场景下的分类可靠性

工作经历

河南贵冠信息科技有限公司

2024.02-2026.09

- 主导企业级大模型应用系统研发，基于LangGraph的多Agent工作流设计与RAG知识问答系统开发，负责模型调用、Prompt设计、知识库构建及业务流程编排，推动系统从需求设计到上线部署的完整落地。
- 面向企业知识管理场景，独立完成RAG问答系统的文档解析、检索增强与智能问答链路搭建，支撑团队知识管理效率提升。

- 设计Transformer文本分类模型研发，完成基于BERT-Base-Chinese的中文文本分类任务微调，参与数据构建、模型训练及效果评估工作

教育经历

郑州财经学院 本科 计算机科学与技术

主修课程:数据结构、机器学习、深度学习、自然语言处理、数据库原理、人工智能

资格证书

普通话二级甲等 大学英语四级 计算机三级 大学英语六级