

基本信息

姓名：雷晶晶

工作年限：8年经验

电话：18917681607

邮箱：leijj0607@163.com

求职意向

职位：全栈开发&Ai应用开发

随时到岗

教育经历

2013-09 ~ 2017-07

长江大学

软件工程（本科）

工作经历

2025-10 ~ 至今	美团	Ai应用开发
2025-04 ~ 2025-09	滴滴出行	Ai应用开发
2021-04 ~ 2024-03	上海甄云科技有限公司	web前端
2018-07 ~ 2021-04	联想云领科技有限公司	web前端

技能特长

- Python：熟练运用 Python 高级特性（装饰器、生成器、上下文管理器、元类等），理解 GIL 全局锁与多进程/协程并发模型，能进行规范的模块化设计与单元测试，具备良好的工程开发习惯。
- 数据库与缓存：精通 MySQL 事务隔离、锁机制及索引优化，拥有线上慢 SQL 排查与性能调优经验；熟练使用 Redis，掌握其底层数据结构、持久化策略（RDB/AOF）及哨兵高可用模式。
- MCP 协议：理解 MCP 标准及其客户端-服务端协作模式，具备将数据库、API 等外部资源包装为 MCP Server 并与 LLM 打通的经验，实现标准化的工具调用链路。
- 多模态开发：掌握多模态模型的调用方式，能融合文本、图像、语音等输入构建交互应用，熟悉 Embedding 对齐、视觉问答（VQA）及多模态内容生成等关键技术路径。
- RAG 工程化：具有 RAG 检索增强生成的落地经验，可独立完成文本分割、向量嵌入、检索与排序等环节，并能结合多模态和 Agent 扩展检索增强应用范围。
- 模型调用与优化：熟悉 Function Calling 机制与流式响应处理，能够根据场景优化 Token 消耗并设计高质量的提示词模板。
- 向量数据库：熟悉 Milvus 的核心操作（向量写入、检索、批量处理），能设计面向语义搜索和推荐场景的向量检索方案。
- AI 辅助编程：持续实践 Vibe Coding 模式，熟练使用 Claude Code、Codex、Cursor 等工具进行需求分析、代码生成与重构，大幅提升日常开发效率。
- 软件设计：善于运用多种设计模式，注重代码的内聚性与扩展性，致力于编写低耦合、高质量的业务代码，以提升项目长期可维护性。
- Vue 与 H5 开发：熟练使用 Vue、React、Element-plus UI、Antd、Webpack及富文本编辑器 ueditor，借助 npm 进行工程化 H5 开发，能够构建响应式、组件化的前端应用。

商品知识智能问答系统

ai应用开发

项目简介：面向商家商品手册与文档的智能知识问答系统。商家拥有大量商品及使用手册，客服需快速查找提问的相关信息，传统方式需要翻阅整份文档，效率低下。本系统通过RAG+Agent架构，支持PDF/MD文档导入后自动解析、切片、向量化入库，用户用自然语言提问即可从知识库和网络中获取精准答案，并支持来源追溯。

技术栈：Python、LangChain、LangGraph、FastAPI、Milvus、BGE-M3、MongoDB、MinIO、MinerU、MCP

核心职责：

- 基于LangGraph构建两调DAG工作流：导入流和查询流，实现条件路由、并发分支/合并、懒加载编译等模型
- 设计三路并发混合检索架构：a. BGE-M3稠密+稀疏向量搜索、b. HyDE假设性文档嵌入检索、c. MCP联网搜索；三路结果通过RRF加权融合，再经过Reranker精排，结合断崖检测动态截断，过滤低质量结果
- 实现LLM驱动的智能实体识别与确认：从用户问题+多轮MongDB对话历史中提取商品名，BGE-M3向量化后再Milvus混合检索

对齐，三级确认机制，支持上下文感知的Query_Rewrite;导入阶段LLM自动识别文档中的商品名称并关联所有切片

4. FastAPI+SSE实现实时流式回答推送，异步执行查询流程不阻塞请求，列队机制实现增量delta推送；MongBD管理多轮对话历史，Prompt构建时带字符预算控制方式Token溢出

5. 搭建RAGAS自动化评估系统：基于RAGAS框架构建5维评估管道，设计自动化Bad case识别机制，输出可定位问题的诊断报告，支撑14轮Prompt优化迭代，累计评估100+测试用例，Answer Correctness从基线提升至0.82

智能流程自动化平台

ai应用开发

项目简介：面向企业级AI应用场景的Multi-Agent智能流程自动化平台，基于大模型的复杂任务自动编排与执行能力。平台基于LangChain与qwen大模型构建Multi-Agent架构，集成数据分析、文档生成、第三方系统对接与RAG知识问答四大核心能力，通过自然语言交互实现复杂业务任务的自动化执行，将单次复杂分析报告生成时间从小时级缩短至分钟级。

技术栈：Python、LangChain、FastAPI、Streamlit、qwen大模型、BGE-Small-ZH、ChromaDB、Redis、MySQL、Pandas、Matplotlib

核心职责：

1. 双路径Agent执行引擎与任务规划

- a. 设计并实现基于ReAct框架的Agent核心引擎，针对任务复杂度设计双路径执行策略：简单问答走单步ReAct循环；复杂任务（如“分析数据并生成报告”）触发TaskPlanner拆解为DAG有向无环图执行。
- b. 实现LLM规划优先 + 规则降级的兜底机制：优先利用大模型推理能力动态生成执行步骤，若LLM解析失败或超时，自动降级至基于关键词匹配的规则引擎，保障系统100%可用性。

2. RAG知识问答与向量检索体系

- a. 构建RAG检索增强生成链路，使用BGE-Small-ZH模型进行文本向量化，并存入ChromaDB向量数据库，支持企业内部文档的语义检索。
- b. 实现通用文档加载器，支持PDF/Word/Excel/TXT多格式解析，采用RecursiveCharacterTextSplitter智能分块，Prompt层增加“依据参考资料回答”强约束，有效抑制大模型幻觉，并提供参考来源追溯。

3. 插件化工具系统与安全沙箱

- a. 基于LangChain BaseTool设计统一工具基类与注册中心，利用Pydantic实现严格的入参校验与类型转换，支持工具的动态注册与热插拔。
- b. 开发DataAnalyzer工具，实现Excel/CSV文件读取、数据清洗、统计分析及Matplotlib可视化，并结合python-docx自动生成包含图表的分析报告；设计Mock/Real双模式切换，外部系统不可用时自动降级模拟数据，保障开发测试连续性。

4. 三级记忆存储与反思重试机制

- a. 设计三级存储记忆策略（Redis缓存 → 内存降级 → MySQL持久化），自定义ConversationBufferWindowMemory，实现多用户会话隔离与上下文无缝保持。
- b. 引入Reflection反思模块，任务执行失败时，LLM自动分析错误日志并调整参数，结合规则策略判断是否可重试，实现系统的自我修复与鲁棒性提升。

5. 前后端服务与API标准化

- a. 基于FastAPI构建RESTful后端服务，提供标准接口，集成Swagger自动文档，统一异常处理与状态码规范。

甄云SRM采购系统

前端开发

项目描述：该系统为多行业领先企业提供供应商报价、竞价管理解决方案，覆盖供应链数字化转型全流程，已接入百胜集团、麦当劳、宁德时代等企业，助力优化采购流程与成本控制。

技术栈：React16.8 + TypeScript + Redux + Choerodon-UI

核心职责：

- 1. 采用 React.memo+useMemo 优化列表渲染，针对 1000 + 行数据表格，滚动流畅度提升 50%，内存占用降低 30%。
- 2. 实现报价单 PDF 导出功能（集成 jsPDF 库），优化文件生成效率，大文件导出时间从 15s 缩短至 5s。
- 3. 配置 Webpack terser 插件与 Tree Shaking，剔除无用代码，打包效率提升 25%；通过 HTTP2 多路复用优化资源加载顺序，关键路径渲染时间缩短 30%。
- 4. 开发消息模板 SDK，支持变量动态插入（如价格公式渲染）与敏感词自动过滤（集成正则校验引擎），覆盖 10 + 业务场景。
- 5. 采用 React.lazy+Suspense 实现动态组件加载，结合 Webpack 代码分割（SplitChunksPlugin），将首屏 JS加载体积从 2.1MB 缩减至 1.9MB，白屏时间减少 40