

2001/11
18749666304

maor_yyds@163.com
4年

马傲然
AI 应用开发工程师



教育经历

河南科技大学

计算机科学与技术 · 本科

2018/09 - 2022/06

专业技能

- 掌握多智能体系统设计与编排；熟悉 **A2A** 协议；熟悉 **MCP** 协议；熟悉 **LangGraph**
- 了解JSON-RPC 2.0；了解Protobuf/gRPC；掌握 SSE 流式；熟悉 Webhook 推送
- 熟练掌握 **Python** 核心语法，熟悉 **FastAPI** 框架及其生态，熟悉 PyTorch 深度学习框架
- 掌握 **Transformer** 架构原理与应用，具备 **BERT** 模型微调
- 掌握 Prompt Engineering精通 **RAG**架构设计与实现
- 基于 **LangChain**构建应用链，覆盖文档切片、父子分块、**BGE-M3** 双向量编码、Milvus 混合检索
- 熟悉多种检索策略，具备 BERT 意图分类模型微调与部署经验。
- 熟练掌握MySQL增删改查、多表查询、索引优化，具备业务数据库设计与 FAQ 知识库建设经验。
- 熟练掌握**Milvus**，掌握 IVF_FLAT + 稀疏倒排索引
- 熟悉 Linux 环境部署，掌握Conda 环境管理及多服务协同（**MySQL + Redis + Milvus**）。
- 熟悉 Coze、Dify 等低代码 Agent 开发平台，具备插件开发、工作流编排和智能体搭建经验。

工作经历

北京极睿科技有限责任公司

算法工程师

2022/07 - 2026/07

- 负责大模型 Agent 应用的设计，基于 LLM 构建具备自主规划、工具调用、记忆检索与智能体系统
- 担任 算法工程师，负责负责意图识别，人机对话核心能力的搭建与落地
- 负责 LangGraph 实现状态机管理、节点编排、条件分支、循环与人机协同。
- 担任算法工程师，负责企业级 RAG 系统的从 0 到 1 建设

项目经历

基于 A2A 协议的多智能体互操作平台

算法工程师

2025/10 - 2026/07

项目背景：

企业客服从"单 Agent 问答机器人"进入"多 Agent 协同生产系统"阶段，但工单系统、知识库、订单、退款等渠道接口异构、集成成本高、缺乏统一标准，单点机器人难以稳定调用外部能力完成"查单-派单-处理-回访"全链路；通用大模型在客服私有场景存在知识滞后、答非所问、违规承诺等幻觉与合规问题。

技术栈：

A2A、**MCP**、**LangGraph**、**LangChain**、**Python**、**FastAPI**、**SSE 流式**、**Embedding**、**BM25**、**BGE-Reranker**、**Milvus**、**asyncio**、**RAG**

核心工作：

- **多智能体编排 (A2A + MCP)**：构建编排 多Agent + 多个专业 Agent 协作链路，Host Agent 解析意图并拆解子任务，按依赖通过 A2A 协议调度专业 Agent 并行执行，由汇总 Agent 聚合输出；
- **任务全生命周期管理**：实现 9 态任务状态机，结合 SSE 流式输出与 Webhook 推送的双通道异步更新，referenceTaskIds 编排任务依赖链。
- **A2A 协议实现**：基于官方 a2a-sdk 实现 A2A Server 与 Client，覆盖 11 个 RPC 方法通过 .well-known/agent-card.json 声明能力、技能与认证方案，实现跨框架 Agent 标准化互操作。

项目成果：

- **跨框架 Agent 接入效率提升**：单一规范源覆盖 6 种语言 SDK，新 Agent 接入由「逐个适配」变为「按规范注册」，集成效率提升约 70%。
- **长任务协作可靠性提升**：基于 Task 9 态状态机 + SSE/Webhook 双通道异步更新，长任务异常定位时间从平8 分钟缩短到2 分钟，任务全链路可审计。
- **跨域安全合规**：Agent Card 声明 OAuth2/OIDC/JWT 认证 + JWS 签名，WebHook 推送支持防 SSRF / 防重放，满足企业级合规要求。

电商智能商家助手

算法工程师

2025/01 - 2025/06

项目背景：

电商商家日常运营长期面临商品资料、平台规则、活动政策、营销 SOP、历史客服工单散落各处的痛点，导致客服与运营人员重复回答效率低、对客口径不统一、答非所问频发；

技术栈：

Python、FastAPI、SSE、**LangChain**、**LangGraph**、RAG、**BGE-M3**、Milvus、**BM25**、BGE-Reranker、MiniLM、MemorySaver、Qwen、LoRA、vLLM、PostgreSQL、Redis

核心工作：

- **电商多源文档解析与智能切分**：基于 LangChain 解析商家资料 PDF / Word、活动公告、运营 SOP 等元数据，解决商品长描述“切太碎丢上下文、切太大引噪声”以及表格型营销规则被误切的难题。
- **混合检索**：搭建 Milvus 向量检索 + BM25 关键词检索双路并行，融合商品类目 / 店铺层级 / 活动时效等元数据过滤，引入 BGE-Reranker 对候选段落重排序；
- **多 Agent 协同调度**：串联“商品答疑 / 规则解读 / 营销生成 / 投流助手”四类 Agent，按意图路由自动调度，对外暴露统一对话入口，复杂任务支持多 Agent 串行 / 并行协作。
- **RAG 编排与引用溯源**：基于 LangChain 构建“检索-增强-生成”链路，设计商品答疑 / 规则解读 / 营销文案 / 投流建议等多套 Prompt 模板，强制模型输出引用来源标记，答案可逐句回溯到原始资料。

项目成果：

- 通过 RAG 引用溯源 + 合规护栏，商家助手**答非所问率下降约 65%**，违规承诺与夸大宣传明显减少，商家投诉与平台违规处罚显著降低。
- 平台接入-商品 / 规则 / 工单文档，客服与运营平均响应耗时降低约 **70%**，新人上岗培训周期由 2 周缩短至 3 天，商家自助解决率提升约 **45%**，重复咨询率大幅下降。
- 私有化推理部署后，单位 token 推理成本较公有 API 调用降低约 **70%**，服务可用性 **99.9%**，敏感商家与交易数据实现“不出域”，通过电商平台数据安全合规评审。

项目背景：

行业大模型取代通用大模型成为落地主流，电商因业务高频、数据海量、个性化要求强成为垂直大模型热门赛道。通用大模型直接用于电商存在商品专业知识弱、买家意图理解偏差、营销话术幻觉、活动时效滞后等短板，且商家与交易数据敏感不可外泄。本项目基于开源基座做电商垂直微调，并叠加 RAG 增强，构建"私有部署、电商对齐、知识可热更新"的电商大模型应用，覆盖商家营销文案生成、智能客服多轮对话、商品搜索增强、买家导购问答四大场景。

技术栈：

LLaMA 3.1、ChatGLM 3、Qwen 2.5、LoRA、QLoRA、PEFT、SFT、RLHF、DPO、LangChain、LlamaIndex、Milvus、BGE-M3、BGE-Reranker、vLLM、AWQ、PyTorch、FastAPI

核心工作：

- **基座选型与电商微调数据构建：**在中文电商任务上的表现选定基座；基于商品标题、卖点文案、客服多轮对话、买家咨询、退换货场景构建电商 SFT 数据集，结合人工标注 + 蒸馏合成 + 安全过滤。
- **RAG 电商知识增强：**基于 LangChain 构建商品库、买家评价、活动规则、平台政策向量库，融合 BM25 关键词 + 向量混合检索与 BGE-Reranker 重排，并实现知识"热更新"

项目成果：

- 电商大模型在内部评测集（商品问答、客服场景、文案生成）上专业问答准确率显著提升，违规 / 夸大宣传类问题拒答率达到 **95%**，通过电商平台安全合规评审。
- RAG 增强后电商问答**幻觉率下降约 60%**，知识更新从"重训模型"变为"更新向量库"，迭代周期从周级降至小时级，敏感商家与交易数据实现**"不出域"**。

电商个性化推荐与搜索排序平台

项目描述：算法工程师 电商流量见顶，平台进入存量竞争，传统协同过滤与人工特征工程难以捕捉用户多样兴趣与长序列行为。项目旨在从 0 到 1 搭建工业级个性化推荐与搜索排序系统，覆盖「首页猜你喜欢」「搜索结果排序」「详情页关联推荐」等核心场景，通过深度学习建模用户动态兴趣与多目标联合优化，提升点击率、转化率。

技术栈：TensorFlow / PyTorch、DeepFM、DIN / DIEN、Transformer、BERT4Rec、GraphSAGE (GNN)、Spark / Flink、Redis、TensorRT、MLflow

核心工作：

- **搭建「召回—粗排—精排—重排」四级架构：**双塔 向量召回 + 轻量粗排，精排采用 Reranke 自动特征交叉，重排层做多样性与业务规则调控，端到端时延控制在 50ms 内。
- **构建用户行为序列建模与实时特征链路：**Transformer / GRU 提取长短期兴趣，Flink 秒级消费行为流写入 Redis 特征缓存，模型参数近实时更新，支撑大促峰值百万级 QPS。

项目成果：

- 多目标模型上线后，整体成交转化率提升约 10%，长尾商品曝光量增加约 25%，缓解头部聚集。
- 优化在线推理服务，将推理 P99 延迟优化至**百毫秒级别**，保障大促高峰高 QPS 服务稳定性；基于 Flink 构建实时特征链路，将特征更新由原 T+1 离线刷新，改造为**分钟级实时更新**。