

高瑛桢

男 | 24 岁 | 18899550891 | g18899550891@126.com

2 年工作经验 | 求职意向：大模型应用开发

专业技能

- ★ **LLM 应用开发与 Prompt 工程** — 熟练运用 DeepSeek、Qwen 等主流大模型进行应用开发，具备丰富的 Prompt 设计、提示词调优与 LLM 策略路由经验，有效控制 Token 消耗与响应质量，经生产环境验证具备高可用与可扩展能力。
- ★ **LangChain / LangGraph 多智能体编排** — 熟悉基于 LangGraph StateGraph 的多 Agent 架构设计，独立实现 Orchestrator 意图路由、单 Agent 直达 / 多 Agent 流水线 / 澄清对话三种执行模式，支持 Agent 插拔式扩展，符合开闭原则且新 Agent 零改动接入。
- ★ **RAG 增强检索全链路优化** — 熟练掌握 BM25 + BGE-M3 混合检索、BGE-Reranker 交叉编码精排、HyDE 假设文档生成、意图分类等多策略 RAG 管线，显著提升垂直领域问答的专业准确率，在实际业务中获得用户的高度认可与好评。
- ★ **向量数据库与 Embedding 技术** — 熟练使用 Milvus 向量数据库进行大规模知识索引与异步检索，掌握 BGE-M3、BGE-Reranker 等 Embedding / 重排序模型的微调、推理部署与性能优化，可支撑大规模知识库构建与日常维护工作。
- ★ **MCP 协议与工具生态集成** — 熟悉 Model Context Protocol (MCP) 协议规范，使用 FastMCP 封装知识库检索、网络搜索等工具 Server，实现大模型与外部工具的能力对接，为工具调用智能化应用落地奠定坚实基础。
- ★ **Python 后端服务与 SSE 流式输出** — 熟悉 FastAPI 框架，具备 RESTful API 设计与 SSE 事件流推送经验，实现从路由决策到 Token 级逐字输出的全链路流式响应，优化用户交互体验，积累了高并发场景下的服务开发实践经验。
- ★ **模型压缩与轻量部署** — 掌握 BERT 知识蒸馏、剪枝、量化等模型压缩技术，实现模型体积压缩至原有 1/10、推理延迟从百毫秒级降至十毫秒级，支撑边缘侧实时推理场景，可在边缘侧场景实现轻量高效部署与推理。
- ★ **Docker 容器化与工程化部署** — 熟练使用 Docker Compose 进行多服务容器化编排与本地部署，具备从开发环境到生产交付的完整工程化能力，保障多服务环境下的稳定运行与高效管理。
- ★ **多租户架构与数据隔离** — 基于 JWT Claims 实现 tenant_id 贯穿依赖注入、请求上下文与数据库层的多租户数据隔离方案，保障 SaaS 场景下的数据安全性，满足企业级数据安全与租户隔离严格要求。
- ★ **OpenClaw / AI Agent 智能体平台开发** — 熟悉 OpenClaw 等 Agent 开发框架与工具链，具备从需求分析、技术选型到上线交付的全生命周期 AI 应用开发经验，覆盖智能对话、Agent 协作、知识问答等核心场景，覆盖从需求到交付的端到端应用落地链路。

工作经历

整数智能

大模型应用开发

2024.07-至今

主导企业级 RAG 系统与多智能体 (Multi-Agent) 协同架构的设计与落地，集成“稠密+稀疏”混合检索及 Re-rank 重排序策略，利用多 Agent 任务编排机制显著解决复杂业务场景下的长尾问答与事实幻觉难题。构建全链路知识库 ETL 流水线，攻克非结构化文档解析与语义分块难点，并结合 LangHarness 建立自动化评估与可观测性体系，通过构建 Golden Test Set 持续量化检索召回率与生成质量，实现系统效果的闭环迭代。具备深厚的模型工程化能力，利用 LoRA 技术对 BERT/T5 等模型进行垂直领域微调，负责模型服务的容器化部署与推理加速（如 vLLM/TensorRT），保障高并发场景下的低延迟响应。作为 AI 技术接口人，持续

跟踪 NLP 与 LLM 前沿技术（如 Agentic Workflow），主导技术选型与方案设计，深度协同业务部门挖掘痛点，推动 AI 解决方案从概念验证到生产环境的价值转化。

项目经历

金融全链路智能投研与合规风控平台

2026.01-2026.08

项目背景： 针对研究员每天要处理海量的财报、公告和新闻，大部分时间都耗在机械的“数据搬运”上，还容易因为疲劳遗漏关键信息。所以我们就搭了一套基于 LangGraph 的多 Agent 协作架构，把任务分发给不同的专家 Agent 去处理。系统由六个 Agent 组成：金融合同审查 Agent、金融专业知识查询 Agent、投资标的评估 Agent、研报图表分析 Agent、金融计算 Agent、舆情分析 Agent 本人独立负责 金融专业知识查询 Agent ,金融合同审查 Agent 两个核心模块的设计与开发，并参与金融计算 Agent 与舆情分析 Agent 的能力建设与跨 Agent 联动设计。

技术栈： Python、LangGraph、LangChain、MCP、Milvus、bge-m3、jieba、Pydantic、PostgreSQL、FastAPI、Redis、Pandas/NumPy（金融数值计算）、GraphRAG（图谱增强检索）、多模态理解、推理模型范式（o1/R1 长思维链）、大语言模型。

工作描述：

重构金融知识库检索架构（Agentic RAG）： 针对金融研报长文本特性，设计“父子块分层索引”与“稠密+稀疏双路召回”机制。引入 Agent 自主决策四阶段检索策略（如假设问题检索、子查询拆解），结合 GraphRAG 解决跨文档多跳推理难题，使复杂金融问答的准确率与上下文完整性显著提升。

搭建并行化合同审查 workflow（LangGraph）： 开发四维并行审查节点，将贷款、对赌等复杂合同的审查耗时大幅缩短。针对高复杂度合规判定，引入长思维链（CoT）推理模型降低误判率；设计优先级排序机制，彻底解决长文本审查时核心风险点被 Token 截断丢失的问题。

实现金融数值“零幻觉”计算引擎： 摒弃大模型直接生成数值的做法，采用“模型+代码”双引擎架构。涉及 IRR、DCF 等精确运算时，强制调用 Python 执行并回填结果；针对自定义公式，自研基于 AST 的白名单安全求值器，在保障 100% 计算精度的同时拦截恶意代码注入。

构建多模态舆情与兜底防御体系： 融合多源新闻情感分值与时间衰减因子，输出量化情绪指数，并与计算、审查 Agent 联动提供深度建议。建立“检索-生成-合规”三重兜底机制（如 BM25 降级、原文脱敏返回、高风险强制人工介入），确保系统在极端情况下的可用性与金融合规性。

推进系统级工具标准化（MCP）： 引入 MCP 协议替代传统硬编码 Function Calling，实现行情接口、财报库等外部工具的即插即用与跨 Agent 共享，大幅降低系统耦合度与维护成本。

项目成果：

投研效能跃升： 深度研报生成周期由平均数天缩短至 30 分钟内，研究效率提升 300%以上；复杂金融问答的检索召回率提升至 95%+，核心事实引用准确率达 98%。

风控降本增效： 复杂合同审查耗时从小时级压缩至分钟级，高优风险点识别漏判率降至 0%；合规审查通过率提升 40%，每年为业务团队节省数百万元人力成本。

数据精准与安全： 彻底解决大模型数值计算幻觉，金融指标（PE/DCF 等）计算准确率达 100%；系统上线至今保持 0 级合规事故，三重兜底机制使系统可用性达 99.9%。

研发提效与复用： 基于 MCP 协议实现 20+ 核心金融工具的标准化接入，跨 Agent 工具复用率达 80%，新业务场景接入周期缩短 50%。

项目背景: 电商/SaaS 客服场景咨询量大且诉求高度异构——售前咨询、订单查询、退换货审批、投诉升级,四类诉求在数据来源、处理逻辑与风险等级上完全不同。团队原采用单一 Prompt 硬接所有意图,但很快遇到天花板:查订单需要调用订单系统 API,单一 Prompt 无法挂接外部系统;退换货涉及在保期、金额阈值、类目等审批规则,塞进 Prompt 既不可控也无法审计;投诉场景缺情绪感知,机械回复易激化矛盾;各类诉求相互干扰导致整体答错率居高不下。本质问题是"一个模型干所有事"与"诉求专业化、流程化"之间的矛盾。基于此重构为多 Agent 协同中台:先由意图路由 Agent 听懂诉求并判紧急度,再派发至对应专业 Agent,各自挂接业务系统与审批规则,在专业化分工中实现"听得懂、派得对、接得上、兜得住"。

技术栈: LangGraph、MCP、Milvus、bge-m3、jieba、PostgreSQL、FastAPI、Redis、PyTorch、Transformers、FastAPI、Few-shot

工作描述:

主导意图路由设计,日均省下可观 Token 成本:原方案任何消息都走大模型,成本高且慢。我设计"规则前置拦截 + LLM 分类"两段式——先用零成本规则拦下"你好/谢谢/人工"等高频元话术,再让大模型只处理真正需要理解的诉求,日均无效调用下降约 30%;同时把含"投诉、曝光、12315"等高危词的消息直接判高优先级转人工,守住投诉风险底线。

训练意图识别模型,让客服"听得懂诉求":用 BERT 微调意图分类(FAQ/订单/退换货/投诉/转人工)与情绪识别模型,替代纯关键词规则,意图路由由准确率做到 90%+(500 条人工标注测试集),投诉等高危场景识别不漏判。

搭建 RAG 知识库,让客服"答得准、答得稳":把产品手册、政策库、历史工单解析成向量知识库(Milvus + BGE-M3 + Reranker 精排),FAQ Agent 检索后生成答案并附引用来源;关键是设了降级机制——检索不到可靠依据时绝不编造、自动转人工,避免 AI 一本正经胡说带来的客诉风险。

设计退换货审批闭环,自动化释放 70% 人工工单:把"在保期/未拆封/金额阈值"等审批规则沉淀到 Agent 内,符合条件的退款自动通过、无需人工;金额超 500 或"已使用"类目强制转人工审批且不可绕过,自动与人工全程写审计日志,既提效又合规可追溯。

守住投诉安全红线,把高危客诉拦在激化前:投诉 Agent 先做情绪识别与安抚,命中"威胁曝光、群体投诉"等高危信号立即转人工坐席,并把情绪、诉求、上下文摘要一并交接,让坐席不用重新听一遍就能接手;设计原则就一条——宁可多转人工,不可漏判。

项目成果:

客服会话一次解决率由 58% 提升至 81%(口径:会话结束是否需转人工或二次进线统计,采样 3000 条会话)转人工率下降约 15 个百分点,人工坐席工单压力显著缓解, 退换货自动通过率约 70%(口径:符合自动审核规则的退款申请中,无需人工介入即完成的比例),释放人工审批工时

意图路由规则前置拦截使日均无效大模型调用下降约 30%(口径:"你好/谢谢/人工"等高频元话术占总咨询量占比),按日均咨询量估算年省 Token 成本可观

高危投诉 100% 兜底转人工,零漏判(口径:含"12315/曝光/群体投诉"等高危词的会话全部命中人工通道,人工复核无遗漏), 退换货审批全链路审计日志可追溯,自动通过与人工审批均落库,满足合规审计要求, FAQ 检索置信度低于阈值(0.6)强制转人工、不编造,杜绝 AI 幻觉引发的客诉风险

项目背景：面向金融垂直领域，构建一套支持多轮对话的智能问答系统。针对金融问题多样性（精确 FAQ vs 开放式咨询）及数据时效性要求高的痛点，设计了 **“MySQL 精确匹配 → BM25 语义检索 → RAG 增强生成”** 三级渐进式检索架构。结合自适应检索策略动态路由与混合重排序机制，实现高效、准确的知识问答服务。系统以 FastAPI + WebSocket 提供流式对话接口，支持前端实时打字输出。

技术栈：Python、FastAPI、WebSocket、LangChain、Milvus、BGE-M3、BGE-Reranker-Large、BERT、PyTorch、Transformers、Redis、MySQL、RapidOCR、RAGAS、DashScope（通义千问）

工作描述：

- 设计三级渐进式检索架构与动态路由策略：

针对金融场景对准确率的高要求，设计了“精确匹配优先，语义兜底”的分层处理机制。用户提问优先走 MySQL 知识库精确匹配（Softmax 归一化置信度阈值 0.87），命中即返回；未命中则计算 BM25 相关性分数，超过阈值直接返回预设答案；仍不满足时自动降级至 RAG 流程，由 LLM 结合检索上下文生成答案。该策略显著降低了 40% 的 LLM 调用成本，同时保证了标准问题的响应速度。

- 实现多维度自适应检索增强（Advanced RAG）：

为解决复杂金融长尾问题，实现了包含直接检索、HyDE（假设文档检索）、子查询分解检索、回溯溯源在内的 4 种检索策略动态路由。通过 LLM 构建策略选择器，根据用户 Query 的复杂度与语义特征自动选择最优检索策略，提升了复杂问题的召回率。

- 构建高精度混合重排序与父子块索引机制：

引入 WeightedRanker 实现跨语言/稀疏加权融合检索，最终取 Top-K 父文档作为上下文。设计父子块分割分块策略（父块 1000 字 / 子块 200 字），以子块粒度进行向量检索，命中后回溯至父块获取完整上下文，既保留了细粒度语义匹配，又确保了 LLM 输入上下文的完整性。

- 搭建全链路 RAG 评估体系与流式服务：

基于 RAGAS 框架构建评估体系，从忠实度、答案相关性、上下文精度等四个维度量化 RAG 管线质量。后端采用 FastAPI + WebSocket 实现流式对话接口，LLM 以 token 粒度实时推送至前端，并引入 Redis 缓存层对高频问题及答案进行缓存，减少重复计算，支持多轮上下文感知（最近 5 轮）及会话管理。

项目成果：

- 问答准确率与响应速度双突破：在金融测试集上，Top-1 准确率提升至 92%，相比单一向量检索提升 18%；通过三级路由机制，简单问题响应时间控制在 200ms 以内，复杂生成式问题首字延迟降低至 800ms。
- 检索召回能力显著增强：引入 HyDE 与父子索引策略后，针对长难句和专业术语的召回率（Recall@5）从 75% 提升至 89%，有效解决了金融研报中跨段落推理导致的“幻觉”问题。

- 系统性能与成本控制优化：通过前置精确匹配与 Redis 缓存策略，拦截了约 35% 的无效 LLM 请求，使得整体 API 调用成本降低 30%；系统上线后稳定支撑日均 2000+ 次专业金融咨询，用户满意度评分达到 4.8/5.0。

基于 Coze 平台的金融股票筛选智能体开发

2024.07-2025.01

项目背景：针对传统股票筛选过程中数据分散、指标繁杂、人工复盘耗时等痛点，基于字节跳动 Coze（扣子）AI 智能体开发平台，设计并落地了一款面向 A 股市场的股票筛选与分析智能体。该项目通过整合专业金融 Skill 与可视化 workflow，实现了从自然语言需求到结构化选股结果的自动化处理，大幅降低了专业投研工具的使用门槛。

技术栈：Coze (扣子), 可视化工作流 (Workflow), Prompt 工程, RAG (检索增强生成), 金融 Skills API, 大语言模型 (LLM) 工作描述：

- 专业金融能力集成：**在 Coze 技能商店中接入并配置了广发证券等机构提供的专业金融 Skill（如 ETF 筛选、财务对比、股票简况 F10、龙虎榜、资金异动等），将高频投研动作封装为 Agent 可直接调用的标准化能力。
- 数据获取 workflow 搭建：**利用 Coze 的工作流（Workflow）功能，串联新浪财经等数据插件与大语言模型节点。设计了“用户输入自然语言 -> 插件获取行情与财报数据 -> 大模型结构化解读 -> 输出筛选结果”的完整自动化链路。
- 多维度选股策略实现：**通过 Prompt 工程与参数配置，使智能体支持多维度、多指标、多策略的组合式筛选。用户可通过对话直接设定跟踪指数、成立时间、成交活跃度、规模等条件，智能体自动完成基本面画像与估值指标（PE、PB、ROE）的横向对比。
- 投研流程系统化：**将盘前宏观变量、盘中资金异动监控、盘后交易复盘等场景融入智能体的长期工作方式，构建了可持续运行的辅助投研系统，支持每日稳定跟踪数十个标的并自动生成复盘记录。

项目成果：

- 选股效率显著提升：单次复杂策略选股（如“低估值+高成长+近期放量”）的平均耗时从人工操作的 15 分钟缩短至 30 秒内，数据提取与整理效率提升 95%；
- 覆盖广度与深度扩展：智能体日均处理行情数据请求超 500 次，累计生成个股深度分析简报 200+份，能够同时监控 50+ 只自选股的实时异动，覆盖了人工盯盘的盲区；
- 用户使用门槛降低：成功将专业的 F10 数据分析与量化选股逻辑转化为自然语言交互，使得无编程基础的初级投资者也能独立完成专业级研报分析，用户反馈操作满意度达 4.6/5.0。

教育经历

河南工业大学 本科 金融学

2020-2024